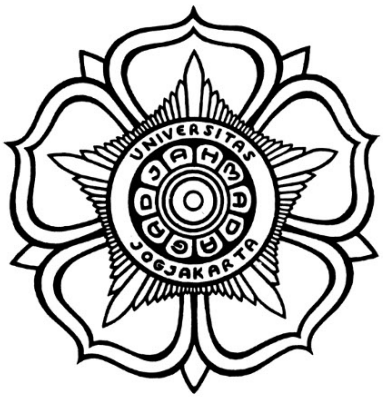
SKRIPSI

PERBANDINGAN PENALARAN DAN KOMUNIKASI BERBASIS RUANG LATEN PADA SISTEM MULTI-AGEN: *MIXTURE OF INPUTS* TERHADAP METODE PENALARAN LATEN LAIN DAN KOMUNIKASI BERBASIS TEKS.

A COMPARISON OF LATENT-SPACE REASONING AND COMMUNICATION IN MULTI-AGENT SYSTEMS: MIXTURE OF INPUTS AGAINST OTHER LATENT REASONING FORMULATIONS AND TEXT-BASED COMMUNICATION.



Harun Yahya
22/505239/PA/21749

PROGRAM SARJANA PROGRAM STUDI STATISTIKA
DEPARTEMEN MATEMATIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS GADJAH MADA
YOGYAKARTA

2026

DAFTAR ISI

DAFTAR ISI . . . . . **ii**
I PENDAHULUAN **2**
1.1. Latar Belakang 2
1.2. Pembatasan Masalah 5
1.3. Tujuan dan Manfaat Penelitian 5
1.4. Tinjauan Pustaka 6
1.5. Metodologi Penelitian 7
1.6. Sistematika Penulisan 8
II DASAR TEORI **10**
2.1. Variabel Random 10
2.1.1. Variabel Random Diskret dan Kontinu 10
2.1.2. Fungsi Distribusi Kumulatif 11
2.2. Ekspektasi dan Variansi 12
2.2.1. Ekspektasi Variabel Random 12
2.2.2. Ekspektasi Vektor Random 13
2.2.3. Variansi dan Kovariansi 14
2.2.4. Koefisien Korelasi 14
2.3. Matriks 15
2.3.1. Jenis dan Operasi Matriks 15
2.4. Vektor 16
2.4.1. Hasil Kali Dalam dan Norma Euklides 16
2.4.2. Kosinus Sudut Antar-Vektor 17
2.5. Distribusi 17
2.5.1. Distribusi Kategorik dan Vektor Indikator 17
2.5.2. Distribusi Multinomial 18
2.5.3. Distribusi Beta 19
2.5.4. Distribusi Dirichlet 22
2.6. Himpunan Konveks 24
2.6.1. Himpunan Konveks 24
2.6.2. Kombinasi Konveks dan Convex Hull 25
2.6.3. Simpleks Probabilitas 26
2.7. Entropi 27
2.7.1. Entropi Shannon 27

2.7.2. Batas Entropi 27
2.8. Inferensi Bayes 28
2.8.1. definisi Bayes: Prior, Likelihood, dan Posterior 28
2.8.2. Prior Konjugat 29
2.8.3. Kekonjugatan Dirichlet–Multinomial 29
2.8.4. Rerata Posterior sebagai Estimator Bayes 30
2.9. Model Bahasa dan Arsitektur *Transformer* 31
2.9.1. Model Bahasa Autoregresif 31
2.9.2. Jaringan Saraf, Fungsi Aktivasi, dan Fungsi *Softmax* 32
2.9.3. Mekanisme Atensi dan *KV-Cache* 34
2.9.4. Embedding Masukan dan Keluaran 35
2.9.5. *Tokenizer* dan *Byte-Pair Encoding* 36
2.10. Strategi Pengambilan Sampel Token 36
2.11. Sistem Multi-Agen 37
2.11.1. Definisi Agen dan Sistem Multi-Agen 37
2.11.2. Topologi Sekuensial dan Hierarkis 38
III METODOLOGI PENELITIAN 39
3.1. Arsitektur Qwen3-8B 39
3.1.1. Blok *Decoder* dan Aliran Residual 41
3.1.2. *Grouped-Query Attention* dan RoPE 43
3.1.3. *KV-cache* per Lapisan 45
3.1.4. *Embedding* Masukan dan Keluaran 46
3.2. Langkah Laten dalam Satu Agen 48
3.2.1. Satu *Latent Pass* 49
3.2.2. *Early Stopping* pada Langkah Laten 51
3.2.3. Dari *Hidden State* ke Distribusi Token 52
3.2.4. Kerangka Penyatuan Metode 53
3.3. Mixture of Inputs 55
3.3.1. Ukuran Ketidakpastian 57
3.3.2. *Prior* Dirichlet 58
3.3.3. Model Observasi 59
3.3.4. Pembaruan *Posterior* 61
3.3.5. Pembentukan Representasi Masukan MoI 63
3.3.6. Verifikasi Bobot MoI 64
3.3.7. Perilaku Bobot terhadap Entropi 65
3.3.8. Pengaruh Parameter β 66

3.4. Metode Pembanding 67
3.4.1. Metode `soft` 68
3.4.2. Metode `sample` 69
3.4.3. Metode `raw` 70
3.5. Komunikasi Antar-Agen 72
3.5.1. Komunikasi `text` 74
3.5.2. Komunikasi `kv` 75
3.6. Rancangan Eksperimen dan Analisis 78
3.6.1. Rancangan Eksperimen 78
3.6.2. Pengukuran dan Analisis Kinerja 81
3.6.3. Benchmark dan Metrik Evaluasi 84
3.6.4. Pengukuran Geometris 85
3.6.5. Interpolasi Geometris 90
IV HASIL DAN PEMBAHASAN 97
4.1. Deskripsi Data dan Lingkungan Eksperimental 97
4.2. Akurasi dan Keandalan Format 99
4.3. Biaya Token dan Waktu Inferensi 100
4.4. Efisiensi Medium KV terhadap Medium Teks 102
4.5. Perbandingan Berpasangan MoI terhadap metode lain 103
4.6. Geometri Vektor Langkah Laten 105
4.7. Kedekatan Geometris dan Akurasi 108
4.8. Ketakpekaan MoI terhadap β 110
4.9. Kinerja Metode Laten 112
V KESIMPULAN DAN SARAN 114
5.1. Kesimpulan 114
5.2. Saran 115
DAFTAR PUSTAKA 116
A Tabel Lengkap Sel Lengan *Benchmark* 123
B Hasil Lengkap Uji Berpasangan 125
C Hiperparameter dan Lingkungan Eksekusi 128

BAB I

PENDAHULUAN

1.1. Latar Belakang

Beberapa tahun terakhir ditandai oleh perkembangan kecerdasan buatan (*artificial intelligence*, AI) yang berlangsung sangat pesat, baik pada layanan komersial berbayar maupun pada model *open-weight*. Kapasitas komputasi AI global tumbuh rata-rata 3,3 kali per tahun sejak 2022 dan mencapai 17,1 juta *H100-equivalents* [Stanford HAI, 2026], sementara biaya inferensi untuk kemampuan yang setara dengan GPT-3.5 turun lebih dari 280 kali antara November 2022 dan Oktober 2024 [Stanford HAI, 2025].

Large Language Model (LLM) menghasilkan teks secara autoregresif. Pada setiap langkah, model menghitung distribusi peluang atas seluruh kosakata, memilih satu *token* diskret dari distribusi tersebut, menambahkannya ke rangkaian masukan, kemudian mengulangi proses yang sama untuk menghasilkan *token* berikutnya [Vaswani dkk, 2017]. Kemampuan penalaran model juga dibangun di atas mekanisme tersebut. Teknik *chain-of-thought* mendorong model untuk menghasilkan langkah-langkah penalaran dalam bentuk teks sebelum menghasilkan jawaban akhir [Wei dkk, 2022], sehingga setiap langkah penalaran tetap diwujudkan melalui pemilihan *token* diskret.

Peran LLM kemudian berkembang dari sistem percakapan menjadi *agent*. Model kini dapat melakukan pencarian informasi, terhubung dengan sumber data dan lingkungan eksternal melalui *Model Context Protocol* (MCP), memanggil *tools*, hingga mengoperasikan antarmuka komputer. *Agent* merupakan sistem yang menerima suatu tujuan, menyusun rencana, dan melakukan tindakan sesuai lingkungan secara relatif otonom [Russell dan Norvig, 2021].

Beberapa agen kemudian dapat digabungkan ke dalam satu *Multi-Agent System* (MAS). Setiap agen dapat diberikan peran yang berbeda dan saling bertukar

informasi untuk menyelesaikan suatu tugas, sehingga keseluruhan sistem dapat dipandang sebagai suatu bentuk kolaborasi antarsistem yang menyerupai tim kerja [Wooldridge dan Jennings, 1995]. MAS berbasis LLM telah digunakan dalam berbagai tugas, termasuk penalaran matematika dan sains, *question answering*, penggunaan *tools*, hingga pengambilan keputusan [Guo dkk, 2024].

Peningkatan kemampuan tersebut juga diikuti oleh peningkatan kebutuhan sumber daya komputasi. Model dengan kemampuan yang lebih tinggi pada umumnya membutuhkan kapasitas memori dan GPU yang lebih besar, sedangkan pada MAS suatu persoalan dapat diselesaikan melalui beberapa kali proses inferensi. Pada layanan komersial berbasis API, penggunaan model umumnya dikenai biaya berdasarkan jumlah *token* masukan dan keluaran [OpenAI, 2026, Anthropic, 2025]. Sementara itu, model *open-weight* yang dijalankan pada GPU lokal maupun sewaan menimbulkan biaya berdasarkan durasi penggunaan sumber daya komputasi. Dengan demikian, pada kedua skema tersebut, pengurangan jumlah *token* yang diproses dan waktu inferensi berpotensi menurunkan biaya penggunaan.

Pertimbangan lain dalam penggunaan LLM adalah privasi dan keamanan data, karena penggunaan layanan tertutup mengharuskan data dikirim dan diproses melalui infrastruktur pihak ketiga. Di antara organisasi yang mengalami insiden keamanan terkait AI, 97% menyatakan tidak memiliki kontrol akses AI yang memadai, sementara 63% belum memiliki kebijakan tata kelola AI [IBM, 2025]. Model *open-weight* yang dijalankan pada infrastruktur yang dikendalikan sendiri menjadi salah satu alternatif yang menarik, meskipun kemampuan model tersebut pada kondisi tertentu masih dapat berada di bawah model komersial.

Pada MAS berbasis LLM, komunikasi antaragen umumnya berlangsung melalui teks, yaitu keluaran satu agen dituliskan sebagai rangkaian *token* diskret sebelum digunakan sebagai masukan bagi agen berikutnya [Zou dkk, 2025]. Pendekatan tersebut memiliki keunggulan dari sisi keterbacaan dan kemudahan interpretasi, tetapi memerlukan proses *decoding* untuk menghasilkan teks dan pemrosesan kembali ketika teks tersebut digunakan sebagai masukan bagi agen berikutnya. Akibatnya, jumlah *token* yang diproses dan waktu inferensi dapat meningkat seiring

dengan bertambahnya panjang penalaran dan jumlah agen yang terlibat.

Sejumlah penelitian kemudian berupaya mengurangi ketergantungan terhadap representasi token diskret pada dua bagian yang berbeda. Pada tingkat penalaran dalam satu agen, *Soft Thinking* [Zhang dkk, 2025] dan LatentMAS [Zou dkk, 2025] mengganti pemilihan token diskret dengan representasi pada ruang kontinu atau ruang laten. Pada *Soft Thinking*, masukan untuk langkah berikutnya dibentuk dari distribusi peluang token, sedangkan pada LatentMAS representasi tersebut dapat dibentuk langsung dari *hidden state*. Pada tingkat komunikasi antaragen, LatentMAS meneruskan KV-*cache* sebagai representasi keadaan internal dari satu agen ke agen berikutnya. Pendekatan-pendekatan tersebut berpotensi mengurangi penggunaan *token* dan waktu inferensi, tetapi menghilangkan atau mengurangi representasi token diskret juga dapat memengaruhi akurasi sistem.

Mixture of Inputs (MoI) [Zhuang dkk, 2025] menempuh pendekatan yang berbeda dengan mempertahankan kedua sumber informasi tersebut, yaitu distribusi peluang keluaran model dan token yang terpilih melalui proses *sampling*. Dengan demikian, informasi mengenai kemungkinan token lain yang tersedia dalam distribusi model tidak sepenuhnya hilang setelah satu token dipilih. Penggabungan kedua sumber informasi tersebut diturunkan melalui pendekatan inferensi Bayes.

Penelitian ini menguji kedua aspek tersebut secara bersamaan dalam satu rancangan eksperimen. Pada aspek penalaran, MoI [Zhuang dkk, 2025] ditetapkan sebagai metode utama dan dibandingkan dengan tiga cara lain dalam membentuk representasi langkah penalaran, yaitu *raw* sebagaimana digunakan oleh LatentMAS, *soft*, dan *sample* yang tetap memilih satu token. Pada aspek komunikasi, komunikasi berbasis teks dibandingkan dengan komunikasi berbasis KV-*cache* sebagaimana digunakan oleh LatentMAS.

Evaluasi dilakukan menggunakan model *open-weight* Qwen3-8B [Yang dkk, 2025] pada tiga *benchmark*, yaitu GSM8K [Cobbe dkk, 2021], ARC-Challenge [Clark dkk, 2018], dan HumanEval+ [Liu dkk, 2023]. Seluruh perlakuan dilakukan secara *training-free* dan menggunakan konfigurasi bawaan masing-masing metode tanpa pencarian parameter. Dengan demikian, penelitian ini diarahkan untuk men-

jawab apakah Multi-Agent System dapat dibuat lebih efisien dalam penggunaan *token* dan waktu inferensi dengan tetap mempertahankan tingkat akurasinya.

1.2. Pembatasan Masalah

Agar penelitian tetap terarah dan tidak meluas di luar ruang lingkup yang ditetapkan, penelitian ini dibatasi pada hal-hal berikut.

1. Model bahasa yang digunakan adalah Qwen3-8B dengan inferensi lokal. Penelitian tidak menguji generalisasi terhadap ukuran maupun keluarga model bahasa lainnya.

2. Seluruh intervensi terhadap proses penalaran bersifat *training-free*. Tidak dilakukan perubahan bobot model, *fine-tuning*, maupun optimasi lainnya.

3. Metode penalaran laten yang dibandingkan dibatasi pada *raw*, *soft*, *sample*, dan *Mixture of Inputs* (MoI).

4. Medium komunikasi utama yang dibandingkan adalah komunikasi berbasis teks dan komunikasi laten berbasis KV-*cache*.

5. Evaluasi kemampuan penalaran dibatasi pada GSM8K, ARC-Challenge, dan HumanEval-Plus. Ketiga tugas digunakan untuk merepresentasikan keluaran numerik, pilihan simbolik, dan penulisan kode.

1.3. Tujuan dan Manfaat Penelitian

Sejalan dengan latar belakang yang telah diuraikan, penelitian ini bertujuan untuk:

1. Merumuskan *Mixture of Inputs* bersama tiga cara lain membentuk langkah penalaran laten, yaitu *raw*, *soft*, dan *sample*, ke dalam satu kerangka yang sama sehingga keempatnya dapat dibandingkan secara adil pada model Qwen3-8B, baik pada medium komunikasi berbasis teks maupun KV-*cache*.

2. Menganalisis efisiensi penggunaan token dan waktu inferensi dari masing-masing metode komunikasi dan penalaran laten, baik antara komunikasi berbasis teks dengan KV-*cache* maupun antar-metode KV-*cache* itu sendiri.

3. Menganalisis hubungan antara efisiensi dan akurasi untuk mengetahui metode yang memberikan keseimbangan paling baik antara pengurangan biaya komputasi dan kemampuan penyelesaian tugas.

Manfaat yang diharapkan adalah sebagai berikut.

1. Memberikan kontribusi bagi kajian komunikasi antaragen berbasis LLM, khususnya mengenai penggunaan representasi kontinu dan ruang laten sebagai alternatif penalaran berbasis token diskret, sekaligus bahan pembanding bagi penelitian lanjutan yang mengembangkan metode komunikasi laten pada Multi-Agent System.

2. Menyediakan perbandingan beberapa metode komunikasi dan representasi informasi dalam kondisi eksperimen yang terkendali, yaitu model dasar dan *benchmark* yang sama sehingga karakteristik masing-masing metode dari segi akurasi, penggunaan token, dan waktu inferensi dapat dipahami.

3. Mengetahui apakah pengurangan komunikasi berbasis teks melalui representasi laten, khususnya *Mixture of Inputs*, dapat menghasilkan Multi-Agent System yang lebih cepat dan lebih murah tanpa mengorbankan akurasi secara signifikan, sebagai pertimbangan praktis dalam merancang sistem yang dijalankan pada model *open-weight* di infrastruktur lokal maupun *cloud* GPU.

1.4. Tinjauan Pustaka

Berikut beberapa literatur kunci yang menjadi acuan penelitian ini.

Zou dkk [2025] mengusulkan LatentMAS, kerangka kolaborasi *multi-agent* di ruang laten dengan dua mekanisme yang dipakai penelitian ini. Pertama, menghasilkan pikiran laten di dalam satu agen: model menambahkan representasi lapisan terakhir secara autoregresif sebagai pengganti langkah pemilihan token, lalu

menyelaraskannya kembali ke ruang *embedding* masukan melalui pemetaan linear berbasis regresi *ridge*. Kedua, pemindahan memori kerja antaragen: KV-*cache* seluruh lapisan diteruskan dari satu agen ke agen berikutnya tanpa penulisan teks. Penelitian ini memakai mekanisme kedua sebagai medium komunikasi laten, dan mekanisme pertama sebagai salah satu formulasi penalaran yang dibandingkan (*raw*).

Zhang dkk [2025] mengusulkan *soft thinking*, yang mengganti pemilihan token diskret selama penalaran dengan *concept token* berupa kombinasi berbobot *embedding* token menurut distribusi peluangnya. Wu dkk [2025] menelaah mekanisme kerjanya dan menunjukkan bahwa penalaran lunak yang deterministik cenderung terkunci pada token berpeluang tertinggi. Penelitian ini membandingkan kedua sisi tersebut secara langsung: formulasi *soft* yang mempertahankan seluruh distribusi dan formulasi *sample* yang mengambil satu token melalui *sampling*.

Zhuang dkk [2025] mengusulkan *Mixture of Inputs* dan memandang pembentukan masukan bagi langkah berikutnya sebagai persoalan inferensi Bayes. Distribusi peluang keluaran model diperlakukan sebagai parameter konsentrasi *prior* Dirichlet dan token hasil pengambilan sampel sebagai satu observasi multinomial, sehingga melalui kekonjugatan Dirichlet–Multinomial diperoleh *posterior* berbentuk tertutup. Masukan bagi langkah berikutnya dibentuk dari ekspektasi *posterior* $\mathbb{E}[w \mid \cdot]$ atas bobot campuran tersebut, dengan besar kontribusi *prior* relatif terhadap observasi diatur oleh entropi distribusi, yaitu oleh tingkat keyakinan model, sehingga metode tersebut menyesuaikan diri tanpa penalaan parameter. MoI dirancang untuk penalaran satu model dan belum diuji sebagai mekanisme komunikasi pada sistem *multi-agent*; celah itulah yang menjadi titik tolak penelitian ini.

Hao dkk [2024] dan survei Chen dkk [2025] menempatkan ketiga pendekatan di atas dalam paradigma penalaran laten yang lebih luas, yaitu pemindahan langkah penalaran dari barisan token diskret ke ruang representasi kontinu.

1.5. Metodologi Penelitian

Metodologi yang digunakan adalah studi literatur dan eksperimen terkendali. Studi literatur dilakukan dengan menelaah publikasi mengenai penalaran laten,

kolaborasi *multi-agent*, dan evaluasi model bahasa, kemudian menurunkan persamaan langkah laten tiap metode dari sumber aslinya ke dalam satu kerangka notasi yang sama. Eksperimen dilakukan dengan menjalankan sistem *multi-agent* berbasis model *open-weight* Qwen3-8B pada tolok ukur GSM8K, ARC-Challenge, dan HumanEval+. Medium komunikasi antaragen dan formulasi representasi laten diperlakukan sebagai faktor yang divariasikan, sedangkan model, topologi agen, *prompt*, banyaknya langkah laten, suhu. Seluruh kondisi dievaluasi pada soal yang sama sehingga perbandingannya bersifat berpasangan.

1.6. Sistematika Penulisan

Penyusunan laporan ini mengacu pada sistematika berikut.

BAB I PENDAHULUAN

Bab ini berisi latar belakang, pembatasan masalah, tujuan dan manfaat penelitian, tinjauan pustaka, metodologi penelitian, dan sistematika penulisan.

BAB II LANDASAN TEORI

Bab ini menguraikan dasar teori yang digunakan, mencakup probabilitas dan distribusi yang relevan, teori informasi, inferensi Bayes, aljabar linear dan representasi vektor, arsitektur *transformer* beserta KV-*cache*, penalaran laten dan keempat formulasi pembentukan representasi laten, sistem *multi-agent*, konsep evaluasi empiris model bahasa, dan pengujian statistik yang dipakai.

BAB III METODOLOGI PENELITIAN

Bab ini menetapkan objek penelitian berupa persamaan langkah laten, menurunkan keempat persamaan yang dibandingkan ke dalam satu kerangka bersama, menyatakan rancangan dua sumbu eksperimen, hipotesis, data dan tugas evaluasi, protokol pengambilan sampel berpasangan, metrik, serta prosedur analisis statistik.

BAB IV HASIL DAN PEMBAHASAN

Bab ini menyajikan hasil eksperimen beserta pembahasannya, mencakup perbandingan akurasi antar-persamaan, keterbedaan hasil menurut jenis tugas, biaya komputasi medium laten, fidelitas simbolik keluaran, bukti mekanisme yang

menjelaskan pola hasil, serta batas berlaku seluruh temuan.

BAB V KESIMPULAN DAN SARAN

Bab ini memuat kesimpulan yang menjawab tujuan penelitian beserta saran bagi penelitian selanjutnya.

BAB II

DASAR TEORI

2.1. Variabel Random

Variabel random memetakan setiap hasil suatu percobaan acak ke sebuah bilangan real sehingga hasil percobaan dapat diperlakukan secara kuantitatif.

Definisi 2.1.1 (Bain dan Engelhardt, 1992) *Variabel random X adalah fungsi dengan daerah asal ruang sampel S yang memetakan setiap anggota S ke bilangan real,*

$$X : S \longrightarrow \mathbb{R}, \qquad X(e) = x, \quad e \in S,\ x \in \mathbb{R}.$$

Variabel random dinotasikan dengan huruf kapital X, Y, Z, sedangkan nilai yang mungkin diambil dinotasikan dengan huruf kecil x, y, z. Berdasarkan himpunan nilai yang mungkin diambil, variabel random dibedakan menjadi diskret dan kontinu.

2.1.1. Variabel Random Diskret dan Kontinu

Variabel random dibedakan menjadi variabel random diskret dan kontinu berdasarkan himpunan nilai yang mungkin diambil serta cara distribusi probabilitasnya dinyatakan.

Definisi 2.1.2 (Bain dan Engelhardt, 1992) *Variabel random X disebut diskret apabila himpunan semua nilai yang mungkin diambil, $\{x_1, x_2, x_3, \ldots\}$, merupakan himpunan terhitung (countable).*

Untuk variabel random diskret, distribusi probabilitas dinyatakan melalui fungsi massa peluang (*probability mass function*, pmf).

Definisi 2.1.3 (Bain dan Engelhardt, 1992) *Fungsi massa peluang dari variabel*

random diskret X adalah fungsi p_X yang didefinisikan sebagai

$$p_X(x) = P(X = x), \qquad x \in \mathcal{X}, \tag{2.1}$$

dengan $\mathcal{X}$ merupakan himpunan nilai yang mungkin diambil oleh X. Fungsi tersebut memenuhi

$$p_X(x) \geq 0, \qquad \sum_{x \in \mathcal{X}} p_X(x) = 1. \tag{2.2}$$

Sementara itu, variabel random kontinu didefinisikan melalui fungsi distribusi kumulatifnya yang dapat dinyatakan sebagai integral suatu fungsi kepadatan peluang.

Definisi 2.1.4 (Bain dan Engelhardt, 1992) *Variabel random X disebut kontinu apabila terdapat fungsi f_X, yang disebut fungsi kepadatan peluang (probability density function, pdf), sedemikian sehingga fungsi distribusi kumulatifnya memenuhi*

$$F_X(x) = \int_{-\infty}^{x} f_X(t)\, dt, \qquad x \in \mathbb{R}. \tag{2.3}$$

Definisi 2.1.5 (Bain dan Engelhardt, 1992) *Fungsi f_X merupakan fungsi kepadatan peluang dari variabel random kontinu X jika memenuhi*

$$f_X(x) \geq 0, \qquad x \in \mathbb{R}, \tag{2.4}$$

dan

$$\int_{-\infty}^{\infty} f_X(x)\, dx = 1. \tag{2.5}$$

Peluang bahwa X berada pada interval $[a, b]$, dengan $a \leq b$, diperoleh melalui

$$P(a \leq X \leq b) = \int_{a}^{b} f_X(x)\, dx. \tag{2.6}$$

2.1.2. Fungsi Distribusi Kumulatif

Fungsi distribusi kumulatif (*cumulative distribution function*, CDF) menyatakan peluang bahwa suatu variabel random mengambil nilai yang tidak lebih besar

daripada suatu nilai tertentu.

Definisi 2.1.6 (Bain dan Engelhardt, 1992) *Fungsi distribusi kumulatif dari variabel random X didefinisikan sebagai*

$$F_X(x) = P(X \leq x), \qquad x \in \mathbb{R}. \tag{2.7}$$

Fungsi distribusi kumulatif bersifat monoton tak turun dan kontinu kanan, serta memenuhi

$$\lim_{x \to -\infty} F_X(x) = 0, \qquad \lim_{x \to \infty} F_X(x) = 1. \tag{2.8}$$

Untuk variabel random diskret dengan fungsi massa peluang p_X, fungsi distribusi kumulatif dapat dituliskan sebagai

$$F_X(x) = \sum_{\substack{t \in \mathcal{X} \\ t \leq x}} p_X(t). \tag{2.9}$$

2.2. Ekspektasi dan Variansi

2.2.1. Ekspektasi Variabel Random

Ekspektasi merupakan salah satu ukuran yang digunakan untuk menunjukkan nilai rata-rata yang diharapkan dari suatu variabel random. Untuk variabel random diskret, ekspektasi diperoleh melalui penjumlahan nilai-nilai yang mungkin, sedangkan untuk variabel random kontinu digunakan integral.

Definisi 2.2.1 (Subanar, 2013) *Ekspektasi atau expected value dari variabel random X dapat ditulis sebagai*

$$\mathbb{E}[X] = \begin{cases} \displaystyle\sum_{x} x f(x), & X \textit{ diskret dengan pmf } f, \\ \displaystyle\int_{-\infty}^{\infty} x f(x)\, dx, & X \textit{ kontinu dengan pdf } f. \end{cases} \tag{2.10}$$

dengan syarat jumlahan atau integral tersebut konvergen. Ekspektasi $\mathbb{E}[X]$ juga biasa dinotasikan dengan μ atau μ_X.

Untuk fungsi dari suatu variabel random, ekspektasi dapat diperoleh dengan menggantikan x pada Persamaan (2.10) dengan fungsi tersebut.

Definisi 2.2.2 (Bain dan Engelhardt, 1992) *Jika u merupakan fungsi bernilai real dari variabel random X, maka*

$$\mathbb{E}[u(X)] = \begin{cases} \sum\limits_{x} u(x) f(x), & X \textit{ diskret}, \\ \int_{-\infty}^{\infty} u(x) f(x)\, dx, & X \textit{ kontinu}. \end{cases} \tag{2.11}$$

Salah satu sifat penting dari ekspektasi adalah sifat linearitas. Jika terdapat dua fungsi dari variabel random yang dikalikan dengan suatu konstanta, maka ekspektasinya dapat dihitung secara terpisah.

2.2.2. Ekspektasi Vektor Random

Ekspektasi suatu vektor random diperoleh dengan menghitung ekspektasi dari setiap komponennya. Dengan demikian, setiap komponen pada vektor ekspektasi menyatakan nilai harapan dari komponen vektor random yang bersesuaian. Sehingga untuk vektor random $\boldsymbol{X}$, Ekspektasinya adalah

$$\mathbb{E}[\boldsymbol{X}] = \big(\mathbb{E}[X_1], \ldots, \mathbb{E}[X_p]\big)^\top \in \mathbb{R}^p. \tag{2.12}$$

Jika $\boldsymbol{u}(X) = (u_1(X), \ldots, u_p(X))^\top$, maka ekspektasi juga dapat diterapkan pada setiap komponen sehingga

$$\mathbb{E}[\boldsymbol{u}(X)] = \begin{cases} \sum\limits_{x} \boldsymbol{u}(x) f(x), & X \text{ diskret}, \\ \int_{-\infty}^{\infty} \boldsymbol{u}(x) f(x)\, dx, & X \text{ kontinu}. \end{cases} \tag{2.13}$$

Hasil dari Persamaan (2.13) merupakan sebuah vektor yang berada di $\mathbb{R}^p$.

2.2.3. Variansi dan Kovariansi

Variansi mengukur seberapa besar penyebaran nilai suatu variabel random terhadap nilai harapannya. Variansi yang kecil menunjukkan bahwa nilai variabel cenderung berada dekat dengan nilai harapannya, sedangkan variansi yang besar menunjukkan penyebaran yang lebih luas.

Definisi 2.2.3 (Bain dan Engelhardt, 1992) *Variansi variabel random X didefinisikan sebagai*

$$\mathrm{Var}(X) = \mathbb{E}\left[(X - \mathbb{E}[X])^2\right]. \tag{2.14}$$

Variansi juga dapat dinotasikan dengan σ^2 atau σ_X^2. Akar kuadrat dari variansi disebut standar deviasi, yaitu

$$\sigma = \sqrt{\mathrm{Var}(X)}. \tag{2.15}$$

Kovariansi mengukur kecenderungan dua variabel random berubah bersama. Kovariansi positif menunjukkan kecenderungan perubahan searah, sedangkan kovariansi negatif menunjukkan kecenderungan perubahan berlawanan arah. Kovariansi antara X dan Y didefinisikan sebagai

$$\mathrm{Cov}(X, Y) = \mathbb{E}\left[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])\right]. \tag{2.16}$$

Variansi merupakan kasus khusus kovariansi ketika kedua variabel yang dibandingkan adalah variabel yang sama, yaitu $\mathrm{Cov}(X, X) = \mathrm{Var}(X)$.

2.2.4. Koefisien Korelasi

Kovariansi menunjukkan arah hubungan antara dua variabel random, tetapi nilainya dipengaruhi oleh skala masing-masing variabel. Oleh karena itu, hubungan tersebut dapat dinyatakan dalam bentuk yang telah dinormalisasi menggunakan koefisien korelasi.

Definisi 2.2.4 (Bain dan Engelhardt, 1992) *Jika* $\mathrm{Var}(X) > 0$ *dan* $\mathrm{Var}(Y) > 0$,

maka koefisien korelasi antara X dan Y didefinisikan sebagai

$$\rho_{XY} = \frac{\mathrm{Cov}(X,Y)}{\sqrt{\mathrm{Var}(X)\,\mathrm{Var}(Y)}}, \qquad -1 \leq \rho_{XY} \leq 1. \tag{2.17}$$

Nilai ρ_{XY} berada antara -1 dan 1. Nilai positif menunjukkan kecenderungan hubungan searah, sedangkan nilai negatif menunjukkan kecenderungan hubungan berlawanan arah. Jika nilainya mendekati nol, hubungan linear antara X dan Y semakin lemah.

2.3. Matriks

2.3.1. Jenis dan Operasi Matriks

Definisi 2.3.1 (Anton dan Rorres, 2010) *Matriks berordo $m \times n$ adalah susunan bilangan real dalam m baris dan n kolom, yang dinotasikan sebagai*

$$A = [a_{ij}] \in \mathbb{R}^{m \times n}, \tag{2.18}$$

dengan a_{ij} menyatakan elemen pada baris ke-i dan kolom ke-j.

Matriks bujur sangkar memiliki jumlah baris dan kolom yang sama. Beberapa jenis matriks bujur sangkar yang umum digunakan adalah matriks identitas, matriks diagonal, dan matriks simetris. Matriks identitas I memiliki elemen diagonal utama bernilai satu dan elemen lainnya bernilai nol. Matriks diagonal memiliki elemen bernilai nol di luar diagonal utama, sedangkan matriks simetris memenuhi $A^\top = A$.

Operasi dasar matriks meliputi penjumlahan, perkalian dengan skalar, dan perkalian antarmatriks. Untuk matriks $A = [a_{ij}]$ dan $B = [b_{ij}]$ yang berordo sama, serta skalar $c \in \mathbb{R}$, berlaku

$$(A + B)_{ij} = a_{ij} + b_{ij}, \tag{2.19}$$

$$(cA)_{ij} = ca_{ij}. \tag{2.20}$$

Jika $A \in \mathbb{R}^{m\times n}$ dan $C \in \mathbb{R}^{n\times p}$, perkalian matriks didefinisikan sebagai

$$(AC)_{ik} = \sum_{j=1}^{n} a_{ij}c_{jk}. \tag{2.21}$$

Penjumlahan memerlukan kedua matriks berordo sama, sedangkan perkalian memerlukan jumlah kolom matriks pertama sama dengan jumlah baris matriks kedua.

2.4. Vektor

Definisi 2.4.1 (Anton dan Rorres, 2010) *Vektor berdimensi n adalah unsur $\mathbb{R}^n$, dituliskan sebagai matriks kolom $x = (x_1, \ldots, x_n)^\top \in \mathbb{R}^{n\times 1}$ atau matriks baris $x^\top \in \mathbb{R}^{1\times n}$.*

2.4.1. Hasil Kali Dalam dan Norma Euklides

Definisi 2.4.2 (Anton dan Rorres, 2010) *Hasil kali dalam (dot product) dua vektor*

$$x = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}, \qquad y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} \in \mathbb{R}^n \tag{2.22}$$

adalah skalar

$$\langle x, y\rangle = x^\top y = \sum_{i=1}^{n} x_i y_i. \tag{2.23}$$

Definisi 2.4.3 (Anton dan Rorres, 2010) *Norma Euklides vektor $x \in \mathbb{R}^n$ adalah*

$$\|x\| = \sqrt{\langle x, x\rangle} = \Big(\sum_{i=1}^{n} x_i^2\Big)^{1/2}. \tag{2.24}$$

Definisi 2.4.4 (Ketaksamaan Cauchy–Schwarz; Anton dan Rorres, 2010) *Untuk setiap $x = (x_1, \ldots, x_n)^\top, y = (y_1, \ldots, y_n)^\top \in \mathbb{R}^n$,*

$$|\langle x, y\rangle| \le \|x\|\,\|y\|, \tag{2.25}$$

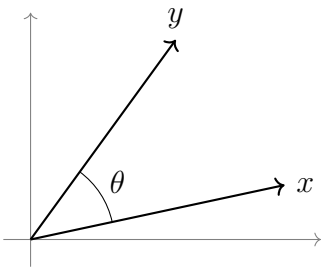
yakni, dalam bentuk komponen,

$$\Big|\sum_{i=1}^{n} x_i y_i\Big| \;\le\; \Big(\sum_{i=1}^{n} x_i^2\Big)^{1/2}\Big(\sum_{i=1}^{n} y_i^2\Big)^{1/2}. \tag{2.26}$$

2.4.2. Kosinus Sudut Antar-Vektor

Definisi 2.4.5 (Anton dan Rorres, 2010) *Untuk $x, y \in \mathbb{R}^n$ taknol, kosinus sudut antara x dan y adalah*

$$\cos(x,y) = \frac{\langle x, y\rangle}{\|x\|\,\|y\|} = \frac{\displaystyle\sum_{i=1}^{n} x_i y_i}{\Big(\displaystyle\sum_{i=1}^{n} x_i^2\Big)^{1/2}\Big(\displaystyle\sum_{i=1}^{n} y_i^2\Big)^{1/2}}. \tag{2.27}$$



Gambar 2.1 Sudut θ antara dua vektor $x, y \in \mathbb{R}^2$; menurut Persamaan (2.27)**,** $\cos\theta = \cos(x,y)$**.**

Untuk setiap x, y taknol, definisi 2.4.4 memberikan $-1 \le \cos(x,y) \le 1$; $\cos(x,y) = 1$ apabila $x = cy$ untuk suatu $c > 0$ (searah), dan $\cos(x,y) = 0$ apabila $\langle x, y\rangle = 0$ (ortogonal). Pada Gambar 2.1 kedua kasus berturut-turut bersesuaian dengan $\theta = 0$ dan $\theta = 90°$.

2.5. Distribusi

2.5.1. Distribusi Kategorik dan Vektor Indikator

Distribusi kategorik dapat dipandang sebagai kasus khusus distribusi multinomial dengan satu percobaan. Misalkan variabel random Y mengambil nilai dalam himpunan $\{1, \ldots, V\}$.

Definisi 2.5.1 (Casella dan Berger, 2002) *Variabel random Y dikatakan berdistribusi kategorik dengan parameter $\boldsymbol{p} = (p_1, \ldots, p_V)^\top$ jika fungsi massa probabilitasnya memenuhi*

$$P(Y = i) = p_i, \qquad i = 1, \ldots, V, \tag{2.28}$$

dengan $p_i \geq 0$ untuk setiap i dan $\sum_{i=1}^{V} p_i = 1$.

Setiap kategori i dapat direpresentasikan menggunakan vektor indikator atau vektor *one-hot* $\boldsymbol{e}_i \in \{0, 1\}^V$, yang didefinisikan sebagai

Definisi 2.5.2 *Vektor indikator $\boldsymbol{e}_i$ untuk kategori ke-i merupakan vektor berdimensi V yang komponen ke-i-nya bernilai satu dan seluruh komponen lainnya bernilai nol. Secara matematis,*

$$(\boldsymbol{e}_i)_j = \begin{cases} 1, & j = i, \\ 0, & j \neq i. \end{cases} \tag{2.29}$$

Setiap vektor indikator memiliki tepat satu komponen bernilai satu, sedangkan komponen lainnya bernilai nol. Jika Y merupakan variabel random dengan distribusi kategorik, maka $\boldsymbol{e}_Y$ menyatakan vektor indikator untuk kategori yang terpilih, sedangkan vektor $\boldsymbol{p}$ menyatakan probabilitas untuk seluruh kategori.

2.5.2. Distribusi Multinomial

Distribusi multinomial merupakan perluasan distribusi kategorik untuk memodelkan peluang kemunculan setiap kategori dalam sejumlah percobaan independen. Misalkan $Y_1, \ldots, Y_n$ merupakan variabel random independen dan berdistribusi identik secara kategorik dengan parameter $\boldsymbol{p} = (p_1, \ldots, p_V)^\top$.

Definisi 2.5.3 (Bain dan Engelhardt, 1992) *Misalkan N_i menyatakan banyaknya kemunculan kategori ke-i dalam n percobaan, yaitu*

$$N_i = \sum_{t=1}^{n} \mathbb{I}(Y_t = i), \qquad i = 1, \ldots, V, \tag{2.30}$$

dengan $\mathbb{I}(Y_t = i)$ bernilai satu jika $Y_t = i$ dan nol selainnya. Vektor peluang

$\boldsymbol{N} = (N_1, \ldots, N_V)^\top$ dikatakan berdistribusi multinomial dengan parameter n dan $\boldsymbol{p}$, ditulis

$$\boldsymbol{N} \sim \text{Multinomial}(n, \boldsymbol{p}),$$

jika fungsi massa probabilitasnya adalah

$$P(\boldsymbol{N} = \boldsymbol{c}) = \frac{n!}{\prod_{i=1}^{V} c_i!} \prod_{i=1}^{V} p_i^{c_i}, \tag{2.31}$$

untuk $c_i \in \{0, 1, 2, \ldots\}$ dengan $\sum_{i=1}^{V} c_i = n$, serta $p_i \geq 0$ dan $\sum_{i=1}^{V} p_i = 1$.

Pada Persamaan (2.31), c_i menyatakan peluang pengamatan pada kategori ke-i, sedangkan p_i merupakan probabilitas kategori tersebut pada setiap percobaan. Faktor $n!/\prod_{i=1}^{V} c_i!$ menyatakan banyaknya susunan hasil percobaan yang menghasilkan vektor peluang $\boldsymbol{c}$ yang sama.

Dalam inferensi Bayes, apabila parameter probabilitas $\boldsymbol{p}$ tidak diketahui dan diperlakukan sebagai parameter random $\boldsymbol{\theta}$, fungsi massa probabilitas multinomial menjadi likelihood bagi $\boldsymbol{\theta}$, yaitu

$$f(\boldsymbol{c} \mid \boldsymbol{\theta}) = \frac{n!}{\prod_{i=1}^{V} c_i!} \prod_{i=1}^{V} \theta_i^{c_i}. \tag{2.32}$$

Bentuk likelihood tersebut digunakan untuk memperoleh distribusi posterior ketika distribusi prior bagi $\boldsymbol{\theta}$ mengikuti distribusi Dirichlet.

2.5.3. Distribusi Beta

Distribusi Beta merupakan salah satu distribusi kontinu yang banyak digunakan untuk memodelkan parameter yang nilainya berada pada interval $(0, 1)$. Distribusi ini memiliki dua parameter bentuk, yaitu a dan b. Sebelum mendefinisikan distribusi Beta, diperlukan dua fungsi yang berkaitan dengan konstanta normalisasinya, yaitu fungsi Gamma dan fungsi Beta.

Definisi 2.5.4 (Casella dan Berger, 2002) *Fungsi Gamma didefinisikan sebagai*

$$\Gamma(a) = \int_0^\infty t^{a-1} e^{-t}\, dt, \qquad a > 0. \tag{2.33}$$

Salah satu sifat penting dari fungsi Gamma adalah hubungan rekursif

$$\Gamma(a+1) = a\Gamma(a). \tag{2.34}$$

Sifat tersebut diperoleh lewat integrasi parsial pada Persamaan (2.33): dengan $u = t^a$ dan $dv = e^{-t}dt$ (sehingga $du = at^{a-1}dt$ dan $v = -e^{-t}$),

$$\Gamma(a+1) = \int_0^\infty t^a e^{-t}\, dt = \left[-t^a e^{-t}\right]_0^\infty + a\int_0^\infty t^{a-1} e^{-t}\, dt = a\Gamma(a). \tag{2.35}$$

Khusus untuk bilangan bulat positif n, karena $\Gamma(1) = \int_0^\infty e^{-t}\, dt = 1$, sifat rekursif tersebut memberikan $\Gamma(n) = (n-1)\Gamma(n-1) = (n-1)(n-2)\Gamma(n-2) = \cdots = (n-1)!$, sehingga fungsi Gamma dapat dipandang sebagai perluasan konsep faktorial ke nilai parameter yang tidak harus berupa bilangan bulat.

Selanjutnya, fungsi Beta didefinisikan menggunakan fungsi Gamma.

Definisi 2.5.5 (Casella dan Berger, 2002) *Fungsi Beta didefinisikan sebagai*

$$B(a,b) = \frac{\Gamma(a)\Gamma(b)}{\Gamma(a+b)}, \qquad a, b > 0. \tag{2.36}$$

Fungsi tersebut juga dapat dituliskan dalam bentuk integral sebagai

$$B(a,b) = \int_0^1 x^{a-1}(1-x)^{b-1}\, dx. \tag{2.37}$$

Bentuk integral pada Persamaan (2.37) nantinya digunakan untuk menghitung integral yang muncul pada distribusi Beta.

Definisi 2.5.6 (Bain dan Engelhardt, 1992) *Variabel random kontinu X dikatakan berdistribusi Beta dengan parameter $a, b > 0$, ditulis*

$$X \sim \text{Beta}(a,b),$$

jika fungsi kepadatannya adalah

$$f(x;a,b) = \frac{1}{B(a,b)} x^{a-1}(1-x)^{b-1}, \qquad 0 < x < 1. \tag{2.38}$$

Faktor $1/B(a,b)$ pada Persamaan (2.38) berfungsi sebagai konstanta normalisasi sehingga total luas di bawah fungsi kepadatan pada interval $(0,1)$ bernilai satu.

Salah satu sifat distribusi Beta yang akan digunakan adalah nilai ekspektasinya. Berdasarkan definisi ekspektasi untuk variabel random kontinu (2.10) dan fungsi kepadatan pada Persamaan (2.38),

$$\mathbb{E}[X] = \int_0^1 x f(x;a,b)\,dx = \frac{1}{B(a,b)} \int_0^1 x^a (1-x)^{b-1}\,dx = \frac{B(a+1,b)}{B(a,b)}, \tag{2.39}$$

karena faktor x dari definisi ekspektasi bergabung dengan x^{a-1} dari kepadatan menjadi x^a, dan berdasarkan fungsi Beta pada Persamaan (2.37) dengan parameter pertama $a+1$. Menguraikan $B(a+1,b)$ dan $B(a,b)$ memakai definisi fungsi Beta pada Persamaan (2.36) dan menyederhanakan faktor $\Gamma(b)$ yang sama pada pembilang dan penyebut,

$$\mathbb{E}[X] = \frac{\Gamma(a+1)\Gamma(b)/\Gamma(a+b+1)}{\Gamma(a)\Gamma(b)/\Gamma(a+b)} = \frac{\Gamma(a+1)}{\Gamma(a)} \cdot \frac{\Gamma(a+b)}{\Gamma(a+b+1)}. \tag{2.40}$$

Menerapkan sifat rekursif Gamma, $\Gamma(a+1) = a\Gamma(a)$ dan $\Gamma(a+b+1) = (a+b)\Gamma(a+b)$, kedua faktor Gamma saling menghilangkan dan

$$\mathbb{E}[X] = \frac{a}{a+b}. \tag{2.41}$$

Hasil ini menunjukkan bahwa parameter a dan b menentukan posisi rata-rata distribusi Beta pada interval $(0,1)$, sehingga nilai ekspektasi semakin besar ketika a semakin besar relatif terhadap b.

2.5.4. Distribusi Dirichlet

Definisi 2.5.7 (Gelman dkk, 2013) *Untuk* $\alpha = (\alpha_1, \ldots, \alpha_V)$, $\alpha_i > 0$, *dan* $\alpha_0 = \sum_{i=1}^{V} \alpha_i$, *fungsi Beta multivariat adalah*

$$B(\alpha) = \frac{\prod_{i=1}^{V} \Gamma(\alpha_i)}{\Gamma(\alpha_0)}. \tag{2.42}$$

Fungsi Beta multivariat muncul sebagai konstanta normalisasi kepadatan Dirichlet, karena berlaku identitas (dikenal sebagai *Integral Dirichlet*)

$$\int_{\Delta^{V-1}} \prod_{i=1}^{V} \theta_i^{\alpha_i - 1} \, d\theta = B(\alpha), \tag{2.43}$$

Integral diambil atas simpleks Δ^{V-1} (Definisi 2.6.4) dan $d\theta = d\theta_1 \cdots d\theta_{V-1}$ ($\theta_V = 1 - \sum_{i<V} \theta_i$; ditentukan oleh $\theta_1, \ldots, \theta_{V-1}$). Pembuktian Persamaan (2.43) memakai representasi V variabel Gamma independen $G_i \sim \mathrm{Gamma}(\alpha_i, 1)$ dan substitusi $\theta_i = G_i / \sum_j G_j$, yang melibatkan kalkulus peubah-banyak (Jacobian transformasi) Gelman dkk [2013].

Definisi 2.5.8 (Gelman dkk, 2013) *Vektor random* $\theta = (\theta_1, \ldots, \theta_V)^\top$ *berdistribusi Dirichlet dengan parameter konsentrasi* $\alpha = (\alpha_1, \ldots, \alpha_V)$, $\alpha_i > 0$, *ditulis* $\theta \sim \mathrm{Dir}(\alpha)$, *apabila* θ *bertumpu pada* Δ^{V-1} *dengan kepadatan*

$$f(\theta; \alpha) = \frac{1}{B(\alpha)} \prod_{i=1}^{V} \theta_i^{\alpha_i - 1}. \tag{2.44}$$

Persamaan (2.44) adalah kepadatan bernilai taknegatif dan berintegral satu dari Persamaan (2.43).

Untuk $V = 2$, distribusi Dirichlet berimpit dengan distribusi Beta. Simpleks $\Delta^1 = \{(\theta_1, \theta_2) : \theta_1 + \theta_2 = 1,\ \theta_i \geq 0\}$ setara dengan selang $\theta_1 \in (0, 1)$, karena $\theta_2 = 1 - \theta_1$ ditentukan sepenuhnya oleh θ_1. Menuliskan $\theta = \theta_1$, $a = \alpha_1$, $b = \alpha_2$,

dan mengganti θ_2 dengan $1 - \theta$ pada Persamaan (2.44),

$$f(\theta; \alpha) = \frac{1}{B(\alpha_1, \alpha_2)} \theta_1^{\alpha_1 - 1} \theta_2^{\alpha_2 - 1} = \frac{1}{B(a, b)} \theta^{a-1} (1 - \theta)^{b-1}, \tag{2.45}$$

karena $B(\alpha_1, \alpha_2) = \Gamma(\alpha_1)\Gamma(\alpha_2)/\Gamma(\alpha_1 + \alpha_2)$ pada Persamaan (2.42) menyerupai $B(a, b)$ pada Persamaan (2.36) untuk $V = 2$. Ruas kanan tersebut menyerupai kepadatan Beta pada Persamaan (2.38), sehingga distribusi Beta adalah kasus khusus Dirichlet untuk $V = 2$.

Nilai ekspektasi θ_i diperoleh berdasarkan definisi ekspektasi variabel random kontinu dan fungsi kepadatan Dirichlet pada Persamaan (2.44). Dengan demikian,

$$\mathbb{E}[\theta_i] = \int_{\Delta^{V-1}} \theta_i f(\theta; \alpha)\, d\theta \tag{2.46}$$

$$= \frac{1}{B(\alpha)} \int_{\Delta^{V-1}} \theta_i \prod_{j=1}^{V} \theta_j^{\alpha_j - 1}\, d\theta \tag{2.47}$$

$$= \frac{1}{B(\alpha)} \int_{\Delta^{V-1}} \theta_i^{\alpha_i} \prod_{j \neq i} \theta_j^{\alpha_j - 1}\, d\theta. \tag{2.48}$$

Karena $\theta_i \theta_i^{\alpha_i - 1} = \theta_i^{\alpha_i}$, integral (2.48) dapat dinyatakan menggunakan fungsi Beta multivariat pada Persamaan (2.43), dengan parameter ke-i dinaikkan dari α_i menjadi $\alpha_i + 1$. Oleh karena itu,

$$\mathbb{E}[\theta_i] = \frac{B(\alpha_1, \ldots, \alpha_i + 1, \ldots, \alpha_V)}{B(\alpha)}. \tag{2.49}$$

Berdasarkan definisi fungsi Beta multivariat pada Persamaan (2.42), diperoleh

$$\mathbb{E}[\theta_i] = \frac{\frac{\Gamma(\alpha_i + 1)\prod_{j \neq i}\Gamma(\alpha_j)}{\Gamma(\alpha_0 + 1)}}{\frac{\prod_{j=1}^{V}\Gamma(\alpha_j)}{\Gamma(\alpha_0)}} \tag{2.50}$$

$$= \frac{\Gamma(\alpha_i + 1)}{\Gamma(\alpha_i)} \cdot \frac{\Gamma(\alpha_0)}{\Gamma(\alpha_0 + 1)}. \tag{2.51}$$

Sifat rekursif fungsi Gamma pada Persamaan (2.34), yaitu $\Gamma(a+1) = a\Gamma(a)$, diperoleh

$$\mathbb{E}[\theta_i] = \frac{\alpha_i\Gamma(\alpha_i)}{\Gamma(\alpha_i)} \cdot \frac{\Gamma(\alpha_0)}{\alpha_0\Gamma(\alpha_0)} \tag{2.52}$$

$$= \frac{\alpha_i}{\alpha_0}. \tag{2.53}$$

Nilai ekspektasi komponen ke-i dari vektor random yang berdistribusi Dirichlet adalah

$$\mathbb{E}[\theta_i] = \frac{\alpha_i}{\alpha_0}, \qquad i = 1, \ldots, V, \tag{2.54}$$

dengan $\alpha_0 = \sum_{j=1}^{V} \alpha_j$.

Massa konsentrasi α_0 berperan sebagai penyebut bersama, dan setiap komponen θ_i diberi bobot sebanding dengan pseudo-count α_i.

2.6. Himpunan Konveks

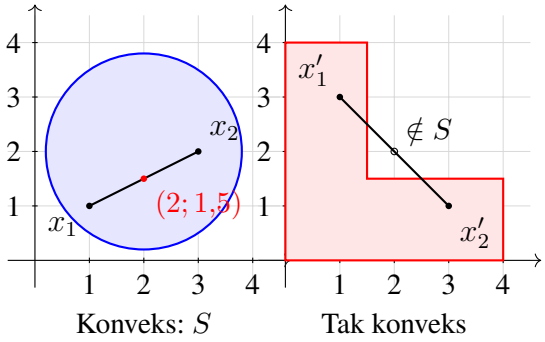
2.6.1. Himpunan Konveks

Sebuah himpunan disebut *konveks* apabila ruas garis yang menghubungkan sembarang dua titik di dalamnya seluruhnya berada di dalam himpunan tersebut. Secara matematis, misalkan $S \subseteq \mathbb{R}^n$ dan $x, y \in S$. Titik-titik pada ruas garis yang menghubungkan x dan y dapat dinyatakan sebagai $\theta x + (1-\theta)y$, dengan $\theta \in [0, 1]$. Nilai $\theta = 0$ menghasilkan y, sedangkan $\theta = 1$ menghasilkan x.

Definisi 2.6.1 (Boyd dan Vandenberghe, 2004) *Himpunan $S \subseteq \mathbb{R}^n$ disebut konveks apabila untuk setiap $x, y \in S$ dan $\theta \in [0, 1]$ berlaku*

$$\theta x + (1 - \theta)y \in S. \tag{2.55}$$

Gambar 2.2 memperlihatkan contoh himpunan konveks dan tak konveks. Pada himpunan konveks, ruas garis yang menghubungkan dua titik di dalamnya tetap berada di dalam himpunan. Sebaliknya, pada himpunan tak konveks, sebagian ruas garis tersebut dapat berada di luar himpunan.



Gambar 2.2 Contoh himpunan konveks (kiri) dan tak konveks (kanan). Pada himpunan tak konveks, ruas garis antara x'_1 dan x'_2 melewati titik $(2, 2)$ yang berada di luar himpunan.

2.6.2. Kombinasi Konveks dan Convex Hull

Konsep himpunan konveks dapat diperluas untuk mencampurkan lebih dari dua titik. Campuran ini disebut *kombinasi konveks* apabila setiap bobot tidak negatif dan jumlah seluruh bobotnya sama dengan satu.

Definisi 2.6.2 (Boyd dan Vandenberghe, 2004) *Untuk titik-titik $x_1, \ldots, x_k \in \mathbb{R}^n$ dan skalar $\theta_1, \ldots, \theta_k$ yang memenuhi $\theta_i \geq 0$ dan $\sum_{i=1}^{k} \theta_i = 1$, titik*

$$\sum_{i=1}^{k} \theta_i x_i \tag{2.56}$$

disebut kombinasi konveks dari $x_1, \ldots, x_k$.

Kumpulan seluruh kombinasi konveks dari titik-titik dalam suatu himpunan membentuk *convex hull*, yaitu himpunan konveks terkecil yang memuat himpunan

tersebut.

Definisi 2.6.3 (Boyd dan Vandenberghe, 2004) *Convex hull dari himpunan* $S \subseteq \mathbb{R}^n$*, ditulis* $\mathrm{conv}(S)$*, didefinisikan sebagai*

$$\mathrm{conv}(S) = \left\{ \sum_{i=1}^{k} \theta_i x_i \;\middle|\; \begin{array}{l} k \in \mathbb{N},\ x_i \in S,\ \theta_i \geq 0, \\ \displaystyle\sum_{i=1}^{k} \theta_i = 1 \end{array} \right\}. \tag{2.57}$$

Dengan demikian, $\mathrm{conv}(S)$ *merupakan himpunan konveks terkecil yang memuat* S*.*

2.6.3. Simpleks Probabilitas

Salah satu contoh penting yang berkaitan dengan kombinasi konveks adalah *simpleks probabilitas*, yaitu himpunan seluruh vektor probabilitas untuk V kategori. Setiap komponennya tidak negatif dan jumlah seluruh komponennya sama dengan satu.

Definisi 2.6.4 (Boyd dan Vandenberghe, 2004) *Simpleks probabilitas berdimensi* $V - 1$ *didefinisikan sebagai*

$$\Delta^{V-1} = \left\{ p = (p_1, \ldots, p_V)^\top \in \mathbb{R}^V \;\middle|\; p_i \geq 0,\ \sum_{i=1}^{V} p_i = 1 \right\}. \tag{2.58}$$

Simpleks probabilitas merupakan *convex hull* dari vektor indikator $e_1, \ldots, e_V$ (Definisi 2.5.2), yaitu

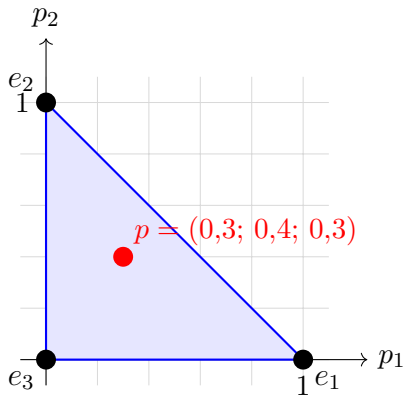
$$\Delta^{V-1} = \mathrm{conv}\{e_1, \ldots, e_V\}. \tag{2.59}$$

Setiap vektor probabilitas $p \in \Delta^{V-1}$ dapat dinyatakan sebagai kombinasi konveks

$$p = \sum_{i=1}^{V} p_i e_i. \tag{2.60}$$

Dalam representasi ini, setiap vektor indikator merupakan titik sudut simpleks yang menyatakan probabilitas satu pada satu kategori, sedangkan titik-titik lainnya menyatakan distribusi probabilitas yang tersebar di antara beberapa kategori.

Gambar 2.3 mengilustrasikan simpleks probabilitas untuk $V = 3$ kategori. Karena $p_1 + p_2 + p_3 = 1$, simpleks tersebut dapat digambarkan pada bidang (p_1, p_2) dengan $p_3 = 1 - p_1 - p_2$.



Gambar 2.3 Simpleks probabilitas Δ^2 untuk $V = 3$ kategori pada bidang (p_1, p_2). Titik sudut e_1, e_2, e_3 menyatakan distribusi yang pasti pada satu kategori, sedangkan titik di bagian dalam menyatakan distribusi campuran.

2.7. Entropi

2.7.1. Entropi Shannon

Entropi Shannon mengukur ketidakpastian suatu variabel random diskret. Misalkan X merupakan variabel random diskret dengan ruang nilai $\mathcal{X}$ dan fungsi massa probabilitas $p(x)$. Entropi Shannon didefinisikan sebagai berikut.

Definisi 2.7.1 (Cover dan Thomas, 2006) *Entropi Shannon dari variabel random diskret X adalah*

$$H(X) = -\sum_{x \in \mathcal{X}} p(x) \log p(x), \tag{2.61}$$

dengan konvensi $0 \log 0 := 0$.

2.7.2. Batas Entropi

Untuk variabel random diskret X dengan ruang nilai berhingga $\mathcal{X}$, entropi Shannon memenuhi batas berikut [Cover dan Thomas, 2006].

$$0 \leq H(X) \leq \log |\mathcal{X}|. \tag{2.62}$$

Batas bawah dicapai jika dan hanya jika distribusi probabilitas X terkonsentrasi pada satu nilai, sedangkan batas atas dicapai jika dan hanya jika distribusi probabilitas X seragam pada $\mathcal{X}$.

2.8. Inferensi Bayes

Inferensi Bayes merupakan pendekatan untuk melakukan inferensi terhadap parameter yang tidak diketahui dengan menggabungkan informasi awal mengenai parameter dengan informasi yang diperoleh dari data. Informasi awal tersebut dinyatakan melalui distribusi prior, sedangkan informasi dari data dinyatakan melalui likelihood. Hasil penggabungan keduanya menghasilkan distribusi posterior.

2.8.1. definisi Bayes: Prior, Likelihood, dan Posterior

Hubungan antara prior, likelihood, dan posterior diberikan oleh definisi Bayes.

Definisi 2.8.1 (definisi Bayes; Casella dan Berger, 2002) *Misalkan θ merupakan parameter dan Y merupakan variabel random yang menghasilkan data y. Jika $f(\theta)$ merupakan distribusi prior dan $f(y \mid \theta)$ merupakan fungsi massa peluang atau fungsi kepadatan bersyarat dari Y diberikan θ, maka distribusi posterior θ diberikan data y adalah*

$$f(\theta \mid y) = \frac{f(y \mid \theta) f(\theta)}{f(y)}. \tag{2.63}$$

Untuk θ kontinu, penyebut pada Persamaan (2.63) *diperoleh dengan mengintegralkan pembilang terhadap seluruh kemungkinan nilai θ, yaitu*

$$f(y) = \int f(y \mid \theta) f(\theta)\, d\theta. \tag{2.64}$$

Jika θ diskret, integral tersebut digantikan dengan penjumlahan.

Bukti. Kepadatan bersama θ dan Y dapat difaktorkan dalam dua arah, $f(\theta, y) = f(\theta \mid y) f(y) = f(y \mid \theta) f(\theta)$. Menyamakan ruas kanan kedua faktorisasi dan membagi kedua ruas dengan $f(y)$ memberikan Persamaan (2.63). ■

definisi Bayes dapat dipahami dengan melihat peran masing-masing komponen pada Persamaan (2.63). Distribusi $f(\theta)$ disebut *prior*, yaitu informasi mengenai θ sebelum data diamati. Fungsi $f(y \mid \theta)$ disebut *likelihood*, yaitu ukuran seberapa sesuai data y dengan suatu nilai θ. Setelah informasi dari data digabungkan dengan prior, diperoleh $f(\theta \mid y)$ yang disebut *posterior*.

Secara proporsional Persamaan (2.63) dapat ditulis sebagai

$$f(\theta \mid y) \propto f(y \mid \theta) f(\theta). \tag{2.65}$$

Simbol $\propto$ berarti "sebanding dengan". Artinya, posterior memiliki bentuk yang sama dengan hasil perkalian likelihood dan prior setelah dilakukan normalisasi. Faktor normalisasi tersebut adalah $f(y)$, yang disebut *evidence* atau distribusi marginal dari data.

2.8.2. Prior Konjugat

Definisi 2.8.2 (Casella dan Berger, 2002) *Keluarga distribusi prior $\mathcal{F}$ disebut konjugat terhadap suatu likelihood $f(y \mid \theta)$ apabila, untuk setiap prior $f(\theta) \in \mathcal{F}$, posterior $f(\theta \mid y) \propto f(y \mid \theta) f(\theta)$ juga berada dalam $\mathcal{F}$.*

Kekonjugatan bermanfaat secara komputasi, dimana posterior dapat langsung dituliskan dalam bentuk tertutup, tanpa menghitung integral penormal $f(y)$ pada Persamaan (2.63) secara eksplisit.

2.8.3. Kekonjugatan Dirichlet–Multinomial

Definisi 2.8.3 (Gelman dkk, 2013) *Misalkan $\theta \sim \mathrm{Dir}(\alpha)$ dan, diberikan θ, $\boldsymbol{c} = (c_1, \ldots, c_V)^\top \sim \mathrm{Multinomial}(n, \theta)$ (Definisi 2.5.3). Distribusi posterior θ diberikan $\boldsymbol{c}$ adalah*

$$\theta \mid \boldsymbol{c} \sim \mathrm{Dir}(\alpha + \boldsymbol{c}). \tag{2.66}$$

Bukti. Oleh definisi 2.8.1, $f(\theta \mid \boldsymbol{c}) \propto f(\boldsymbol{c} \mid \theta) f(\theta)$ sebagai fungsi θ. Likelihood multinomial (Persamaan (2.31)) dan prior Dirichlet (Persamaan (2.44)) memberik-

an

$$f(\boldsymbol{c} \mid \theta) f(\theta) = \left(\frac{n!}{\prod_{i=1}^{V} c_i!} \prod_{i=1}^{V} \theta_i^{c_i} \right) \left(\frac{1}{B(\alpha)} \prod_{i=1}^{V} \theta_i^{\alpha_i - 1} \right),$$

yang setelah suku-suku konstan (tak bergantung θ) digabungkan,

$$f(\boldsymbol{c} \mid \theta) f(\theta) = \frac{n!}{B(\alpha) \prod_{i=1}^{V} c_i!} \prod_{i=1}^{V} \theta_i^{\alpha_i + c_i - 1}.$$

Sebagai fungsi θ, $f(\boldsymbol{c} \mid \theta) f(\theta)$ sebanding dengan $\prod_{i=1}^{V} \theta_i^{(\alpha_i + c_i) - 1}$, yaitu kernel kepadatan $\mathrm{Dir}(\alpha + \boldsymbol{c})$ pada Persamaan (2.44). Karena kepadatan $\theta \mid \boldsymbol{c}$ harus berintegral satu atas Δ^{V-1}, dan oleh Persamaan (2.43) satu-satunya konstanta yang menormalkan kernel tersebut adalah $1/B(\alpha + \boldsymbol{c})$, diperoleh

$$f(\theta \mid \boldsymbol{c}) = \frac{1}{B(\alpha + \boldsymbol{c})} \prod_{i=1}^{V} \theta_i^{(\alpha_i + c_i) - 1},$$

yaitu kepadatan $\mathrm{Dir}(\alpha + \boldsymbol{c})$. ■

Untuk $n = 1$ (satu pengamatan), $\boldsymbol{c} = e_y$, vektor indikator (Definisi 2.5.2) pada kategori y yang teramati, sehingga Persamaan (2.66) menjadi $\theta \mid y \sim \mathrm{Dir}(\alpha + e_y)$.

Definisi 2.8.4 (Gelman dkk, 2013) *Pada konteks definisi 2.8.3, parameter prior α_i disebut pseudo-count kategori i sebelum data teramati, dan $\alpha_0 = \sum_i \alpha_i$ disebut massa konsentrasi prior. Pembaruan $\alpha \to \alpha + \boldsymbol{c}$ menambahkan peluang teramati c_i langsung ke pseudo-count α_i.*

2.8.4. Rerata Posterior sebagai Estimator Bayes

Definisi 2.8.5 (Casella dan Berger, 2002) *Untuk parameter random $\theta \in \mathbb{R}^V$ dan penduga (estimator) $\delta = \delta(y) \in \mathbb{R}^V$, risiko kuadratik (posterior expected squared-error loss) adalah*

$$R(\delta \mid y) = \mathbb{E}\big[\|\theta - \delta\|^2 \,\big|\, y \big]. \tag{2.67}$$

Penduga δ^* yang meminimumkan $R(\delta \mid y)$ atas seluruh $\delta \in \mathbb{R}^V$ disebut estimator Bayes di bawah risiko kuadratik.

Estimator Bayes di bawah risiko kuadratik ternyata adalah rerata posterior itu sendiri. Untuk tiap komponen i, definisi **??** yang diterapkan pada distribusi posterior memberikan

$$\mathbb{E}\big[(\theta_i - \delta_i)^2 \mid y\big] = \mathbb{E}\big[\theta_i^2 \mid y\big] - 2\delta_i\, \mathbb{E}[\theta_i \mid y] + \delta_i^2.$$

Ruas kanan berbentuk kuadrat dalam δ_i dengan koefisien pangkat dua positif, sehingga memiliki minimum tunggal, tercapai ketika turunannya terhadap δ_i nol: $-2\mathbb{E}[\theta_i \mid y] + 2\delta_i = 0$, yaitu $\delta_i^* = \mathbb{E}[\theta_i \mid y]$. Menjumlahkan atas $i = 1, \ldots, V$, risiko $R(\delta \mid y) = \sum_{i=1}^{V} \mathbb{E}[(\theta_i - \delta_i)^2 \mid y]$ diminimumkan pada

$$\delta^* = \big(\mathbb{E}[\theta_1 \mid y], \ldots, \mathbb{E}[\theta_V \mid y]\big)^\top = \mathbb{E}[\theta \mid y]. \tag{2.68}$$

2.9. Model Bahasa dan Arsitektur *Transformer*

2.9.1. Model Bahasa Autoregresif

Definisi 2.9.1 (Goodfellow dkk, 2016) *Misalkan $\mathcal{V} = \{1, \ldots, V\}$ kosakata (vocabulary) berukuran V, dan $x = (x_1, \ldots, x_n)$ barisan token dengan $x_t \in \mathcal{V}$. Model bahasa (language model) adalah distribusi peluang atas barisan token, difaktorkan menurut aturan rantai peluang sebagai*

$$p(x) = \prod_{t=1}^{n} p(x_t \mid x_{<t}), \tag{2.69}$$

dengan $x_{<t} = (x_1, \ldots, x_{t-1})$. Model yang memfaktorkan peluangnya demikian — token ke-t dibangkitkan bergantung pada seluruh token sebelumnya — disebut autoregresif.

Persamaan (2.69) adalah penerapan berulang aturan rantai peluang. Untuk

$n = 3$ misalnya, produknya terurai menjadi tiga faktor,

$$p(x_1, x_2, x_3) = p(x_1)\, p(x_2 \mid x_1)\, p(x_3 \mid x_1, x_2), \tag{2.70}$$

dengan $p(x_1) = p(x_1 \mid x_{<1})$ memakai $x_{<1} = \varnothing$ (barisan kosong, tidak ada token sebelum token pertama). Setiap faktor pada Persamaan (2.70) adalah distribusi atas V kategori yang bersyarat pada token-token sebelumnya, sehingga membangkitkan barisan x berarti membangkitkan token satu per satu secara berurutan: x_1 terlebih dahulu, kemudian x_2 dengan x_1 diketahui, dan seterusnya.

Pada praktiknya, $p(\cdot \mid x_{<t})$ dihitung oleh jaringan saraf yang menerima $x_{<t}$ sebagai masukan dan mengeluarkan satu distribusi peluang atas V kategori, yaitu satu titik pada simpleks Δ^{V-1} (Definisi 2.6.4). Subbab berikut menjelaskan bagaimana distribusi tersebut dihitung.

2.9.2. Jaringan Saraf, Fungsi Aktivasi, dan Fungsi *Softmax*

Komponen dasar jaringan saraf tiruan adalah lapisan (*layer*) yang memetakan masukan $u \in \mathbb{R}^m$ menjadi keluaran $\sigma(Wu + b)$, dengan W dan b parameter yang dipelajari dan σ *fungsi aktivasi* taklinear (misalnya ReLU atau *tanh*) yang memungkinkan tumpukan lapisan memodelkan hubungan yang lebih kompleks daripada kombinasi linear semata [Goodfellow dkk, 2016]. *Transformer* tersusun atas banyak lapisan demikian.

Lapisan terakhir model menghasilkan vektor *logit* $\ell = (\ell_1, \ldots, \ell_V)^\top \in \mathbb{R}^V$, satu nilai per kategori kosakata, yang perlu diubah menjadi distribusi peluang.

Definisi 2.9.2 (Goodfellow dkk, 2016) *Untuk vektor logit $\ell \in \mathbb{R}^V$ dan parameter suhu (temperature) $T > 0$, fungsi softmax menghasilkan vektor peluang $p = \mathrm{softmax}(\ell/T) \in \Delta^{V-1}$ dengan komponen*

$$p_i = \frac{\exp(\ell_i/T)}{\sum_{j=1}^{V} \exp(\ell_j/T)}, \qquad i = 1, \ldots, V. \tag{2.71}$$

Karena $\exp(\cdot) > 0$ untuk sembarang argumen, setiap p_i pada Persama-

an (2.71) taknegatif. Menjumlahkan seluruh komponen, penyebutnya sama untuk tiap i sehingga dapat dikeluarkan dari jumlah,

$$\sum_{i=1}^{V} p_i = \sum_{i=1}^{V} \frac{\exp(\ell_i/T)}{\sum_{j=1}^{V} \exp(\ell_j/T)} = \frac{\sum_{i=1}^{V} \exp(\ell_i/T)}{\sum_{j=1}^{V} \exp(\ell_j/T)} = 1, \tag{2.72}$$

sehingga p memang berada pada simpleks Δ^{V-1} (Definisi 2.6.4).

Parameter suhu T mengatur seberapa tajam distribusi tersebut, dan kedua kasus batasnya dapat diturunkan langsung dari Persamaan (2.71). Saat $T \to \infty$, setiap $\ell_i/T \to 0$ sehingga $\exp(\ell_i/T) \to \exp(0) = 1$ untuk seluruh i, dan

$$p_i \longrightarrow \frac{1}{V}, \qquad i = 1, \ldots, V, \tag{2.73}$$

yaitu p mendekati distribusi seragam pada V kategori.

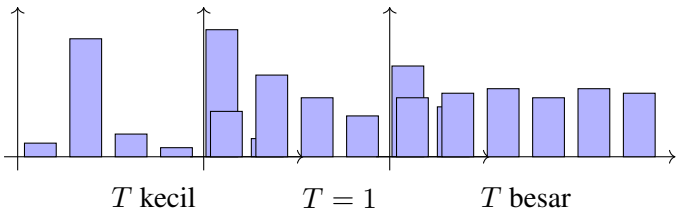
Saat $T \to 0^+$, misalkan $\ell_k = \max_i \ell_i$ tunggal (tidak ada dua komponen ℓ yang sama besar). Membagi pembilang dan penyebut Persamaan (2.71) dengan $\exp(\ell_k/T)$,

$$p_i = \frac{\exp\big((\ell_i - \ell_k)/T\big)}{\sum_{j=1}^{V} \exp\big((\ell_j - \ell_k)/T\big)}. \tag{2.74}$$

Untuk $i = k$, pembilangnya $\exp(0) = 1$. Untuk $i \neq k$, $\ell_i - \ell_k < 0$ karena ℓ_k tunggal terbesar, sehingga $(\ell_i - \ell_k)/T \to -\infty$ dan $\exp\big((\ell_i - \ell_k)/T\big) \to 0$ saat $T \to 0^+$. Akibatnya, penyebut Persamaan (2.74) mendekati 1 (hanya suku $i = k$ yang tersisa), dan

$$p_k \to 1, \qquad p_i \to 0 \text{ untuk } i \neq k, \tag{2.75}$$

yaitu p mendekati vektor indikator (Definisi 2.5.2) kategori k. Bentuk Persamaan (2.74) — mengurangkan logit terbesar sebelum menerapkan $\exp(\cdot)$ — juga dipakai dalam praktiknya untuk menghitung Persamaan (2.71) secara stabil tanpa risiko luapan (*overflow*) numerik pada $\exp(\ell_i/T)$ untuk ℓ_i/T besar. Gambar 2.4 mengilustrasikan pengaruh T terhadap bentuk distribusi.



Gambar 2.4 Pengaruh suhu T terhadap bentuk distribusi $p = \mathrm{softmax}(\ell/T)$ untuk logit ℓ yang sama ($V = 6$ kategori). Saat T kecil (kiri), distribusi memusat tajam pada satu kategori, mendekati vektor indikator; saat $T = 1$ (tengah), distribusi mengikuti logit apa adanya; saat T besar (kanan), distribusi mendekati seragam.

2.9.3. Mekanisme Atensi dan *KV-Cache*

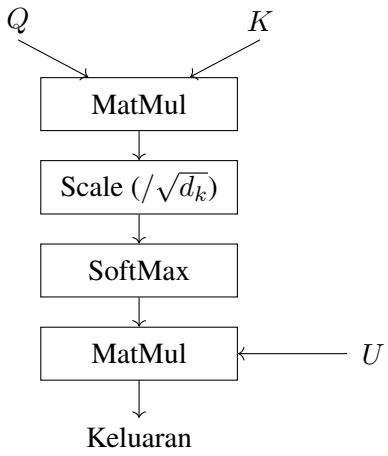
Transformer memproses seluruh token sekaligus lewat mekanisme atensi (*attention*), yang memungkinkan representasi tiap posisi dibentuk dari kombinasi berbobot representasi posisi-posisi lain.

Definisi 2.9.3 (Vaswani dkk, 2017) *Untuk matriks kueri (query) $Q \in \mathbb{R}^{n \times d_k}$, kunci (key) $K \in \mathbb{R}^{n \times d_k}$, dan nilai (value) $U \in \mathbb{R}^{n \times d_v}$ (huruf U dipakai menggantikan V pada notasi asli agar tidak tumpang tindih dengan V, ukuran kosakata), atensi produk-titik berskala (scaled dot-product attention) didefinisikan sebagai*

$$\mathrm{Atensi}(Q, K, U) = \mathrm{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) U, \tag{2.76}$$

dengan fungsi softmax (Definisi 2.9.2) pada Persamaan (2.76) *diterapkan baris demi baris.*

Baris ke-t dari $QK^\top$ berisi kemiripan (*dot product*) kueri posisi t dengan kunci seluruh posisi; *softmax* mengubah kemiripan tersebut menjadi bobot yang berjumlah satu (satu titik pada simpleks), dan pembagi $\sqrt{d_k}$ menstabilkan besaran kemiripan agar tidak mendominasi *softmax* saat d_k besar. Gambar 2.5 menggambarkan alur perhitungan ini. Pada praktiknya, Q, K, U dihitung paralel pada beberapa *head* berdimensi lebih kecil lalu digabungkan (*multi-head attention*).



Gambar 2.5 Alur perhitungan atensi produk-titik berskala pada Persamaan (2.76)**, mengikuti diagram Vaswani dkk [2017].**

Pada pembangkitan teks autoregresif, token dihasilkan satu per satu, dan K, U pada tiap lapisan hanya bergantung pada token yang sudah ada. Alih-alih menghitung ulang K, U untuk seluruh token setiap langkah, baris K, U milik token-token sebelumnya dapat disimpan dan dipakai kembali.

Definisi 2.9.4 *KV-cache pada langkah ke-t adalah himpunan matriks kunci dan nilai yang telah dihitung untuk token $1, \ldots, t-1$ di tiap lapisan l,*

$$\mathcal{M}_t^{(l)} = \left\{ K_{1:t-1}^{(l)},\, U_{1:t-1}^{(l)} \right\}. \tag{2.77}$$

Pada langkah t, hanya $K_t^{(l)}, U_t^{(l)}$ untuk token baru yang perlu dihitung dan digabungkan dengan $\mathcal{M}_t^{(l)}$, bukan menghitung ulang seluruh matriks.

2.9.4. Embedding Masukan dan Keluaran

Definisi 2.9.5 (Vaswani dkk, 2017) *Matriks embedding masukan $W_{\text{in}} \in \mathbb{R}^{V \times d}$ memetakan tiap token $i \in \mathcal{V}$ ke baris ke-i-nya, sebuah vektor berdimensi d. Matriks embedding keluaran (atau unembedding) $W_{\text{out}} \in \mathbb{R}^{V \times d}$ memetakan representasi tersembunyi $h \in \mathbb{R}^d$ menjadi vektor logit $\ell = W_{\text{out}} h \in \mathbb{R}^V$ pada Persamaan* (2.71)*.*

Pada sejumlah arsitektur, kedua matriks ini disatukan ($W_{\text{out}} = W_{\text{in}}$, disebut *tied embedding*), sedangkan pada arsitektur lain keduanya dipelajari independen

(*untied*) [Vaswani dkk, 2017]. Pada kasus *untied*, ruang representasi masukan dan ruang representasi keluaran tidak otomatis identik.

2.9.5. *Tokenizer* dan *Byte-Pair Encoding*

Token pada Persamaan (2.69) bukan selalu berupa kata utuh. *Tokenizer* memecah teks menjadi unit subkata (*subword unit*), dan *byte-pair encoding* (BPE) adalah salah satu algoritma untuk membentuk kosakata subkata tersebut: dimulai dari karakter individual, pasangan simbol yang paling sering muncul berdampingan digabung menjadi satu simbol baru, diulang hingga kosakata mencapai ukuran target V [Sennrich dkk, 2016]. Dengan demikian, kata yang sering muncul utuh cenderung menjadi satu token, sedangkan kata yang jarang muncul dipecah menjadi beberapa subkata yang lebih umum.

2.10. Strategi Pengambilan Sampel Token

Setelah distribusi $p = \mathrm{softmax}(\ell/T) \in \Delta^{V-1}$ diperoleh (Persamaan (2.71)), token berikutnya x_t masih harus dipilih dari distribusi tersebut. Cara paling sederhana adalah *greedy*, memilih kategori dengan peluang terbesar, $x_t = \arg\max_i p_i$, atau membangkitkannya langsung, $x_t \sim \mathrm{Kategorik}(p)$ (Definisi 2.5.2). Kedua ekstrem ini punya kelemahan: *greedy* selalu deterministik, sedangkan sampling langsung dari p sesekali memilih kategori berpeluang sangat kecil.

Dua strategi berikut memotong dahulu distribusi p sebelum sampling, sehingga kategori berpeluang sangat kecil tersisih.

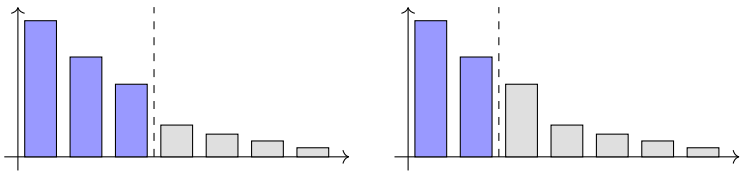
Definisi 2.10.1 (Holtzman dkk, 2020) *Untuk ambang $k \in \mathbb{N}$, misalkan $\mathcal{I}_k \subset \mathcal{V}$ himpunan k kategori dengan p_i terbesar. Top-k sampling membangkitkan x_t dari distribusi p yang dipotong pada $\mathcal{I}_k$ dan dinormalisasi ulang,*

$$P[x_t = i] = \begin{cases} \dfrac{p_i}{\sum_{j \in \mathcal{I}_k} p_j}, & i \in \mathcal{I}_k, \\ 0, & i \notin \mathcal{I}_k. \end{cases} \tag{2.78}$$

Nucleus (top-p) sampling melakukan hal serupa dengan $\mathcal{I}_k$ diganti $\mathcal{I}_p$, himpunan

terkecil yang peluang kumulatifnya — setelah p_i diurutkan menurun — baru saja melampaui ambang $p \in (0, 1)$.

Gambar 2.6 membandingkan kedua cara memotong distribusi tersebut.



Gambar 2.6 Perbandingan *top-k sampling* (kiri, memotong pada banyaknya kategori) dan *nucleus sampling* (kanan, memotong pada peluang kumulatif). Batang biru menandai kategori yang tersisa untuk disampling ulang; batang abu-abu tersisih.

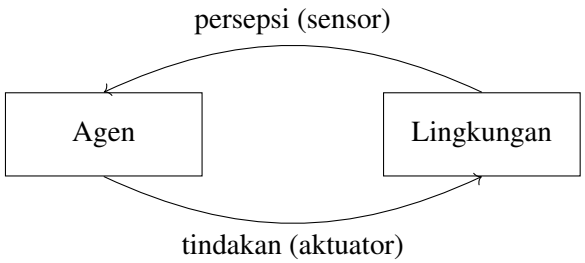
2.11. Sistem Multi-Agen

2.11.1. Definisi Agen dan Sistem Multi-Agen

Definisi 2.11.1 (Wooldridge, 2009) *Agen (agent) adalah entitas komputasi yang mengamati lingkungannya melalui sensor dan bertindak terhadap lingkungan itu melalui aktuator secara otonom — tanpa campur tangan langsung manusia atau agen lain pada setiap langkahnya — untuk mencapai tujuan tertentu.*

Definisi 2.11.2 (Wooldridge, 2009) *Sistem multi-agen (multi-agent system, MAS) adalah sistem yang tersusun atas dua atau lebih agen yang berinteraksi — saling bertukar informasi dan saling memengaruhi tindakan satu sama lain — di dalam lingkungan bersama.*

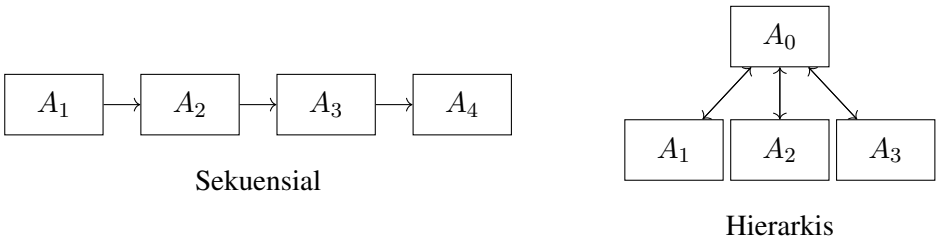
Gambar 2.7 menggambarkan siklus persepsi–tindakan satu agen terhadap lingkungannya.



Gambar 2.7 Siklus persepsi–tindakan agen dan lingkungannya [Wooldridge, 2009]. Pada sistem multi-agen, beberapa agen semacam ini berbagi satu lingkungan dan dapat saling memengaruhi.

2.11.2. Topologi Sekuensial dan Hierarkis

Interaksi antaragen pada sistem multi-agen dapat diatur menurut berbagai topologi koordinasi; dua yang paling mendasar adalah sekuensial dan hierarkis [Wooldridge, 2009]. Pada topologi *sekuensial*, agen disusun sebagai rantai: keluaran satu agen menjadi masukan agen berikutnya, sehingga informasi mengalir searah dari agen pertama hingga agen terakhir. Pada topologi *hierarkis*, satu agen berperan sebagai koordinator yang mendelegasikan sub-tugas kepada beberapa agen bawahan dan menggabungkan keluaran mereka. Gambar 2.8 menggambarkan kedua topologi tersebut.



Gambar 2.8 Topologi sekuensial (kiri), rantai agen $A_1 \rightarrow A_2 \rightarrow A_3 \rightarrow A_4$, dan topologi hierarkis (kanan), koordinator A_0 yang mendelegasikan ke A_1, A_2, A_3 dan menggabungkan keluarannya.

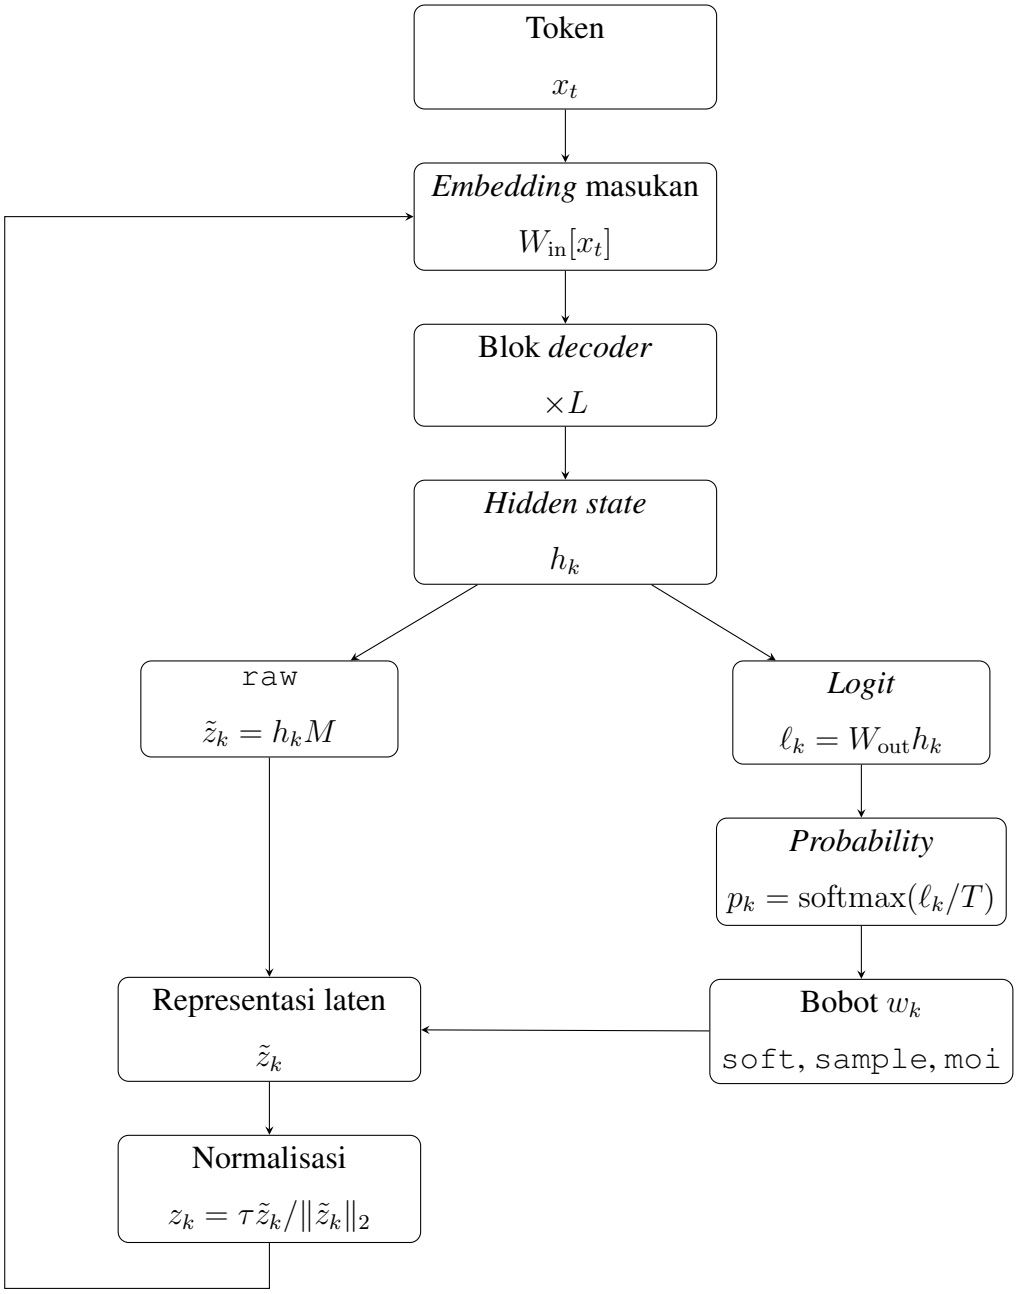
BAB III

METODOLOGI PENELITIAN

Penelitian ini membandingkan *Mixture of Inputs* (MoI), yaitu metode *reasoning* melalui representasi laten, dengan tiga metode lain: `raw` (*input-output alignment*), `soft` (*Soft Thinking*), dan `sample` (*discrete token*). Keempatnya diterapkan pada sistem multi-agen yang berkomunikasi melalui transfer *KV-cache*, yang selanjutnya juga dibandingkan dengan sistem multi-agen standar berbasis teks.

3.1. Arsitektur Qwen3-8B

Qwen3-8B merupakan model bahasa autoregresif dengan arsitektur *Transformer decoder-only* [Yang dkk, 2025].



Gambar 3.1 Alur representasi laten pada arsitektur Qwen3.

Gambar 3.1 memperlihatkan alur komputasi yang digunakan sebagai dasar pembahasan. Teks *input* diubah menjadi token(*tokenization*), kemudian dipetakan melalui *embedding* masukan W_{in} menjadi vektor. Hasil *embedding* tersebut diproses melalui seluruh blok *decoder* hingga menghasilkan *hidden state* h_k. Pada pembuatan token biasa, *hidden state* tersebut dipetakan melalui *output projection* W_{out} menjadi *logit*, yang kemudian diubah menjadi *probability* melalui fungsi *softmax*.

3.1.1. Blok *Decoder* dan Aliran Residual

Masukan bagi lapisan pertama adalah barisan vektor *embedding* token. Jika x_t menyatakan indeks token pada posisi t, maka vektor masukan dapat dituliskan sebagai

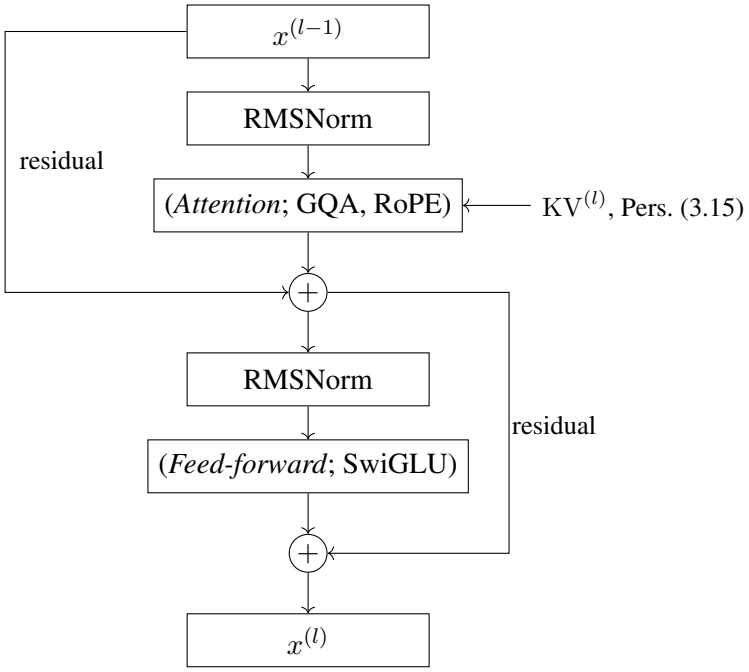
$$x_t^{(0)} = W_{\text{in}}[x_t]. \tag{3.1}$$

Setiap lapisan (*layer*) $l = 1, \ldots, L$ terdiri atas dua sublapisan, yaitu sublapisan atensi (*attention*) yang mencampur informasi antarposisi dan jaringan umpan-maju (*feed-forward network*) yang mengolah representasi pada setiap posisi secara terpisah. Keduanya menggunakan normalisasi sebelum transformasi (*pre-norm*) dan koneksi residual. Secara berurutan, transformasi pada satu lapisan dapat dituliskan sebagai

$$\widetilde{x}^{(l)} = x^{(l-1)} + \text{Attn}^{(l)}\left(\text{RMSNorm}\left(x^{(l-1)}\right) \,\middle|\, \text{KV}^{(l)}\right), \tag{3.2}$$

$$x^{(l)} = \widetilde{x}^{(l)} + \text{MLP}^{(l)}\left(\text{RMSNorm}\left(\widetilde{x}^{(l)}\right)\right). \tag{3.3}$$

Suku pertama pada masing-masing persamaan merupakan bagian dari *residual stream*. Dengan demikian, setiap sublapisan hanya menambahkan koreksi terhadap representasi yang telah tersedia, bukan menggantikannya. Aliran residual tersebut membawa informasi dari lapisan pertama hingga lapisan terakhir. Pada sublapisan atensi, informasi posisi-posisi sebelumnya diakses melalui *key-value cache* (KV-cache), yang pada lapisan l dinotasikan sebagai $\text{KV}^{(l)}$.



Gambar 3.2 Satu blok *decoder* Qwen3-8B.

Setelah seluruh L lapisan selesai diproses, representasi pada posisi terakhir dinormalisasi kembali untuk memperoleh *hidden state* yang digunakan oleh metode laten. Jika posisi terakhir dinyatakan dengan indeks t, maka

$$h_t = \mathrm{RMSNorm}\left(x_t^{(L)}\right). \tag{3.4}$$

Dengan demikian, $h_t \in \mathbb{R}^d$ merupakan representasi akhir pada posisi terakhir yang menjadi masukan bagi fungsi Φ pada langkah laten.

Normalisasi yang digunakan adalah *Root Mean Square Normalization* (RMSNorm). Untuk suatu vektor $x \in \mathbb{R}^d$, RMSNorm dapat dituliskan sebagai

$$\mathrm{RMSNorm}(x) = \frac{x}{\sqrt{\frac{1}{d}\sum_{j=1}^{d} x_j^2 + \epsilon}} \odot g, \qquad \epsilon = 10^{-6}, \tag{3.5}$$

dengan $g \in \mathbb{R}^d$ merupakan vektor parameter penguatan yang dipelajari dan $\odot$ menyatakan menyatakan perkalian Hadamard.. Berbeda dengan *layer normaliza-*

tion, RMSNorm tidak mengurangi rata-rata komponen terlebih dahulu, melainkan hanya mengatur besaran representasi.

Sublapisan umpan-maju menggunakan struktur SwiGLU. Untuk suatu masukan $u \in \mathbb{R}^d$, bentuknya dapat dituliskan sebagai

$$\mathrm{MLP}(u) = W_{\downarrow} \left(\mathrm{SiLU} \left(W_g u \right) \odot \left(W_u u \right) \right), \tag{3.6}$$

dengan fungsi SiLU didefinisikan sebagai

$$\mathrm{SiLU}(a) = a \cdot \sigma(a), \tag{3.7}$$

dengan $\sigma(\cdot)$ merupakan fungsi *sigmoid* dan $\odot$ menyatakan menyatakan perkalian Hadamard.. Suku $\mathrm{SiLU}(W_g u)$ berperan sebagai gerbang yang mengatur komponen dari $W_u u$ sebelum hasilnya diproyeksikan kembali melalui $W_{\downarrow}$.

3.1.2. *Grouped-Query Attention* dan RoPE

Sub-lapisan *attention* Qwen3-8B menggunakan *grouped-query attention* (GQA). Model memiliki $H_q = 32$ *query heads* dan $H_{kv} = 8$ pasangan *key-value heads* [Yang dkk, 2025]. Dengan demikian, beberapa *query heads* berbagi pasangan *key-value* yang sama.

Dimensi setiap *head* ditentukan oleh

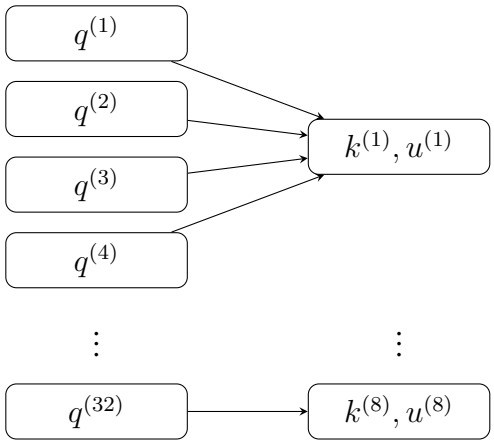
$$d_k = \frac{d}{H_q} = \frac{4096}{32} = 128. \tag{3.8}$$

Untuk *query head* ke-η, dengan $\eta \in \{1, \ldots, 32\}$, indeks pasangan *key-value* yang digunakan dapat dinyatakan sebagai

$$g(\eta) = \left\lceil \frac{\eta}{H_q / H_{kv}} \right\rceil = \left\lceil \frac{\eta}{4} \right\rceil, \qquad g(\eta) \in \{1, \ldots, 8\}. \tag{3.9}$$

Sebagai contoh, *query heads* pertama hingga keempat menggunakan pasangan *key-value* pertama, *query heads* kelima hingga kedelapan menggunakan pa-

sangan kedua, dan seterusnya. Dengan demikian, setiap pasangan *key-value* digunakan bersama oleh empat *query heads*.



Gambar 3.3 Ilustrasi pembagian *query heads* pada GQA.

Dengan konvensi notasi pada Bab II, vektor *value* dinyatakan dengan u. Untuk *query head* ke-η, kueri, kunci, dan nilai diperoleh melalui proyeksi

$$q^{(\eta)} = W_Q^{(\eta)} x, \qquad k^{(g(\eta))} = W_K^{(g(\eta))} x, \qquad u^{(g(\eta))} = W_V^{(g(\eta))} x. \tag{3.10}$$

Sebelum digunakan dalam perhitungan *attention*, informasi posisi direpresentasikan menggunakan *Rotary Position Embedding* (RoPE) [Su dkk, 2024]. Untuk suatu pasangan komponen ke-r pada posisi t, transformasi rotasi dapat dituliskan sebagai

$$\begin{pmatrix} x'_{t,2r} \\ x'_{t,2r+1} \end{pmatrix} = \begin{pmatrix} \cos\theta_{t,r} & -\sin\theta_{t,r} \\ \sin\theta_{t,r} & \cos\theta_{t,r} \end{pmatrix} \begin{pmatrix} x_{t,2r} \\ x_{t,2r+1} \end{pmatrix}. \tag{3.11}$$

Transformasi tersebut diterapkan pada *query* dan *key*. Dengan demikian, secara konseptual diperoleh

$$\widetilde{q}_t^{(\eta)} = \mathrm{RoPE}_t\left(q_t^{(\eta)}\right), \qquad \widetilde{k}_j^{(g(\eta))} = \mathrm{RoPE}_j\left(k_j^{(g(\eta))}\right). \tag{3.12}$$

Bobot *attention* kemudian dihitung berdasarkan kesesuaian antara *query* dan

key. Untuk posisi t, bobot terhadap posisi j dapat dituliskan sebagai

$$\alpha_{tj}^{(\eta)} = \frac{\exp\left(\frac{\left(\widetilde{q}_t^{(\eta)}\right)^{\mathsf{T}} \widetilde{k}_j^{(g(\eta))}}{\sqrt{d_k}}\right)}{\sum_{r=1}^{t} \exp\left(\frac{\left(\widetilde{q}_t^{(\eta)}\right)^{\mathsf{T}} \widetilde{k}_r^{(g(\eta))}}{\sqrt{d_k}}\right)}. \tag{3.13}$$

Keluaran *attention* kemudian merupakan kombinasi berbobot dari vektor nilai:

$$\mathrm{Attn}\left(q_t^{(\eta)}, k_{1:t}^{(g(\eta))}, u_{1:t}^{(g(\eta))}\right) = \sum_{j=1}^{t} \alpha_{tj}^{(\eta)} u_j^{(g(\eta))}. \tag{3.14}$$

Persamaan tersebut memperlihatkan bahwa RoPE memengaruhi perhitungan kesesuaian antara *query* dan *key*, sedangkan vektor *value* digunakan untuk membentuk keluaran *attention*. Hal ini menjadi relevan ketika *KV-cache* digunakan untuk mempertahankan informasi dari posisi-posisi sebelumnya.

3.1.3. *KV-cache* per Lapisan

Pada *Transformer decoder-only*, hasil proyeksi *key* dan *value* dari posisi-posisi sebelumnya dapat disimpan sehingga tidak perlu dihitung ulang ketika posisi baru diproses. Penyimpanan tersebut disebut *KV-cache*.

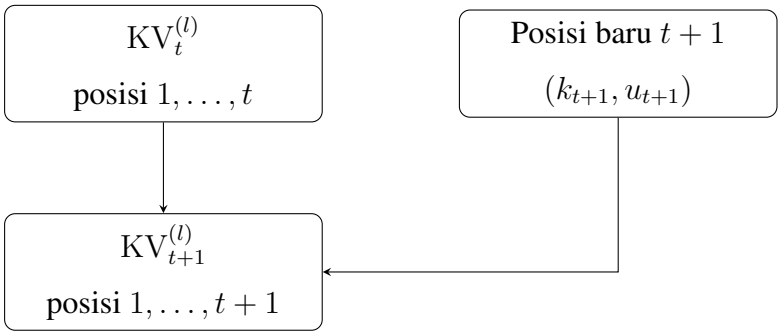
Untuk lapisan ke-l, setelah t posisi diproses, *KV-cache* secara konseptual dapat dituliskan sebagai

$$\mathrm{KV}_t^{(l)} = \left\{ \left(k_j^{(l,g)}, u_j^{(l,g)}\right) : 1 \le j \le t,\ 1 \le g \le H_{kv} \right\}. \tag{3.15}$$

Karena Qwen3-8B memiliki $H_{kv} = 8$, setiap posisi baru yang diproses menambahkan delapan pasangan *key-value* ke dalam *cache* pada masing-masing lapisan. Secara konseptual, pertumbuhan tersebut dapat dituliskan sebagai

$$\mathrm{KV}_{t+1}^{(l)} = \mathrm{KV}_t^{(l)} \parallel \left\{ \left(k_{t+1}^{(l,g)}, u_{t+1}^{(l,g)}\right) : 1 \le g \le 8 \right\}, \tag{3.16}$$

dengan $\|$ menyatakan penggabungan sepanjang dimensi posisi.



Gambar 3.4 Pertumbuhan *KV-cache* ketika posisi baru diproses.

Sifat pertumbuhan *KV-cache* tersebut penting dalam penelitian ini karena sebuah vektor pada langkah laten juga diproses sebagai posisi baru. Oleh sebab itu, langkah laten tidak hanya menghasilkan *hidden state* baru, tetapi juga memperbarui *KV-cache*. Dalam sistem multi-agen, *KV-cache* inilah yang digunakan sebagai salah satu medium komunikasi antar-agen.

3.1.4. *Embedding* Masukan dan Keluaran

Qwen3-8B menggunakan matriks *embedding* masukan dan matriks keluaran yang tidak diikat (*untied embedding*) [Yang dkk, 2025]. Dengan konvensi kolom yang digunakan dalam penelitian ini, keduanya dituliskan sebagai

$$W_{\mathrm{in}},\ W_{\mathrm{out}} \in \mathbb{R}^{V \times d}. \tag{3.17}$$

Matriks W_{in} digunakan untuk memperoleh vektor *embedding* token. Jika x_t merupakan indeks token, maka

$$x_t^{(0)} = W_{\mathrm{in}}[x_t]. \tag{3.18}$$

Sebaliknya, matriks W_{out} digunakan untuk mengubah *hidden state* menjadi *logit*. Untuk suatu $h \in \mathbb{R}^d$, diperoleh

$$\ell = W_{\mathrm{out}} h, \tag{3.19}$$

dengan $\ell \in \mathbb{R}^V$ merupakan vektor *logit* untuk seluruh entri kosakata.

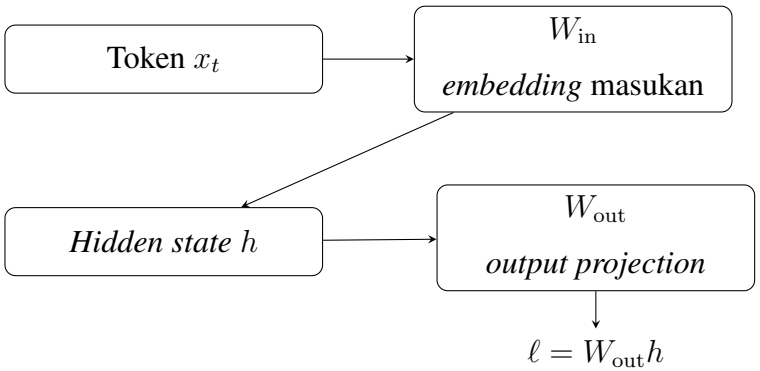
Ukuran kosakata yang sesuai dengan jumlah baris kedua matriks tersebut adalah

$$V = 151\,936. \tag{3.20}$$

Karena kedua matriks tidak diikat, W_{in} dan W_{out} merupakan parameter yang dipelajari secara independen. Pada model yang digunakan dalam penelitian ini, rata-rata kosinus antara baris yang bersesuaian dari kedua matriks diukur sebesar

$$\frac{1}{V}\sum_{i=1}^{V} \cos\left(W_{\text{in}}[i], W_{\text{out}}[i]\right) = 0{,}0041. \tag{3.21}$$

Nilai tersebut merupakan hasil pengukuran pada bobot model yang digunakan, bukan parameter arsitektur Qwen3. Hasil ini menunjukkan bahwa pasangan baris yang bersesuaian antara W_{in} dan W_{out} tidak memiliki keselarasan arah yang kuat. Hal tersebut menjadi relevan bagi metode `raw`, karena *hidden state* keluaran perlu diselaraskan terlebih dahulu sebelum digunakan sebagai vektor pada ruang *embedding* masukan.



Gambar 3.5 Hubungan *embedding* masukan dan keluaran pada Qwen3-8B.

Spesifikasi arsitektur yang digunakan dalam penelitian ini dirangkum pada Tabel 3.1.

Tabel 3.1 Spesifikasi arsitektur Qwen3-8B yang digunakan dalam penelitian.

Komponen	Nilai	Sumber
Jumlah lapisan L	36	Yang dkk [2025]
Dimensi *hidden state* d	4096	Yang dkk [2025]
Query heads H_q	32	Yang dkk [2025]
Key-value heads H_{kv}	8	Yang dkk [2025]
Dimensi tiap *head* d_k	128	d/H_q
Ukuran kosakata V	151 936	pengukuran model
Embedding	*untied*	Yang dkk [2025]
Rata-rata kosinus per baris	0,0041	pengukuran model
Normalisasi	RMSNorm, *pre-norm*	Yang dkk [2025]
feed-forward	SwiGLU	Yang dkk [2025]
Representasi posisi	RoPE	Yang dkk [2025]

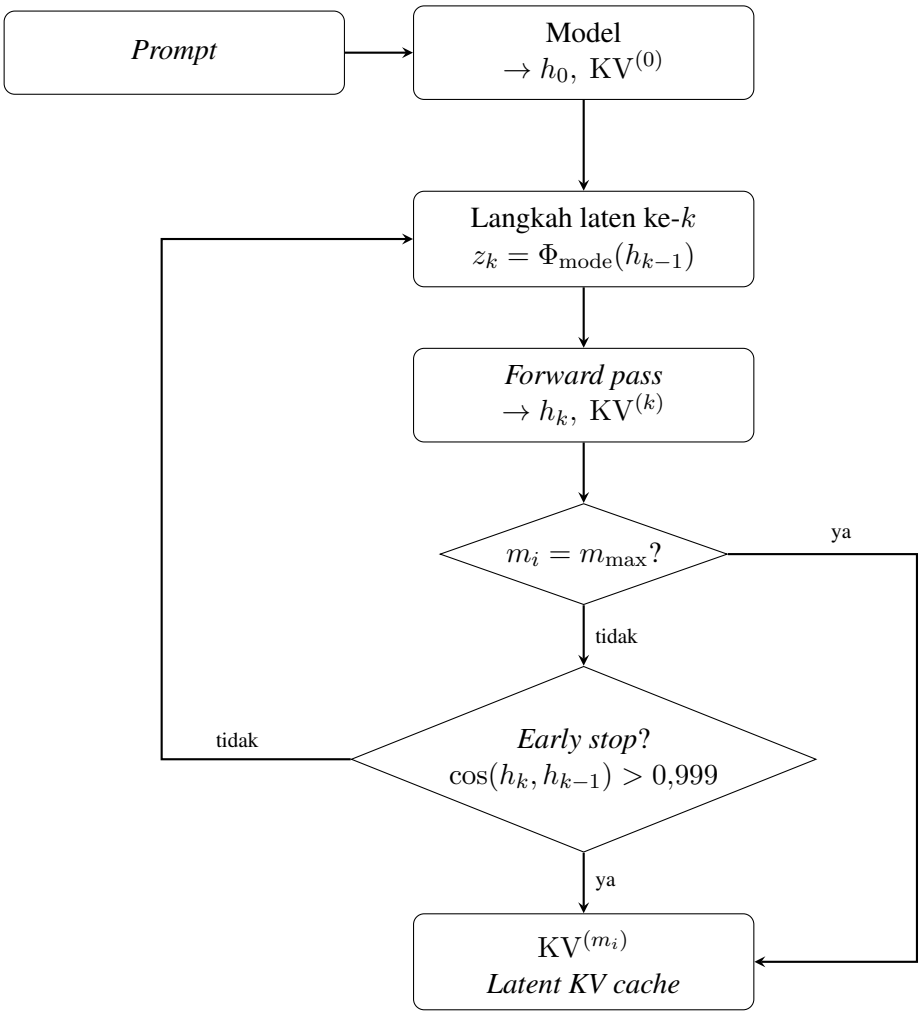
Berdasarkan uraian tersebut, alur komputasi yang relevan bagi penelitian dapat diringkas sebagai berikut. Token mula-mula dipetakan melalui W_{in} menjadi vektor masukan. Vektor tersebut kemudian diproses melalui seluruh blok *decoder* yang mencakup RMSNorm, GQA, RoPE, dan SwiGLU hingga menghasilkan *hidden state* h. Pada pembuatan token biasa, h dipetakan melalui W_{out} menjadi *logit*. Sebaliknya, pada langkah laten, h diberikan kepada fungsi Φ_{mode} untuk menghasilkan vektor laten z yang kembali dimasukkan ke model. Mekanisme tersebut dibahas pada Subbab 3.2..

3.2. Langkah Laten dalam Satu Agen

Langkah laten merupakan mekanisme yang memungkinkan model menghasilkan representasi perantara tanpa terlebih dahulu mengubah *hidden state* menjadi token diskret. Pada generasi autoregresif konvensional, *hidden state* pada suatu posisi diproyeksikan ke ruang kosakata untuk menghasilkan distribusi token berikutnya. Satu token kemudian dipilih dari distribusi tersebut dan *embedding* token yang terpilih digunakan sebagai masukan pada langkah berikutnya. Dengan demikian, informasi yang diteruskan ke langkah berikutnya direpresentasikan oleh satu token

diskret.

Pada penelitian ini, representasi tersebut digantikan oleh vektor laten $z_k \in \mathbb{R}^d$ yang diberikan langsung kepada model melalui *input embedding* pada langkah berikutnya. Vektor laten tidak didekode menjadi token selama proses ini, tetapi diproses kembali oleh model untuk menghasilkan *hidden state* baru dan memperbarui *key-value cache* (KV cache). Dengan demikian, langkah laten membentuk suatu proses iteratif pada ruang representasi kontinu.



Gambar 3.6 Alur satu *latent pass* pada satu agen.

3.2.1. Satu *Latent Pass*

Satu agen menjalankan sejumlah langkah laten secara berurutan dalam satu *latent pass*. Proses dimulai dengan pemrosesan *prompt* oleh model hingga dipero-

leh *hidden state* awal h_0 dan *key-value cache* (KV cache) awal $\mathrm{KV}^{(0)}$. Selanjutnya, *hidden state* digunakan untuk membentuk vektor laten, yang kemudian diberikan kembali kepada model sebagai masukan pada langkah berikutnya. Secara konseptual, inisialisasi tersebut dapat dituliskan sebagai

$$\mathrm{Prompt} \longrightarrow \left(h_0, \mathrm{KV}^{(0)}\right). \tag{3.22}$$

Untuk setiap langkah ke-k, vektor laten dibentuk dari *hidden state* sebelumnya dan kemudian diproses kembali oleh model, sehingga

$$z_k = \Phi_{\mathrm{mode}}(h_{k-1}), \tag{3.23}$$

$$\left(h_k, \mathrm{KV}^{(k)}\right) = f_\theta\left(z_k, \mathrm{KV}^{(k-1)}\right), \tag{3.24}$$

dengan $h_{k-1} \in \mathbb{R}^d$ merupakan *hidden state* sebelum langkah laten ke-k, $z_k \in \mathbb{R}^d$ merupakan vektor laten yang diberikan kembali kepada model, Φ_{mode} merupakan fungsi pembentukan vektor laten yang bergantung pada metode, dan f_θ menyatakan satu *forward pass* model dengan *KV cache* yang telah terbentuk sebelumnya.

Dengan demikian, rangkaian langkah laten dalam satu *latent pass* dapat dinyatakan sebagai

$$h_0 \longrightarrow z_1 \longrightarrow h_1 \longrightarrow z_2 \longrightarrow \cdots \longrightarrow z_{m_i} \longrightarrow h_{m_i}. \tag{3.25}$$

Pada setiap langkah, vektor z_k tidak didekode menjadi token diskret, melainkan langsung digunakan sebagai masukan kontinu melalui *input embedding*. Oleh karena itu, rangkaian tersebut merupakan proses iteratif pada ruang representasi kontinu.

Selain menghasilkan *hidden state* baru, pemrosesan z_k juga memperbarui *KV cache*. Pada lapisan ke-l, *KV cache* setelah t posisi dapat direpresentasikan se-

bagai

$$\mathrm{KV}_t^{(l)} = \left\{ \left(k_j^{(l)}, v_j^{(l)} \right) \right\}_{j=1}^{t}, \tag{3.26}$$

dengan $k_j^{(l)}$ dan $v_j^{(l)}$ masing-masing merupakan vektor *key* dan *value* pada posisi ke-j di lapisan ke-l. Secara konseptual, ketika z_k diproses oleh model, *KV cache* diperbarui melalui

$$\mathrm{KV}^{(k)} = \mathrm{KV}^{(k-1)} \parallel \mathrm{KV}(z_k), \tag{3.27}$$

dengan $\parallel$ menyatakan penggabungan sepanjang dimensi urutan dan $\mathrm{KV}(z_k)$ menyatakan pasangan *key-value* yang dihasilkan dari pemrosesan z_k. Dengan demikian, yang disimpan dalam *KV cache* bukanlah vektor laten z_k secara langsung, melainkan representasi *key* dan *value* yang dihasilkan model dari vektor tersebut.

Setelah seluruh langkah laten selesai, satu *latent pass* menghasilkan rangkaian vektor laten

$$Z_i = (z_1, \ldots, z_{m_i}), \tag{3.28}$$

serta *KV cache* akhir

$$\mathrm{KV}_i = \mathrm{KV}^{(m_i)}. \tag{3.29}$$

Pada mode komunikasi yang menghasilkan keluaran teks, *KV cache* akhir tersebut selanjutnya digunakan sebagai konteks untuk proses generasi teks. Dengan demikian, generasi teks merupakan tahap setelah *latent pass*, sedangkan pengulangan langkah laten berlangsung sepenuhnya sebelum tahap tersebut.

3.2.2. *Early Stopping* pada Langkah Laten

Jumlah langkah laten maksimum pada penelitian ini ditetapkan sebesar $m_{\max} = 10$. Namun, satu agen tidak selalu menjalankan seluruh langkah tersebut. Setelah

hidden state baru h_k diperoleh, kemiripannya dengan *hidden state* pada langkah sebelumnya h_{k-1} digunakan sebagai kriteria untuk menentukan apakah proses laten masih perlu dilanjutkan.

Kemiripan tersebut diukur menggunakan *cosine similarity*, yaitu

$$\cos(h_k, h_{k-1}) = \frac{h_k^{\mathsf{T}} h_{k-1}}{\|h_k\|_2 \, \|h_{k-1}\|_2}. \tag{3.30}$$

Proses langkah laten dihentikan apabila

$$\cos(h_k, h_{k-1}) > 0{,}999. \tag{3.31}$$

Kriteria tersebut menunjukkan bahwa proses laten dihentikan ketika dua *hidden state* berturut-turut memiliki arah yang sangat serupa. Apabila kriteria tersebut belum terpenuhi, proses dilanjutkan ke langkah laten berikutnya hingga mencapai batas maksimum.

Dengan demikian, jumlah langkah laten aktual yang dilakukan oleh agen ke-i memenuhi

$$1 \leq m_i \leq m_{\max}, \qquad m_{\max} = 10, \tag{3.32}$$

dengan m_i ditentukan oleh tercapainya kriteria *early stopping* atau batas maksimum langkah laten.

3.2.3. Dari *Hidden State* ke Distribusi Token

Untuk metode yang memanfaatkan distribusi token, h_k terlebih dahulu diproyeksikan ke ruang kosakata menggunakan matriks keluaran model W_{out}. Logit token ke-i pada langkah ke-k didefinisikan sebagai

$$\ell_{k,i} = W_{\text{out}}[i]^{\mathsf{T}} h_k, \tag{3.33}$$

atau dalam bentuk vektor,

$$\boldsymbol{\ell}_k = W_{\text{out}} h_k \in \mathbb{R}^{|\mathcal{V}|}. \tag{3.34}$$

Selanjutnya, logit tersebut diubah menjadi distribusi probabilitas atas seluruh kosakata menggunakan fungsi *softmax*. Dengan temperatur $T > 0$, diperoleh

$$p_{k,i} = \frac{\exp\left(\ell_{k,i}/T\right)}{\sum_{j=1}^{|\mathcal{V}|} \exp\left(\ell_{k,j}/T\right)}, \qquad i = 1, \ldots, |\mathcal{V}|. \tag{3.35}$$

Dalam bentuk vektor, Persamaan (3.35) dapat dituliskan sebagai

$$p_k = \text{softmax}\left(\frac{\boldsymbol{\ell}_k}{T}\right) \in \Delta^{|\mathcal{V}|-1}, \tag{3.36}$$

dengan

$$\Delta^{|\mathcal{V}|-1} = \left\{ w \in \mathbb{R}^{|\mathcal{V}|} : w_i \geq 0,\ \sum_{i=1}^{|\mathcal{V}|} w_i = 1 \right\} \tag{3.37}$$

merupakan *probability simplex*. Temperatur pada penelitian ini ditetapkan sebesar

$$T = 0{,}7. \tag{3.38}$$

Distribusi p_k merupakan distribusi prediktif model terhadap token berikutnya. Distribusi tersebut menjadi dasar pembentukan bobot w_k pada metode `soft`, `sample`, dan `moi`. Sebaliknya, metode `raw` tidak memerlukan pembentukan distribusi token sehingga tidak melalui tahapan pada Persamaan (3.34) hingga Persamaan (3.36).

3.2.4. Kerangka Penyatuan Metode

Keempat metode pembentukan langkah laten menggunakan *hidden state* h_k yang sama sebagai sumber informasi. Perbedaan antarmetode terletak pada meka-

nisme yang digunakan untuk mengubah *hidden state* tersebut menjadi representasi laten sebelum diberikan kembali kepada model. Untuk menyatakan mekanisme tersebut secara umum, digunakan Φ_{mode}, dengan mode menyatakan metode pembentukan representasi laten.

Secara umum, representasi laten dapat dipandang sebagai proses dua tahap. Tahap pertama menghasilkan representasi laten awal $\tilde{z}_k^{\mathrm{mode}}$, sedangkan tahap kedua menyesuaikan magnitudonya agar berada pada skala yang sama untuk seluruh metode. Dengan demikian,

$$z_k^{\mathrm{mode}} = \mathcal{N}\left(\tilde{z}_k^{\mathrm{mode}}\right), \tag{3.39}$$

dengan $\mathcal{N}(\cdot)$ menyatakan operator normalisasi dan $\tilde{z}_k^{\mathrm{mode}} \in \mathbb{R}^d$ merupakan representasi laten sebelum normalisasi. Normalisasi tersebut didefinisikan sebagai

$$z_k^{\mathrm{mode}} = \tau \frac{\tilde{z}_k^{\mathrm{mode}}}{\left\|\tilde{z}_k^{\mathrm{mode}}\right\|_2}, \qquad \mathrm{mode} \in \{\mathrm{soft}, \mathrm{sample}, \mathrm{moi}, \mathrm{raw}\}, \tag{3.40}$$

dengan $\tau > 0$ merupakan norma target yang ditetapkan sama untuk seluruh metode. Dengan normalisasi tersebut, setiap representasi laten yang diberikan kepada model memenuhi

$$\left\|z_k^{\mathrm{mode}}\right\|_2 = \tau. \tag{3.41}$$

Sehinggap perbandingan metode selanjutnya bisa berfokus pada mekanisme pembentukan arah representasi $\tilde{z}_k^{\mathrm{mode}}$.

Untuk metode `soft`, `sample`, dan `moi`, representasi laten awal dibentuk melalui ruang *input embedding*. Matriks *input embedding* didefinisikan sebagai

$$W_{\mathrm{in}} = \begin{bmatrix} W_{\mathrm{in}}[1]^{\mathsf{T}} \\ \vdots \\ W_{\mathrm{in}}[|\mathcal{V}|]^{\mathsf{T}} \end{bmatrix} \in \mathbb{R}^{|\mathcal{V}| \times d}, \tag{3.42}$$

dengan $W_{\text{in}}[i] \in \mathbb{R}^d$ merupakan vektor *embedding* token ke-i. Apabila w_k menyatakan bobot atas kosakata, maka representasi laten awal dapat dituliskan secara umum sebagai

$$\tilde{z}_k^{\text{mode}} = W_{\text{in}}^{\mathsf{T}} w_k, \qquad \text{mode} \in \{\text{soft}, \text{sample}, \text{moi}\}. \tag{3.43}$$

Karena w_k merupakan bobot atas kosakata, bentuk tersebut mencakup pembentukan representasi melalui kombinasi berbobot dari vektor *embedding*. Perbedaan antara `soft`, `sample`, dan `moi` dengan demikian tidak terletak pada bentuk pemetaan $W_{\text{in}}^{\mathsf{T}} w_k$, tetapi pada cara masing-masing metode memperoleh w_k.

Sementara itu, metode `raw` tidak membentuk representasi melalui bobot atas kosakata. Metode ini memetakan *hidden state* secara langsung ke ruang *input embedding* menggunakan matriks penyelarasan $M \in \mathbb{R}^{d \times d}$, sehingga

$$\tilde{z}_k^{\text{raw}} = M^{\mathsf{T}} h_k. \tag{3.44}$$

Dengan demikian, keempat metode dapat ditempatkan dalam satu kerangka umum, yaitu

$$h_k \longrightarrow \tilde{z}_k^{\text{mode}} \longrightarrow z_k^{\text{mode}}, \tag{3.45}$$

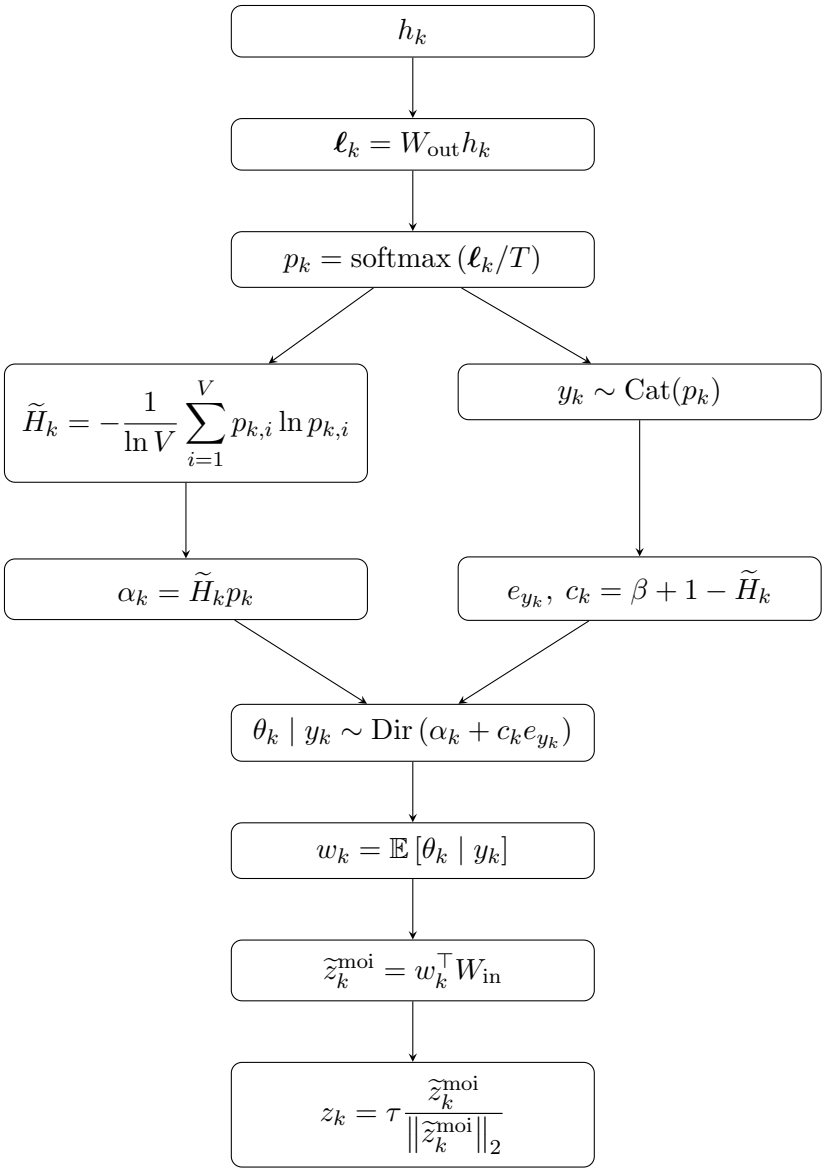
dengan perbedaan antarmetode ditentukan oleh pemetaan yang menghasilkan $\tilde{z}_k^{\text{mode}}$. Untuk `soft`, `sample`, dan `moi`, pemetaan tersebut melalui bobot atas kosakata, sedangkan `raw` menggunakan pemetaan langsung dari *hidden state*.

3.3. Mixture of Inputs

Pada langkah laten, *hidden state* h_k terlebih dahulu digunakan untuk menghasilkan distribusi probabilitas token berikutnya. Pada metode *Mixture of Inputs* (MoI), distribusi tersebut tidak langsung direduksi menjadi satu token, tetapi digunakan bersama dengan token hasil *sampling* untuk membentuk bobot campuran yang kemudian digunakan dalam penyusunan representasi masukan berikutnya.

Dengan demikian, informasi mengenai ketidakpastian model tetap dipertahankan pada representasi kontinu yang diberikan kembali kepada model.

Secara umum, alur pembentukan representasi laten pada metode MoI dapat dituliskan sebagai berikut.



Gambar 3.7 Alur pembentukan langkah laten menggunakan *Mixture of Inputs*.

Alur pada Gambar 3.7 menunjukkan bahwa terdapat dua informasi utama yang digunakan oleh MoI. Informasi pertama adalah distribusi prediktif p_k yang menggambarkan keyakinan model terhadap seluruh token dalam kosakata. Informasi kedua adalah token y_k yang diperoleh melalui proses *sampling*. Kedua infor-

masi tersebut kemudian digabungkan melalui estimasi Bayesian untuk memperoleh bobot w_k.

3.3.1. Ukuran Ketidakpastian

Distribusi p_k yang dihasilkan model tidak hanya menunjukkan token mana yang memiliki probabilitas terbesar, tetapi juga menunjukkan tingkat ketidakpastian model terhadap pilihan token. Untuk mengukur ketidakpastian tersebut digunakan entropi Shannon. Untuk distribusi token

$$p_k = (p_{k,1}, p_{k,2}, \ldots, p_{k,V}), \tag{3.46}$$

entropi Shannon didefinisikan sebagai

$$H(p_k) = -\sum_{i=1}^{V} p_{k,i} \ln p_{k,i}. \tag{3.47}$$

Nilai entropi bergantung pada jumlah kategori dalam distribusi. Oleh karena itu, agar nilai entropi dapat dibandingkan pada skala yang sama, entropi dinormalisasi terhadap entropi maksimum dari distribusi dengan V kategori. Entropi ternormalisasi kemudian didefinisikan sebagai

$$\widetilde{H}_k = \frac{H(p_k)}{\ln V} = -\frac{1}{\ln V} \sum_{i=1}^{V} p_{k,i} \ln p_{k,i}, \qquad 0 \leq \widetilde{H}_k \leq 1. \tag{3.48}$$

dengan:

- $\widetilde{H}_k$ adalah entropi ternormalisasi pada langkah laten ke-k;
- $p_{k,i}$ adalah probabilitas token ke-i;
- V adalah ukuran kosakata.

Batas bawah $\widetilde{H}_k = 0$ terjadi ketika seluruh probabilitas terkonsentrasi pada satu token. Sebaliknya, $\widetilde{H}_k = 1$ terjadi ketika seluruh token memiliki probabilitas

yang sama. Dengan demikian, nilai $\widetilde{H}_k$ digunakan sebagai ukuran tingkat ketidakpastian distribusi prediktif model.

Dalam penelitian ini, entropi dihitung pada seluruh kosakata Qwen3-8B, yaitu $V = 151,936$, sehingga penyebut pada Persamaan (3.48) adalah $\ln(151,936)$.

3.3.2. *Prior* Dirichlet

Setelah tingkat ketidakpastian distribusi diketahui, MoI memodelkan bobot campuran sebagai suatu parameter probabilitas yang berada pada simpleks. Misalkan

$$\theta_k = (\theta_{k,1}, \theta_{k,2}, \ldots, \theta_{k,V}), \qquad \theta_k \in \Delta^{V-1}. \tag{3.49}$$

Parameter θ_k dapat dipandang sebagai distribusi probabilitas laten yang akan menentukan bobot masing-masing embedding token. MoI menggunakan distribusi Dirichlet sebagai *prior* untuk parameter tersebut,

$$\theta_k \sim \mathrm{Dir}(\alpha_k), \tag{3.50}$$

dengan parameter konsentrasi

$$\alpha_{k,i} = \widetilde{H}_k p_{k,i}, \qquad i = 1, \ldots, V. \tag{3.51}$$

Dalam bentuk vektor, Persamaan (3.51) dapat dituliskan sebagai

$$\boldsymbol{\alpha}_k = \widetilde{H}_k p_k. \tag{3.52}$$

Pemilihan parameter tersebut membuat distribusi p_k menjadi pusat informasi dari *prior*, sedangkan besar kecilnya $\widetilde{H}_k$ menentukan total massa konsentrasi *prior*. Hal tersebut dapat dilihat dengan menjumlahkan seluruh parameter Dirichlet:

$$\alpha_{k,0} = \sum_{i=1}^{V} \alpha_{k,i} = \sum_{i=1}^{V} \widetilde{H}_k p_{k,i} = \widetilde{H}_k \sum_{i=1}^{V} p_{k,i} = \widetilde{H}_k. \tag{3.53}$$

dengan $\alpha_{k,0}$ menyatakan total massa konsentrasi distribusi Dirichlet.

Hasil pada Persamaan (3.53) menunjukkan bahwa

$$\alpha_{k,0} = \widetilde{H}_k. \tag{3.54}$$

Dengan demikian, entropi tidak mengubah proporsi relatif antar-komponen dari p_k, tetapi mengatur besarnya massa konsentrasi *prior*. Ketika $\widetilde{H}_k$ kecil, massa konsentrasi *prior* juga kecil sehingga informasi *prior* mempunyai pengaruh yang lebih lemah terhadap estimasi akhir. Sebaliknya, ketika $\widetilde{H}_k$ besar, distribusi prediktif memperoleh massa konsentrasi yang lebih besar.

Rerata distribusi Dirichlet secara umum diberikan oleh

$$\mathbb{E}[\theta_{k,i}] = \frac{\alpha_{k,i}}{\alpha_{k,0}}. \tag{3.55}$$

Dengan Persamaan (3.51) dan Persamaan (3.53), diperoleh

$$\mathbb{E}[\theta_{k,i}] = \frac{\widetilde{H}_k p_{k,i}}{\widetilde{H}_k} = p_{k,i}, \qquad \widetilde{H}_k > 0. \tag{3.56}$$

Dengan demikian, p_k merupakan pusat atau rerata dari *prior* Dirichlet, sedangkan $\widetilde{H}_k$ mengatur kekuatan informasi tersebut.

3.3.3. Model Observasi

Pada proses autoregresif, model tetap melakukan *sampling* untuk memperoleh token diskret. Metode *Mixture of Inputs* menggunakan token tersebut sebagai informasi observasi dalam pembentukan *posterior*.

Token pada langkah ke-k disampling dari distribusi prediktif model menurut

$$y_k \sim \mathrm{Cat}(p_k), \tag{3.57}$$

dengan $\mathrm{Cat}(p_k)$ menyatakan distribusi kategorik dengan V kemungkinan token.

Token hasil *sampling* kemudian direpresentasikan menggunakan vektor indikator atau *one-hot vector*,

$$e_{y_k} = (e_{k,1}, e_{k,2}, \ldots, e_{k,V}), \tag{3.58}$$

dengan

$$e_{k,i} = \mathbb{1}(i = y_k). \tag{3.59}$$

Dengan demikian, hanya komponen yang berkorespondensi dengan token hasil *sampling* yang bernilai satu, sedangkan komponen lainnya bernilai nol. Secara khusus,

$$\sum_{i=1}^{V} e_{k,i} = 1. \tag{3.60}$$

Pada persamaan MoI, informasi observasi tersebut diberikan suatu bobot yang disebut *pseudo-count*. Besarnya *pseudo-count* ditentukan oleh

$$\kappa_k = \beta + 1 - \widetilde{H}_k, \tag{3.61}$$

dengan $\beta \geq 0$ merupakan parameter yang mengatur konsentrasi tambahan pada token hasil *sampling*.

Vektor *pseudo-count* kemudian dapat ditulis sebagai

$$c_k = \kappa_k e_{y_k}. \tag{3.62}$$

Komponen-komponennya adalah

$$c_{k,i} = \left(\beta + 1 - \widetilde{H}_k\right) e_{k,i}. \tag{3.63}$$

Jumlah seluruh *pseudo-count* adalah

$$\sum_{i=1}^{V} c_{k,i} = \left(\beta + 1 - \widetilde{H}_k\right) \sum_{i=1}^{V} e_{k,i} = \beta + 1 - \widetilde{H}_k. \tag{3.64}$$

Dengan demikian, ketika entropi rendah, yaitu ketika model relatif yakin terhadap prediksinya, nilai κ_k menjadi lebih besar. Sebaliknya, ketika entropi tinggi, kontribusi *pseudo-count* menjadi lebih kecil.

3.3.4. Pembaruan *Posterior*

Keuntungan penggunaan distribusi Dirichlet adalah sifat kekonjugatannya terhadap distribusi kategorik atau multinomial. Apabila parameter probabilitas θ_k memiliki *prior*

$$\theta_k \sim \mathrm{Dir}(\alpha_k) \tag{3.65}$$

dan observasi memberikan vektor jumlah kejadian c_k, maka distribusi *posterior* tetap berada dalam keluarga Dirichlet, yaitu

$$\theta_k \mid y_k \sim \mathrm{Dir}\left(\alpha_k + c_k\right). \tag{3.66}$$

Dengan Persamaan (3.51) dan Persamaan (3.62), diperoleh

$$\alpha_k + c_k = \widetilde{H}_k p_k + \left(\beta + 1 - \widetilde{H}_k\right) e_{y_k}. \tag{3.67}$$

Dengan demikian,

$$\boxed{\theta_k \mid y_k \sim \mathrm{Dir}\left(\widetilde{H}_k p_k + \left(\beta + 1 - \widetilde{H}_k\right) e_{y_k}\right)}. \tag{3.68}$$

Selanjutnya, yang digunakan sebagai bobot campuran bukan sampel baru dari distribusi *posterior*, melainkan rerata *posterior*. Untuk distribusi Dirichlet dengan parameter $\gamma = (\gamma_1, \ldots, \gamma_V)$, rerata setiap komponennya adalah

$$\mathbb{E}[\theta_i] = \frac{\gamma_i}{\sum_{j=1}^{V} \gamma_j}. \tag{3.69}$$

Oleh karena itu,

$$w_{k,i} = \mathbb{E}\left[\theta_{k,i} \mid y_k\right] = \frac{\alpha_{k,i} + c_{k,i}}{\sum_{j=1}^{V} \left(\alpha_{k,j} + c_{k,j}\right)}. \tag{3.70}$$

Penyebut pada Persamaan (3.70) dapat diturunkan sebagai

$$\sum_{j=1}^{V} \left(\alpha_{k,j} + c_{k,j}\right) = \sum_{j=1}^{V} \alpha_{k,j} + \sum_{j=1}^{V} c_{k,j} \quad = \widetilde{H}_k + \left(\beta + 1 - \widetilde{H}_k\right) \; = \beta + 1. \tag{3.71}$$

Dengan memasukkan Persamaan (3.51), Persamaan (3.63), dan Persamaan (3.71) ke dalam Persamaan (3.70), diperoleh

$$w_{k,i} = \frac{\widetilde{H}_k p_{k,i} + \left(\beta + 1 - \widetilde{H}_k\right) e_{k,i}}{\beta + 1}. \tag{3.72}$$

Dalam bentuk vektor, bobot MoI dapat dituliskan sebagai

$$\boxed{w_k = \mathbb{E}\left[\theta_k \mid y_k\right] = \frac{\widetilde{H}_k p_k + \left(\beta + 1 - \widetilde{H}_k\right) e_{y_k}}{\beta + 1}}. \tag{3.73}$$

Persamaan (3.73) merupakan persamaan utama metode MoI yang digunak-

an dalam penelitian ini. Persamaan tersebut menunjukkan bahwa bobot masukan ditentukan dari gabungan informasi dari distribusi prediktif p_k dan token hasil *sampling*. Keduanya digabungkan melalui estimasi rerata *posterior* Bayesian.

3.3.5. Pembentukan Representasi Masukan MoI

Setelah bobot w_k diperoleh, bobot tersebut digunakan untuk membentuk kombinasi embedding dari seluruh token dalam kosakata. Sesuai dengan kerangka penyatuan pada subbab 3.2.4., representasi sebelum normalisasi dituliskan sebagai

$$\tilde{z}_k^{\mathrm{moi}} = w_k^\top W_{\mathrm{in}} = \sum_{i=1}^{V} w_{k,i} W_{\mathrm{in}}[i]. \tag{3.74}$$

dengan:

- $w_k \in \mathbb{R}^V$ adalah bobot MoI;
- $W_{\mathrm{in}} \in \mathbb{R}^{V \times d}$ adalah matriks embedding masukan;
- $W_{\mathrm{in}}[i] \in \mathbb{R}^d$ adalah embedding token ke-i;
- $\tilde{z}_k^{\mathrm{moi}} \in \mathbb{R}^d$ adalah representasi laten sebelum normalisasi.

Karena w_k merupakan rerata *posterior* Dirichlet, setiap elemennya tidak negatif dan jumlahnya sama dengan satu. Oleh sebab itu, $\tilde{z}_k^{\mathrm{moi}}$ merupakan kombinasi konveks dari embedding token.

Representasi akhir yang diberikan kepada model mengikuti normalisasi magnitudo bersama yang telah didefinisikan pada subbab 3.2.4., yaitu

$$z_k^{\mathrm{moi}} = \tau \frac{\tilde{z}_k^{\mathrm{moi}}}{\left|\tilde{z}_k^{\mathrm{moi}}\right|_2}. \tag{3.75}$$

Dengan demikian, keseluruhan pemetaan MoI dari *hidden state* menuju langkah laten dapat dirangkum sebagai

$$h_k \longrightarrow \boldsymbol{\ell}_k \longrightarrow p_k \longrightarrow \widetilde{H}_k \longrightarrow w_k \longrightarrow \tilde{z}_k^{\mathrm{moi}} \longrightarrow z_k^{\mathrm{moi}}. \tag{3.76}$$

Pada tahap ini, token y_k juga digunakan dalam pembentukan w_k melalui vektor indikator e_{y_k}. Dengan demikian, meskipun keluaran token tetap diperoleh melalui proses *sampling*, representasi yang diberikan kembali kepada model tidak lagi berupa embedding dari satu token saja. Representasi tersebut merupakan hasil pencampuran embedding berdasarkan informasi distribusi prediktif dan token yang terpilih.

3.3.6. Verifikasi Bobot MoI

Agar w_k dapat digunakan sebagai bobot kombinasi konveks, perlu ditunjukkan bahwa seluruh komponennya tidak negatif dan jumlahnya sama dengan satu.

Pertama, karena

$$p_{k,i} \geq 0, \qquad e_{k,i} \geq 0, \qquad 0 \leq \widetilde{H}_k \leq 1, \qquad \beta \geq 0, \tag{3.77}$$

maka

$$\beta + 1 - \widetilde{H}_k \geq 0. \tag{3.78}$$

Akibatnya,

$$w_{k,i} \geq 0. \tag{3.79}$$

Kedua, jumlah seluruh bobot dapat dihitung sebagai

$$\sum_{i=1}^{V} w_{k,i} = \frac{1}{\beta+1} \sum_{i=1}^{V} \left[\widetilde{H}_k p_{k,i} + \left(\beta + 1 - \widetilde{H}_k \right) e_{k,i} \right] \tag{3.80}$$

$$\tag{3.81}$$

$$= \frac{1}{\beta+1} \left[\widetilde{H}_k \sum_{i=1}^{V} p_{k,i} + \left(\beta + 1 - \widetilde{H}_k \right) \sum_{i=1}^{V} e_{k,i} \right] \tag{3.82}$$

$$\tag{3.83}$$

$$= \frac{\widetilde{H}_k + \beta + 1 - \widetilde{H}_k}{\beta+1} \tag{3.84}$$

$$= 1. \tag{3.85}$$

Dengan demikian,

$$w_k \in \Delta^{V-1}. \tag{3.86}$$

Hal ini memastikan bahwa $\tilde{z}_k^{\text{moi}}$ merupakan kombinasi konveks dari embedding pada W_{in}.

3.3.7. Perilaku Bobot terhadap Entropi

Struktur Persamaan (3.73) dapat ditulis kembali sebagai

$$w_k = \frac{\widetilde{H}_k}{\beta+1} p_k + \frac{\beta + 1 - \widetilde{H}_k}{\beta+1} e_{y_k}. \tag{3.87}$$

Jika didefinisikan

$$a_k = \frac{\widetilde{H}_k}{\beta+1}, \tag{3.88}$$

maka

$$w_k = a_k p_k + (1 - a_k) e_{y_k}. \tag{3.89}$$

Persamaan (3.89) menunjukkan bahwa MoI dapat dipandang sebagai interpolasi antara dua bentuk representasi. Komponen pertama adalah distribusi penuh p_k, sedangkan komponen kedua adalah vektor satu-hot e_{y_k} yang merepresentasikan token hasil *sampling*.

Untuk $\widetilde{H}_k \to 0$, diperoleh

$$w_k \to \frac{(\beta+1)e_{y_k}}{\beta+1} = e_{y_k}. \tag{3.90}$$

Dengan demikian, pada entropi yang sangat rendah, bobot MoI semakin mendekati representasi diskret dari token yang dipilih.

Sementara itu, untuk $\widetilde{H}_k \to 1$, diperoleh

$$w_k \to \frac{p_k + \beta e_{y_k}}{\beta+1}. \tag{3.91}$$

Persamaan (3.91) menunjukkan bahwa untuk $\beta > 0$, batas ketika $\widetilde{H}_k \to 1$ masih mengandung kontribusi token hasil *sampling*. Nilai $w_k \to p_k$ secara tepat hanya diperoleh apabila $\beta = 0$.

3.3.8. Pengaruh Parameter β

Parameter β menentukan tambahan konsentrasi yang diberikan kepada token hasil *sampling*. Berdasarkan Persamaan (3.73), pengaruh β dapat diamati melalui bentuk

$$w_k = \frac{\widetilde{H}_k}{\beta+1}p_k + \frac{\beta+1-\widetilde{H}_k}{\beta+1}e_{y_k}. \tag{3.92}$$

Nilai β yang lebih besar meningkatkan kontribusi relatif komponen e_{y_k}, sedangkan nilai yang lebih kecil mempertahankan proporsi yang lebih besar dari distribusi p_k. Oleh karena itu, β mengendalikan keseimbangan antara informasi distri-

busional dan informasi token hasil *sampling*.

Dalam penelitian ini digunakan

$$\boxed{\beta = 1}. \tag{3.93}$$

Dengan demikian, bobot yang digunakan pada seluruh eksperimen MoI ditetapkan sebagai

$$w_k = \frac{\widetilde{H}_k p_k + \left(2 - \widetilde{H}_k\right) e_{y_k}}{2}. \tag{3.94}$$

Selanjutnya, bobot tersebut digunakan untuk membentuk representasi laten melalui

$$\tilde{z}_k^{\mathrm{moi}} = w_k^{\top} W_{\mathrm{in}}, \tag{3.95}$$

yang kemudian dinormalisasi menggunakan konvensi bersama,

$$z_k^{\mathrm{moi}} = \tau \frac{\tilde{z}_k^{\mathrm{moi}}}{|\tilde{z}_k^{\mathrm{moi}}|_2}. \tag{3.96}$$

3.4. Metode Pembanding

Untuk mengevaluasi karakteristik metode *Mixture of Inputs* (MoI), penelitian ini menggunakan tiga metode pembanding dalam pembentukan langkah laten, yaitu `soft`, `sample`, dan `raw`. Ketiga metode tersebut memiliki cara yang berbeda dalam mengubah *hidden state* menjadi representasi laten. Metode `soft` mempertahankan seluruh distribusi probabilitas token, metode `sample` menggunakan token hasil *sampling* secara langsung, sedangkan metode `raw` memetakan *hidden state* secara langsung ke ruang embedding masukan melalui matriks penyelarasan.

Dalam penelitian ini, ketiga metode pembanding mengikuti kerangka langkah laten yang sama pada Subbab 3.2.4.. Dengan demikian, perbedaan antar-metode terletak pada pemetaan dari *hidden state* h_k menjadi representasi sebelum normali-

sasi $\widetilde{z}_k$, sedangkan normalisasi magnitudo diterapkan secara bersama. Hal ini memungkinkan perbandingan dilakukan pada representasi laten dengan skala yang sama.

3.4.1. Metode `soft`

Metode `soft` menggunakan seluruh distribusi probabilitas token yang dihasilkan model sebagai bobot untuk menggabungkan embedding masukan. Distribusi probabilitas pada langkah ke-k diperoleh dari *logit* model,

$$\boldsymbol{\ell}_k = W_{\text{out}} h_k, \tag{3.97}$$

kemudian dikonversi menjadi distribusi probabilitas menggunakan fungsi *softmax*,

$$p_k = \text{softmax}\left(\frac{\boldsymbol{\ell}_k}{T}\right), \tag{3.98}$$

dengan T merupakan temperatur laten. Karena p_k merupakan distribusi probabilitas, berlaku

$$p_{k,i} \geq 0, \qquad \sum_{i=1}^{V} p_{k,i} = 1. \tag{3.99}$$

Distribusi tersebut kemudian digunakan secara langsung sebagai bobot embedding. Dengan konvensi vektor kolom yang digunakan dalam penelitian ini, representasi sebelum normalisasi adalah

$$\widetilde{z}_k^{\text{soft}} = W_{\text{in}}^{\top} p_k. \tag{3.100}$$

Secara ekuivalen, Persamaan (3.100) dapat dituliskan sebagai

$$\widetilde{z}_k^{\text{soft}} = \sum_{i=1}^{V} p_{k,i} W_{\text{in}}[i]. \tag{3.101}$$

Karena p_k merupakan distribusi probabilitas, representasi $\widetilde{z}_k^{\text{soft}}$ merupakan kombinasi konveks dari seluruh embedding pada W_{in}. Representasi tersebut kemudian dinormalisasi menggunakan normalisasi magnitudo bersama yang telah didefinisikan pada Subbab 3.2.4.,

$$z_k^{\text{soft}} = \tau \frac{\widetilde{z}_k^{\text{soft}}}{\left\| \widetilde{z}_k^{\text{soft}} \right\|_2}. \tag{3.102}$$

Dengan demikian, metode `soft` mempertahankan informasi dari seluruh distribusi prediktif model tanpa memilih satu token tertentu sebagai representasi masukan.

3.4.2. Metode `sample`

Berbeda dari metode `soft`, metode `sample` menggunakan satu token yang diperoleh melalui proses *sampling*. Token pada langkah ke-k disampling dari distribusi p_k menurut

$$y_k \sim \text{Cat}(p_k). \tag{3.103}$$

Token hasil *sampling* kemudian direpresentasikan menggunakan vektor satu-*hot*,

$$e_{y_k} = (e_{k,1}, e_{k,2}, \ldots, e_{k,V}), \qquad e_{k,i} = \mathbb{1}(i = y_k). \tag{3.104}$$

Sehingga hanya satu komponen dari e_{y_k} yang bernilai satu dan komponen lainnya bernilai nol. Secara khusus,

$$\sum_{i=1}^{V} e_{k,i} = 1. \tag{3.105}$$

Representasi sebelum normalisasi kemudian diperoleh dengan menggunakan vektor satu-*hot* tersebut sebagai bobot embedding,

$$\widetilde{z}_k^{\text{sample}} = W_{\text{in}}^{\top} e_{y_k} = W_{\text{in}}[y_k]. \tag{3.106}$$

Metode `sample` hanya meneruskan embedding dari token yang terpilih. Representasi tersebut selanjutnya dinormalisasi menggunakan normalisasi magnitudo bersama,

$$z_k^{\text{sample}} = \tau \frac{\widetilde{z}_k^{\text{sample}}}{\left\| \widetilde{z}_k^{\text{sample}} \right\|_2}. \tag{3.107}$$

Metode `sample` merepresentasikan bentuk paling diskret dalam kerangka pembentukan langkah laten yang digunakan pada penelitian ini. Informasi mengenai probabilitas token lain dalam p_k tidak secara langsung digunakan dalam pembentukan representasi setelah token y_k dipilih.

3.4.3. Metode `raw`

Metode `raw` mengikuti pendekatan penyelarasan(*alignment*) ruang masukan dan keluaran yang digunakan dalam LatentMAS Zou dkk, 2025. Berbeda dari metode `soft`, `sample`, dan MoI yang membentuk representasi melalui kombinasi embedding pada W_{in}, metode ini secara langsung memetakan *hidden state* h_k menggunakan suatu matriks penyelarasan M.

Matriks M diperoleh melalui regresi *ridge* dengan tujuan menyelaraskan ruang keluaran model dengan ruang embedding masukan. Fungsi objektif yang digunakan adalah

$$J(M) = \|W_{\text{out}} M - W_{\text{in}}\|_F^2 + \lambda \|M\|_F^2, \qquad M \in \mathbb{R}^{d \times d}, \tag{3.108}$$

dengan $\|\cdot\|_F$ menyatakan norma Frobenius dan $\lambda > 0$ merupakan parameter regularisasi.

Untuk memperoleh bentuk tertutup dari M, fungsi objektif dapat dinyatakan menggunakan operator jejak sebagai

$$J(M) = \operatorname{tr}\left[(W_{\text{out}}M - W_{\text{in}})^\top (W_{\text{out}}M - W_{\text{in}})\right] + \lambda \operatorname{tr}(M^\top M) \tag{3.109}$$

$$= \operatorname{tr}\left(M^\top W_{\text{out}}^\top W_{\text{out}} M\right) - 2\operatorname{tr}\left(M^\top W_{\text{out}}^\top W_{\text{in}}\right) + \operatorname{tr}\left(W_{\text{in}}^\top W_{\text{in}}\right) + \lambda \operatorname{tr}(M^\top M). \tag{3.110}$$

Dengan menurunkan $J(M)$ terhadap M dan menyamakannya dengan nol, diperoleh

$$\frac{\partial J}{\partial M} = 2W_{\text{out}}^\top W_{\text{out}} M - 2W_{\text{out}}^\top W_{\text{in}} + 2\lambda M = 0, \tag{3.111}$$

sehingga

$$\left(W_{\text{out}}^\top W_{\text{out}} + \lambda I\right) M = W_{\text{out}}^\top W_{\text{in}}. \tag{3.112}$$

Dengan demikian, matriks penyelarasan diperoleh sebagai

$$\boxed{M = \left(W_{\text{out}}^\top W_{\text{out}} + \lambda I\right)^{-1} W_{\text{out}}^\top W_{\text{in}}}. \tag{3.113}$$

Dalam penelitian ini digunakan nilai regularisasi

$$\lambda = 10^{-5}. \tag{3.114}$$

Setelah matriks M diperoleh, *hidden state* h_k dipetakan ke representasi sebelum normalisasi. Dengan konvensi vektor kolom yang digunakan dalam penelitian ini, pemetaan tersebut dituliskan sebagai

$$\widetilde{z}_k^{\text{raw}} = M^\top h_k. \tag{3.115}$$

Bentuk tersebut ekuivalen dengan implementasi berbasis vektor baris $h_k M$.

Representasi akhir kemudian dinormalisasi menggunakan normalisasi magnitudo bersama,

$$z_k^{\mathrm{raw}} = \tau \frac{\widetilde{z}_k^{\mathrm{raw}}}{\left\|\widetilde{z}_k^{\mathrm{raw}}\right\|_2}. \tag{3.116}$$

Berbeda dari ketiga metode berbasis distribusi token, representasi $\widetilde{z}_k^{\mathrm{raw}}$ tidak secara umum dapat dinyatakan sebagai kombinasi konveks dari embedding pada W_{in}. Oleh karena itu,

$$\widetilde{z}_k^{\mathrm{raw}} \notin \mathrm{conv}\left\{W_{\mathrm{in}}[i]\right\}_{i=1}^{V} \quad \text{secara umum.} \tag{3.117}$$

Dengan demikian, metode `raw` digunakan sebagai pembanding yang merepresentasikan pendekatan pemetaan langsung dari ruang *hidden state* menuju ruang embedding masukan, sedangkan metode `soft`, `sample`, dan MoI membentuk representasi melalui bobot atas kosakata.

3.5. Komunikasi Antar-Agen

Komunikasi antar-agen pada penelitian ini digunakan untuk meneruskan informasi dari satu agen ke agen berikutnya dalam sistem *multi-agent*. Sistem terdiri atas empat agen yang bekerja secara berurutan, yaitu *planner*, *critic*, *refiner*, dan *judger*. Secara umum, rantai agen dinyatakan sebagai

$$A_1 \longrightarrow A_2 \longrightarrow A_3 \longrightarrow A_4, \tag{3.118}$$

dengan

$$A_1 = \textit{Planner}, \qquad A_2 = \textit{Critic}, \qquad A_3 = \textit{Refiner}, \qquad A_4 = \textit{Judger}. \tag{3.119}$$

Setiap agen menerima instruksi yang dinyatakan sebagai *prompt* dan informasi yang diteruskan dari agen sebelumnya. Untuk agen ke-i, misalkan P_i menya-

takan *prompt* dan $C_i^{(c)}$ menyatakan konteks komunikasi pada medium c, dengan

$$c \in \{\texttt{text}, \texttt{kv}\}. \tag{3.120}$$

Masukan agen ke-i kemudian secara konseptual dapat dinyatakan sebagai

$$X_i^{(c)} = \left(P_i, C_i^{(c)}\right). \tag{3.121}$$

Agen A_i selanjutnya dapat dipandang sebagai suatu pemetaan dari masukan tersebut menuju keluaran yang bergantung pada medium komunikasi,

$$O_i^{(c)} = A_i\left(P_i, C_i^{(c)}\right). \tag{3.122}$$

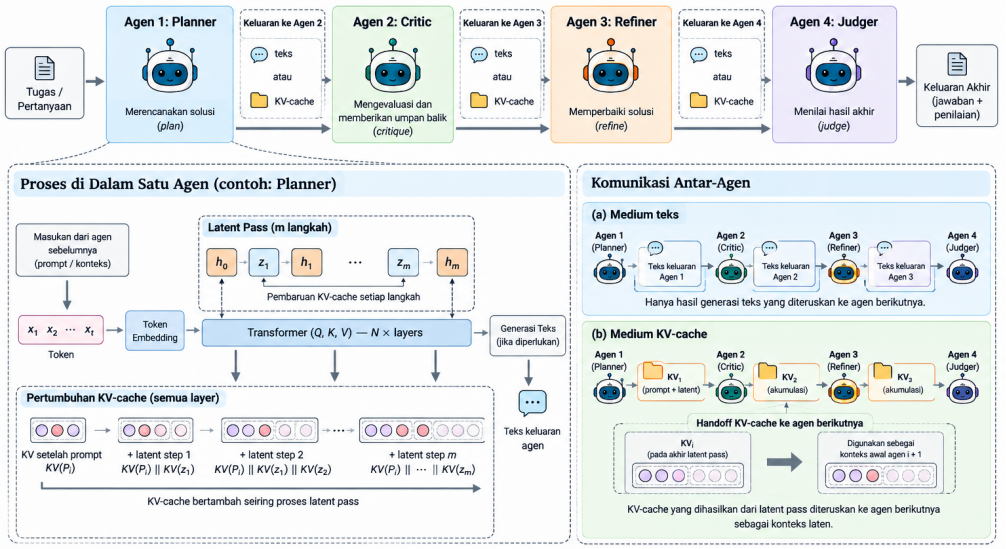
Untuk agen pertama, tidak terdapat informasi dari agen sebelumnya sehingga konteks awal dinyatakan sebagai

$$C_1^{(c)} = \varnothing. \tag{3.123}$$

Untuk $i > 1$, konteks $C_i^{(c)}$ dibentuk dari informasi yang diteruskan oleh agen ke-$(i-1)$ sesuai dengan medium komunikasi yang digunakan.

Dalam penelitian ini, medium komunikasi dibatasi pada komunikasi berbasis `text` dan komunikasi berbasis `kv`. Pada medium `text`, keluaran agen berupa teks yang digunakan sebagai konteks bagi agen berikutnya. Sebaliknya, pada medium `kv`, informasi yang diteruskan berupa *KV cache* yang terbentuk selama *latent pass*. Dengan demikian, perbedaan kedua medium terletak pada bentuk representasi informasi yang diteruskan antargen, sedangkan struktur rantai agen dan *prompt* yang digunakan tetap sama.

Struktur rantai agen dan kedua medium komunikasi tersebut ditunjukkan pada Gambar 3.8.



Gambar 3.8 Arsitektur Multi-Agen dengan Medium Komunikasi

3.5.1. Komunikasi `text`

Pada medium `text`, informasi antar-agen diteruskan dalam bentuk keluaran teks. Tidak terdapat *latent pass* maupun pewarisan *KV cache* antar-agen. Berdasarkan notasi 3.122, keluaran agen ke-i pada medium `text` dapat dinyatakan sebagai $O_i^{(\text{text})}$, yang dalam implementasinya berupa teks S_i,

$$O_i^{(\text{text})} = S_i. \tag{3.124}$$

Untuk agen pertama, tidak terdapat konteks komunikasi dari agen sebelumnya, sehingga

$$C_1^{(\text{text})} = \varnothing, \qquad S_1 = A_1\left(P_1, C_1^{(\text{text})}\right). \tag{3.125}$$

Untuk agen ke-i, dengan $i > 1$, konteks komunikasi dibentuk dari keluaran tekstual seluruh agen sebelumnya. Konteks tersebut dibatasi hingga panjang maksimum L dan dinyatakan sebagai

$$C_i^{(\text{text})} = \text{trunc}_L\left(S_1 \| \cdots \| S_{i-1}\right), \qquad i > 1. \tag{3.126}$$

dengan $\|$ menyatakan konkatenasi teks dan trunc_L menyatakan pemangkasan konteks hingga panjang maksimum L. Pada penelitian ini digunakan

$$L = 8000. \tag{3.127}$$

Selanjutnya, agen ke-i menghasilkan keluaran berdasarkan *prompt* P_i dan konteks komunikasi $C_i^{(\text{text})}$,

$$S_i = O_i^{(\text{text})} = A_i\left(P_i, C_i^{(\text{text})}\right), \qquad i > 1. \tag{3.128}$$

Dengan demikian, komunikasi pada medium `text` meneruskan keluaran tekstual dari satu agen sebagai bagian dari konteks bagi agen berikutnya,

$$S_1 \longrightarrow S_2 \longrightarrow S_3 \longrightarrow S_4. \tag{3.129}$$

3.5.2. Komunikasi `kv`

Pada medium `kv`, informasi antar-agen diteruskan dalam bentuk *KV cache* yang terbentuk selama pemrosesan *prompt* dan *latent pass*. Berbeda dengan medium `text`, keluaran agen tidak didekode menjadi teks sebelum diteruskan kepada agen berikutnya. Dengan notasi pada Persamaan (3.122), keluaran komunikasi agen ke-i pada medium `kv` dinyatakan sebagai

$$O_i^{(\text{kv})} = \mathrm{KV}_i. \tag{3.130}$$

Dengan demikian, konteks komunikasi yang diterima agen berikutnya merupakan *KV cache* yang telah dibentuk oleh agen sebelumnya. Untuk agen pertama, tidak terdapat *KV cache* yang diwariskan sehingga

$$C_1^{(\text{kv})} = \varnothing. \tag{3.131}$$

Setelah memproses *prompt* dan menjalankan *latent pass*, agen pertama meng-

hasilkan *KV cache* akhir

$$O_1^{(\mathrm{kv})} = \mathrm{KV}_1 = A_1\left(P_1, C_1^{(\mathrm{kv})}\right). \tag{3.132}$$

Untuk agen ke-i, dengan $i > 1$, *KV cache* dari agen sebelumnya digunakan sebagai konteks yang telah tersedia sebelum agen tersebut memproses *prompt* dan langkah laten barunya. Dengan demikian,

$$C_i^{(\mathrm{kv})} = \mathrm{KV}_{i-1}, \qquad i > 1, \tag{3.133}$$

dan keluaran agen dapat dinyatakan sebagai

$$O_i^{(\mathrm{kv})} = \mathrm{KV}_i = A_i\left(P_i, \mathrm{KV}_{i-1}\right), \qquad i > 1. \tag{3.134}$$

Pada tingkat lapisan model, *KV cache* menyimpan pasangan vektor *key* dan *value* untuk setiap posisi yang telah diproses. Untuk lapisan ke-l, setelah t posisi diproses, *KV cache* dapat dinyatakan sebagai

$$\mathrm{KV}_t^{(l)} = \left(K_t^{(l)}, U_t^{(l)}\right), \tag{3.135}$$

dengan

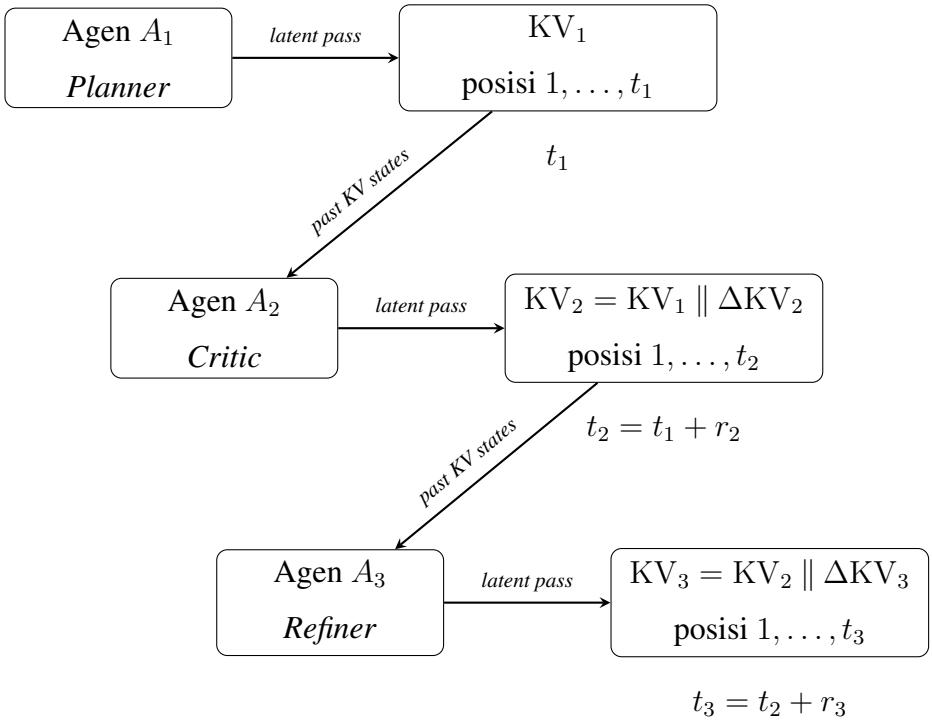
$$K_t^{(l)} = \left\{k_j^{(l,g)} : 1 \le j \le t,\ 1 \le g \le H_{kv}\right\}, \qquad U_t^{(l)} = \left\{u_j^{(l,g)} : 1 \le j \le t,\ 1 \le g \le H_{kv}\right\}, \tag{3.136}$$

dengan $k_j^{(l,g)}$ dan $u_j^{(l,g)}$ masing-masing menyatakan vektor *key* dan *value* pada posisi ke-j, *head* ke-g, dan lapisan ke-l. Pada Qwen3-8B digunakan $H_{kv} = 8$ *key-value heads*. [Yang dkk, 2025]

Jika sebuah posisi baru diproses, pasangan *key-value* pada posisi tersebut ditambahkan ke bagian akhir *KV cache*. Oleh karena itu, pertumbuhan *KV cache* dapat dinyatakan sebagai

$$\mathrm{KV}_{t+1}^{(l)} = \mathrm{KV}_{t}^{(l)} \parallel \left(K_{t+1}^{(l)}, U_{t+1}^{(l)}\right), \tag{3.137}$$

dengan $\parallel$ menyatakan penggabungan sepanjang dimensi posisi. Dengan kata lain, informasi pada posisi $1, \ldots, t$ tetap berada dalam *KV cache*, sedangkan posisi $t+1$ menambahkan pasangan *key-value* baru. Sifat pertumbuhan ini merupakan konsekuensi dari penggunaan *KV cache* untuk menyimpan hasil proyeksi posisi-posisi yang telah diproses.



Gambar 3.9 Alur pewarisan dan pertumbuhan *KV cache* antar-agen.

Pada komunikasi antar-agen, pertumbuhan tersebut terjadi tidak hanya ketika satu agen memproses posisi baru, tetapi juga ketika *KV cache* hasil suatu agen diwariskan kepada agen berikutnya. Misalkan t_i menyatakan jumlah posisi yang telah tersimpan setelah agen ke-i selesai diproses. Jika agen ke-$(i+1)$ memproses sebanyak r_{i+1} posisi baru, maka panjang cache menjadi

$$t_{i+1} = t_i + r_{i+1}. \tag{3.138}$$

Dengan demikian, pada setiap lapisan,

$$\mathrm{KV}_{i+1}^{(l)} = \mathrm{KV}_{i}^{(l)} \parallel \Delta\mathrm{KV}_{i+1}^{(l)}, \tag{3.139}$$

dengan $\Delta\mathrm{KV}_{i+1}^{(l)}$ menyatakan bagian *KV cache* yang terbentuk dari pemrosesan baru oleh agen ke-$(i+1)$.

Jika r_i mencakup seluruh posisi baru yang diproses oleh agen ke-i, termasuk posisi *prompt* dan posisi yang berasal dari langkah laten, maka panjang cache setelah N agen dapat dituliskan sebagai

$$t_N = \sum_{i=1}^{N} r_i. \tag{3.140}$$

Secara konseptual, pewarisan tersebut dapat diringkas sebagai

$$\mathrm{KV}_1 \longrightarrow \mathrm{KV}_2 \longrightarrow \cdots \longrightarrow \mathrm{KV}_N, \tag{3.141}$$

dengan setiap KV_i mempertahankan informasi yang telah tersimpan sebelumnya dan menambahkan representasi dari posisi yang diproses oleh agen ke-i.

3.6. Rancangan Eksperimen dan Analisis

3.6.1. Rancangan Eksperimen

Penelitian ini menggunakan eksperimen terkendali untuk membandingkan formulasi representasi langkah laten dan medium komunikasi antar-agen dalam *Multi-Agent System* (MAS). Rancangan eksperimen dibentuk dari dua aspek, yaitu medium komunikasi dan formulasi pembentukan representasi langkah laten.

- **Medium komunikasi:** berbasis teks dan berbasis *KV-cache*.
- **Formulasi langkah laten (pada medium *KV-cache*):** `raw`, `soft`, `sample`, dan `moi`.

Kondisi eksperimen terdiri atas satu kondisi komunikasi berbasis teks dan empat kondisi berbasis *KV-cache*:

- Pada kondisi `text`, informasi antar-agen diteruskan sebagai keluaran tekstual sehingga tidak ada persamaan Φ terpisah.
- Pada keempat kondisi lainnya, informasi diteruskan melalui *KV-cache* dan representasi langkah laten dibentuk menggunakan persamaan Φ yang sesuai.

Struktur ini memungkinkan pengaruh medium komunikasi diuji dengan membandingkan kondisi `text` terhadap kelompok kondisi *KV-cache*, sedangkan perbedaan antarformulasi laten dianalisis dengan membandingkan keempat kondisi *KV-cache*.

Secara ringkas, struktur perlakuan dapat dinyatakan sebagai

$$\mathcal{C} = \{\texttt{text}, \texttt{raw}, \texttt{soft}, \texttt{sample}, \texttt{moi}\}, \tag{3.142}$$

dengan

$$\begin{aligned} \texttt{text}: &\quad \text{medium teks}, \\ \texttt{raw}: &\quad \textit{KV-cache} \text{ dengan } \Phi_{\texttt{raw}}, \\ \texttt{soft}: &\quad \textit{KV-cache} \text{ dengan } \Phi_{\texttt{soft}}, \\ \texttt{sample}: &\quad \textit{KV-cache} \text{ dengan } \Phi_{\texttt{sample}}, \\ \texttt{moi}: &\quad \textit{KV-cache} \text{ dengan } \Phi_{\texttt{moi}}. \end{aligned} \tag{3.143}$$

Seluruh kondisi dijalankan menggunakan *backbone* Qwen3-8B dan rantai agen yang sama, yaitu *planner* $\rightarrow$ *critic* $\rightarrow$ *refiner* $\rightarrow$ *judger*. Untuk kondisi yang menggunakan langkah laten, setiap agen menjalankan paling banyak $m = 10$ langkah laten.

Faktor-faktor yang tidak menjadi objek perlakuan dijaga tetap sepanjang eksperimen utama. Faktor tersebut mencakup model yang digunakan, struktur rantai agen, jumlah maksimum langkah laten, parameter suhu pembentukan distribusi langkah laten, parameter β pada *Mixture of Inputs*, *temperature* pembuatan keluaran teks, *top-*p, batas panjang keluaran, kriteria penghentian dini. Penetapan tersebut dilakukan agar perbedaan hasil antarkondisi dapat dikaitkan dengan perlakuan yang

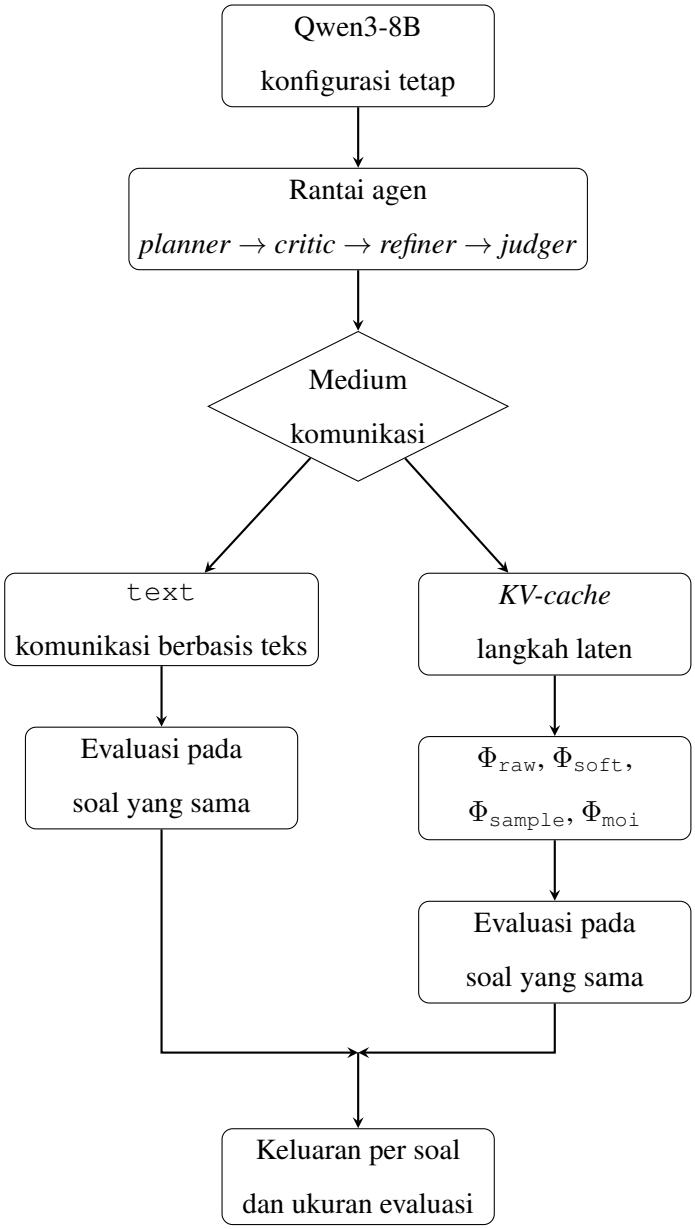
dibandingkan, bukan dengan perubahan konfigurasi eksperimen.

Evaluasi dilakukan pada GSM8K, ARC-Challenge, dan HumanEval+. Ketiga *benchmark* digunakan secara konsisten pada seluruh kondisi dalam *benchmark* yang sama. Pada setiap *benchmark*, himpunan soal yang digunakan juga dibuat identik untuk seluruh kondisi. Dengan demikian, apabila kondisi $c_1, c_2 \in \mathcal{C}$ dibandingkan pada soal ke-k, hasil keduanya membentuk satu pasangan observasi,

$$(Y_{k,c_1}, Y_{k,c_2}), \qquad k = 1, \ldots, n, \tag{3.144}$$

dengan $Y_{k,c}$ menyatakan hasil evaluasi kondisi c pada soal ke-k. Struktur berpasangan tersebut digunakan karena setiap kondisi dievaluasi pada objek soal yang sama, sehingga perbedaan tingkat kesulitan antar himpunan soal tidak menjadi sumber perbedaan antarkondisi.

Secara keseluruhan, rancangan eksperimen dapat diringkas dalam alur berikut.



Gambar 3.10 Rancangan eksperimen penelitian.

3.6.2. Pengukuran dan Analisis Kinerja

Kinerja setiap kondisi eksperimen dievaluasi berdasarkan akurasi, *format rate*, jumlah token keluaran, dan waktu inferensi. Keempat ukuran dihitung pada tingkat soal sehingga hasil dari soal yang sama pada kondisi berbeda dapat dibandingkan secara berpasangan. Akurasi digunakan untuk mengukur proporsi jawaban benar, sedangkan *format rate* digunakan untuk mengukur proporsi keluaran yang

memenuhi format evaluasi. Definisi kedua ukuran tersebut mengacu pada metrik yang telah dibahas pada Bab 3.6.3..

Untuk kondisi c pada suatu *benchmark*, dengan N soal, akurasi dihitung sebagai

$$A_c = \frac{1}{N} \sum_{i=1}^{N} I(Y_{ic} = 1), \tag{3.145}$$

dengan $Y_{ic} = 1$ apabila jawaban pada soal ke-i dinyatakan benar dan $Y_{ic} = 0$ apabila dinyatakan salah. Sementara itu, *format rate* dihitung sebagai

$$F_c = \frac{1}{N} \sum_{i=1}^{N} I(R_{ic} = 1), \tag{3.146}$$

dengan $R_{ic} = 1$ apabila keluaran dapat diproses oleh prosedur evaluasi dan $R_{ic} = 0$ sebaliknya.

Jumlah token keluaran dan waktu inferensi digunakan sebagai ukuran efisiensi. Untuk masing-masing kondisi, nilai yang dilaporkan adalah rata-rata per soal,

$$\bar{T}_c = \frac{1}{N} \sum_{i=1}^{N} T_{ic}, \qquad \bar{W}_c = \frac{1}{N} \sum_{i=1}^{N} W_{ic}, \tag{3.147}$$

dengan T_{ic} menyatakan jumlah token keluaran dan W_{ic} menyatakan waktu inferensi untuk soal ke-i pada kondisi c.

Perbandingan berpasangan. Karena himpunan soal yang digunakan sama pada seluruh kondisi dalam satu *benchmark*, perbandingan dilakukan berdasarkan pasangan hasil pada soal yang sama. Untuk dua kondisi c_1 dan c_2, pasangan pengamatan ke-i dituliskan sebagai

$$\left(Y_{ic_1}, Y_{ic_2}\right), \qquad i = 1, \ldots, N. \tag{3.148}$$

Pendekatan berpasangan digunakan agar perbedaan tingkat kesulitan antarsoal tidak diperlakukan sebagai variasi antarperlakuan.

Uji McNemar eksak. Perbedaan akurasi antara dua kondisi dianalisis menggunakan uji McNemar eksak. Untuk setiap pasangan kondisi, banyaknya soal diklasifikasikan menjadi empat kategori a, b, c, d, dengan b dan c menunjukkan hasil yang berbeda antara kedua kondisi. Di bawah hipotesis nol

$$H_0 : \pi_b = \pi_c, \tag{3.149}$$

jumlah pasangan diskordan $b + c$ digunakan sebagai ukuran sampel pada distribusi binomial dengan probabilitas $1/2$. Nilai-p diperoleh secara eksak dari distribusi tersebut. Pendekatan ini digunakan untuk menghindari ketergantungan pada aproksimasi χ^2 ketika jumlah pasangan diskordan relatif kecil.

***Bootstrap* berpasangan.** Untuk jumlah token dan waktu inferensi, ketidakpastian perbedaan antarkondisi diukur menggunakan *bootstrap* berpasangan. Untuk setiap soal didefinisikan selisih

$$D_i = X_{ic_1} - X_{ic_2}, \qquad i = 1, \ldots, N, \tag{3.150}$$

dengan X berupa jumlah token atau waktu inferensi. Indeks soal kemudian di-*resample* dengan pengembalian sehingga pasangan pengamatan tetap dipertahankan. Statistik selisih dihitung pada setiap sampel ulang dan interval kepercayaan 95% diperoleh dari persentil ke-$2{,}5$ dan ke-$97{,}5$ distribusi *bootstrap*. Prosedur ini mengikuti konsep *bootstrap* yang telah dijelaskan pada Bab **??**.

Koreksi perbandingan berganda. Pengujian dilakukan untuk beberapa pasangan kondisi dan *benchmark*. Oleh karena itu, nilai-p dari pengujian yang termasuk dalam satu kelompok perbandingan disesuaikan menggunakan koreksi perbandingan berganda sebelum interpretasi signifikansi dilakukan. Hasil analisis dilaporkan bersama estimasi perbedaan dan interval kepercayaannya sehingga keputusan tidak hanya didasarkan pada nilai-p.

3.6.3. Benchmark dan Metrik Evaluasi

Kemampuan model bahasa pada tugas bernalar diukur lewat tolok ukur (*benchmark*) baku: kumpulan soal beserta cara penilaian jawabannya yang telah distandardisasi agar hasil dapat dibandingkan antarpenelitian. Berikut tiga tolok ukur yang merentang jenis keluaran yang dituntut, dari bilangan tunggal hingga kode program yang harus dieksekusi.

GSM8K [Cobbe dkk, 2021] berisi soal cerita matematika tingkat sekolah dasar–menengah yang memerlukan beberapa langkah penalaran aritmetika berurutan; jawaban akhir berupa satu bilangan.

ARC-Challenge [Clark dkk, 2018] (*AI2 Reasoning Challenge*) berisi soal sains pilihan ganda yang dipilih karena tidak terjawab benar oleh pencocokan kata kunci sederhana, sehingga menuntut penalaran; jawaban berupa satu simbol pilihan.

HumanEval-Plus [Chen dkk, 2021, Liu dkk, 2023] berisi soal pemrograman berupa tanda tangan fungsi beserta deskripsi tugasnya; jawaban berupa kode program yang harus lolos serangkaian kasus uji unit. Akhiran "Plus" menyatakan perluasan kasus uji oleh Liu dkk [2023] yang menutup celah himpunan uji asli [Chen dkk, 2021], sehingga solusi yang tampak benar namun keliru pada kasus tepi lebih mungkin terdeteksi.

Ketiga tolok ukur di atas dinilai dengan metrik berikut.

Definisi 3.6.1 *Untuk N soal dengan hasil benar/salah, akurasi adalah proporsi jawaban benar,*

$$\textit{akurasi} = \frac{1}{N}\left|\{\, i : \textit{jawaban ke-}i\ \textit{benar}\,\}\right|. \tag{3.151}$$

Definisi 3.6.2 (Chen dkk, 2021) *Untuk satu soal pemrograman, dibangkitkan $n \geq k$ sampel kode, dan $c \leq n$ di antaranya lolos seluruh kasus uji. Pass@k adalah peluang paling sedikit satu dari k sampel yang dipilih acak (tanpa pengembalian)*

dari n sampel tersebut lolos, diestimasi tak bias lewat

$$\textit{pass@}k = \mathop{\mathbb{E}}_{\textit{soal}}\left[1 - \frac{\binom{n-c}{k}}{\binom{n}{k}}\right]. \tag{3.152}$$

Definisi 3.6.3 *Format rate adalah proporsi keluaran model yang mengikuti format yang diminta (misalnya dapat diurai menjadi jawaban akhir atau kode yang sintaksisnya sahih), terlepas dari benar-salahnya isi jawaban. Metrik ini memisahkan kegagalan mengikuti format keluaran dari kegagalan substansi jawaban.*

Definisi 3.6.4 *Biaya komputasi suatu metode diukur lewat banyaknya token yang diproses (masukan dan keluaran) dan/atau waktu inferensi (wall-clock time) per soal — proksi baku untuk membandingkan efisiensi antarmetode, karena tidak bergantung pada perangkat keras tertentu (peluang token) atau langsung mencerminkan waktu tunggu pengguna (waktu inferensi).*

3.6.4. Pengukuran Geometris

Pengukuran geometris digunakan untuk mengetahui posisi representasi langkah laten yang dihasilkan oleh setiap formulasi relatif terhadap ruang representasi token yang tersedia bagi model.

Objek Representasi

Keempat formulasi langkah laten menggunakan *hidden state* yang sama sebagai sumber informasi. Untuk suatu *hidden state* h, persamaan mode menghasilkan representasi laten

$$z^{\mathrm{mode}} = \Phi_{\mathrm{mode}}(h), \qquad \mathrm{mode} \in \{\mathrm{raw}, \mathrm{soft}, \mathrm{sample}, \mathrm{moi}\}. \tag{3.153}$$

Dalam eksperimen, representasi tersebut telah dinormalisasi menggunakan norma target τ, sehingga

$$z^{\mathrm{mode}} = \tau \frac{\widetilde{z}^{\mathrm{mode}}}{\left\|\widetilde{z}^{\mathrm{mode}}\right\|_2}, \qquad \left\|z^{\mathrm{mode}}\right\|_2 = \tau. \tag{3.154}$$

Normalisasi ini yang memungkinkan perbandingan antarmetode difokuskan pada arah representasi. Dengan norma yang sama, perbedaan panjang vektor tidak menjadi sumber perbedaan pada ukuran geometris yang digunakan.

Ruang Pembanding

Representasi laten dibandingkan dengan ruang *input embedding* model. Misalkan ukuran kosakata adalah V dan dimensi representasi adalah d. Matriks *input embedding* dituliskan sebagai

$$W_{\mathrm{in}} = \begin{bmatrix} W_{\mathrm{in}}[1]^{\mathsf{T}} \\ W_{\mathrm{in}}[2]^{\mathsf{T}} \\ \vdots \\ W_{\mathrm{in}}[V]^{\mathsf{T}} \end{bmatrix} \in \mathbb{R}^{V \times d}, \tag{3.155}$$

dengan

$$W_{\mathrm{in}}[i] \in \mathbb{R}^d \tag{3.156}$$

merupakan vektor *embedding* untuk token ke-i.

Ruang pembanding tersebut dipilih karena z^{mode} digunakan kembali sebagai representasi masukan pada langkah laten berikutnya. Dengan demikian, pertanyaan geometris yang diuji adalah seberapa dekat representasi laten tersebut dengan representasi token yang memang dapat diterima oleh model.

Hal ini berbeda dari membandingkan dengan W_{out}. Matriks W_{out} digunakan untuk memetakan *hidden state* menjadi *logit*, sedangkan W_{in} merupakan ruang tempat vektor representasi token diberikan kepada model. Karena W_{in} dan W_{out} tidak diikat pada model yang digunakan, keduanya tidak diasumsikan sebagai ruang geometris yang sama.

Kemiripan Kosinus

Kedekatan antara dua vektor diukur menggunakan kemiripan kosinus. Untuk dua vektor tidak nol $u, v \in \mathbb{R}^d$, kemiripan kosinus didefinisikan sebagai

$$\cos(u, v) = \frac{u^\mathsf{T} v}{\|u\|_2 \|v\|_2}. \tag{3.157}$$

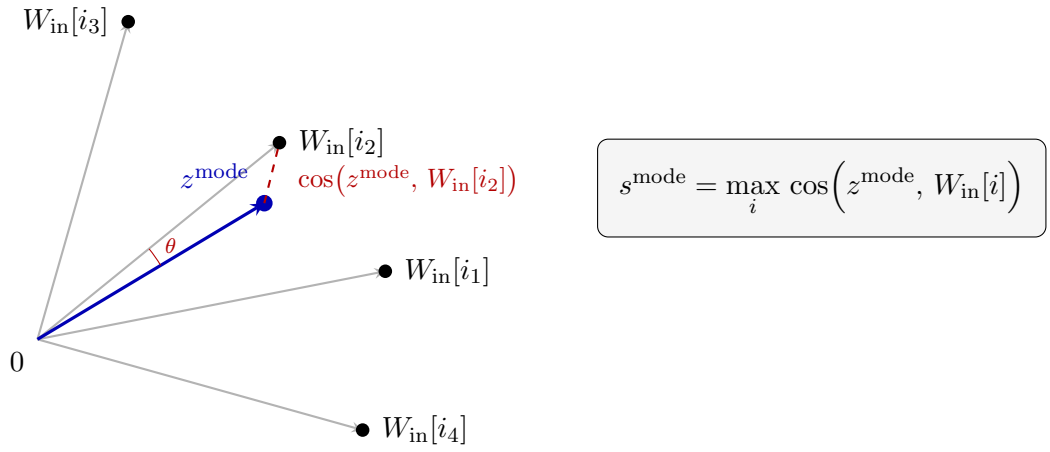
Persamaan (3.157) membandingkan arah kedua vektor. Secara khusus, apabila

$$u^\mathsf{T} v = \|u\|_2 \|v\|_2, \tag{3.158}$$

maka

$$\cos(u, v) = 1, \tag{3.159}$$

yang menunjukkan bahwa kedua vektor memiliki arah yang sama. Sebaliknya, nilai yang semakin kecil menunjukkan bahwa arah kedua vektor semakin berbeda.



Gambar 3.11 Ilustrasi konseptual pengukuran geometris. Vektor z^{mode} dibandingkan dengan seluruh vektor *input embedding* $W_{\text{in}}[i]$, kemudian kemiripan kosinus terbesar digunakan sebagai ukuran kedekatan geometris.

Untuk sebuah representasi laten z^{mode}, kemiripan terhadap seluruh kosakata

dihitung dengan

$$s_i^{\text{mode}} = \cos\left(z^{\text{mode}}, W_{\text{in}}[i]\right), \qquad i = 1, \ldots, V. \tag{3.160}$$

Karena tujuan pengukuran adalah mengetahui apakah terdapat setidaknya satu *embedding* token yang memiliki arah dekat dengan representasi laten, nilai maksimum digunakan sebagai ukuran kedekatan geometris,

$$s^{\text{mode}} = \max_{1 \le i \le V} \cos\left(z^{\text{mode}}, W_{\text{in}}[i]\right). \tag{3.161}$$

Persamaan (3.161) tidak menyatakan bahwa token dengan kemiripan maksimum tersebut merupakan token yang benar atau token yang kemudian dihasilkan model. Ukuran tersebut hanya menyatakan apakah terdapat arah pada ruang *embedding* token yang dekat dengan representasi laten.

Nilai s^{mode} yang semakin mendekati 1 menunjukkan bahwa representasi laten semakin dekat secara arah dengan setidaknya satu *embedding* token. Sebaliknya, nilai yang lebih rendah menunjukkan bahwa representasi tersebut lebih jauh dari seluruh arah *embedding* token.

Agregasi Pengukuran

Satu soal menghasilkan beberapa representasi laten karena setiap agen dapat menjalankan beberapa langkah laten. Oleh karena itu, nilai s^{mode} pada Persamaan (3.161) terlebih dahulu dihitung pada setiap langkah laten.

Misalkan q menyatakan indeks soal, a indeks agen, dan k indeks langkah laten. Kedekatan geometris pada satu posisi representasi didefinisikan sebagai

$$s_{qak}^{\text{mode}} = \max_{1 \le i \le V} \cos\left(z_{qak}^{\text{mode}}, W_{\text{in}}[i]\right). \tag{3.162}$$

Untuk memperoleh satu ukuran geometris pada tingkat agen dan soal, nilai tersebut dirata-ratakan sepanjang langkah laten yang benar-benar dihasilkan. Jika K_{qa}^{mode} adalah jumlah langkah laten pada agen a untuk soal q, maka

$$\bar{s}_{qa}^{\text{mode}} = \frac{1}{K_{qa}^{\text{mode}}} \sum_{k=1}^{K_{qa}^{\text{mode}}} s_{qak}^{\text{mode}}. \tag{3.163}$$

Agregasi selanjutnya dilakukan pada tingkat agen. Dengan A menyatakan jumlah agen dalam rantai,

$$\bar{s}_{q}^{\text{mode}} = \frac{1}{A} \sum_{a=1}^{A} \bar{s}_{qa}^{\text{mode}}. \tag{3.164}$$

Nilai $\bar{s}_{q}^{\text{mode}}$ kemudian menjadi ukuran geometris pada tingkat soal. Untuk N soal, ukuran agregat suatu persamaan dihitung sebagai

$$\overline{s}^{\text{mode}} = \frac{1}{N} \sum_{q=1}^{N} \bar{s}_{q}^{\text{mode}}. \tag{3.165}$$

Dengan struktur tersebut, agregasi dilakukan secara bertahap,

$$s_{qak}^{\text{mode}} \longrightarrow \bar{s}_{qa}^{\text{mode}} \longrightarrow \bar{s}_{q}^{\text{mode}} \longrightarrow \overline{s}^{\text{mode}}. \tag{3.166}$$

Urutan tersebut mempertahankan unit soal sebagai unit observasi pada analisis selanjutnya. Hal ini memungkinkan ukuran geometris dibandingkan dengan hasil keluaran pada soal yang sama.

Hubungan dengan Keluaran

Ukuran geometris digunakan sebagai variabel representasi, sedangkan keluaran tugas digunakan sebagai ukuran kinerja. Untuk soal ke-q, keberhasilan keluaran dituliskan sebagai variabel indikator

$$Y_{q}^{\text{mode}} = \mathbb{1}\left[\text{keluaran ke-}q\text{ benar}\right]. \tag{3.167}$$

Dengan demikian, setiap soal memiliki pasangan

$$\left(\bar{s}_{q}^{\text{mode}}, Y_{q}^{\text{mode}}\right), \qquad q = 1, \ldots, N. \tag{3.168}$$

Pasangan tersebut digunakan untuk melihat apakah perubahan karakteristik geometris muncul bersamaan dengan perubahan pada keluaran. Pada tingkat agregat, akurasi tetap dihitung dari

$$A^{\mathrm{mode}} = \frac{1}{N}\sum_{q=1}^{N} Y_q^{\mathrm{mode}}, \tag{3.169}$$

sedangkan karakteristik geometris diringkas melalui

$$\overline{s}^{\mathrm{mode}} = \frac{1}{N}\sum_{q=1}^{N} \bar{s}_q^{\mathrm{mode}}. \tag{3.170}$$

Perbandingan A^{mode} dan $\overline{s}^{\mathrm{mode}}$ digunakan sebagai analisis deskriptif untuk melihat apakah formulasi dengan karakteristik geometris yang berbeda juga menunjukkan pola kinerja yang berbeda. Hubungan tersebut tidak dimaksudkan sebagai hubungan sebab-akibat. Kedekatan geometris hanya memberikan bukti mengenai karakteristik representasi yang dapat digunakan untuk membantu menjelaskan perbedaan keluaran.

3.6.5. Interpolasi Geometris

Pengukuran geometris pada Subbab 3.6.4. memberikan ukuran kedekatan masing-masing representasi laten terhadap ruang *embedding* masukan. Namun, perbandingan antara dua persamaan hanya memberikan informasi pada dua titik representasi. Untuk mengamati perubahan kinerja sepanjang perpindahan dari formulasi *raw* menuju formulasi *soft*, digunakan interpolasi geometris.

Interpolasi dilakukan pada keluaran akhir kedua formulasi, yaitu $\Phi_{\mathtt{raw}}(h)$ dan $\Phi_{\mathtt{soft}}(h)$. Kedua vektor tersebut telah dinormalisasi menggunakan norma yang sama τ sebagaimana pada Pers. (3.154). Untuk $\alpha \in [0, 1]$, mula-mula dibentuk vektor campuran

$$u_\alpha = (1-\alpha)\Phi_{\mathtt{raw}}(h) + \alpha\Phi_{\mathtt{soft}}(h). \tag{3.171}$$

Vektor campuran tersebut kemudian dinormalisasi kembali ke norma τ,

$$\boxed{\Phi^{(\alpha)}_{\text{mix}}(h) = \tau \frac{u_\alpha}{\|u_\alpha\|}} \qquad u_\alpha \neq \mathbf{0}. \tag{3.172}$$

Pers. (3.171) menentukan arah pencampuran antara kedua representasi, sedangkan Pers. (3.172) memastikan bahwa representasi yang digunakan pada setiap nilai α memiliki magnitudo yang sama. Dengan demikian,

$$\left\| \Phi^{(\alpha)}_{\text{mix}}(h) \right\| = \tau, \qquad \forall \alpha \in [0, 1]. \tag{3.173}$$

Pilihan ini membuat perubahan representasi sepanjang interpolasi dapat dipandang terutama sebagai perubahan arah pada ruang laten.

Titik ujung interpolasi. Konstruksi pada Pers. (3.172) mempertahankan kedua formulasi asal secara tepat pada titik ujung $\alpha = 0$ dan $\alpha = 1$. Untuk $\alpha = 0$, diperoleh

$$\begin{aligned} u_0 &= (1-0)\Phi_{\texttt{raw}}(h) + 0\Phi_{\texttt{soft}}(h) \\ &= \Phi_{\texttt{raw}}(h). \end{aligned} \tag{3.174}$$

Karena $\|\Phi_{\texttt{raw}}(h)\| = \tau$, maka

$$\begin{aligned} \Phi^{(0)}_{\text{mix}}(h) &= \tau \frac{\Phi_{\texttt{raw}}(h)}{\|\Phi_{\texttt{raw}}(h)\|} \\ &= \tau \frac{\Phi_{\texttt{raw}}(h)}{\tau} \\ &= \Phi_{\texttt{raw}}(h). \end{aligned} \tag{3.175}$$

Dengan cara yang sama, untuk $\alpha = 1$,

$$u_1 = \Phi_{\texttt{soft}}(h), \tag{3.176}$$

$$\begin{aligned}\Phi^{(1)}_{\text{mix}}(h) &= \tau \frac{\Phi_{\texttt{soft}}(h)}{\|\Phi_{\texttt{soft}}(h)\|} \\ &= \Phi_{\texttt{soft}}(h).\end{aligned} \tag{3.177}$$

Dengan demikian,

$$\boxed{\Phi^{(0)}_{\text{mix}}(h) = \Phi_{\texttt{raw}}(h), \qquad \Phi^{(1)}_{\text{mix}}(h) = \Phi_{\texttt{soft}}(h)}. \tag{3.178}$$

Pers. (3.178) menunjukkan bahwa interpolasi tidak menghasilkan perubahan pada kedua kondisi pembatas. Kondisi $\alpha = 0$ identik dengan formulasi *raw*, sedangkan $\alpha = 1$ identik dengan formulasi *soft*. Oleh karena itu, kedua titik ujung dapat menggunakan hasil eksperimen yang telah diperoleh sebelumnya.

Lintasan geometris. Selanjutnya, misalkan

$$a = \Phi_{\texttt{raw}}(h), \qquad b = \Phi_{\texttt{soft}}(h), \qquad \|a\| = \|b\| = \tau. \tag{3.179}$$

Sebelum normalisasi, u_α merupakan kombinasi linear dari a dan b. Oleh karena itu,

$$u_\alpha = (1-\alpha)a + \alpha b \in \operatorname{span}\{a, b\}. \tag{3.180}$$

Ketika u_α dinormalisasi ke norma τ, setiap titik pada ruas garis yang menghubungkan a dan b diproyeksikan kembali ke bola berjari-jari τ. Karena seluruh ruas tersebut berada pada bidang yang dibentuk oleh a dan b, lintasan hasil normalisasi berada pada irisan bidang tersebut dengan bola, yaitu suatu lingkaran besar (*great circle*).

Dengan demikian, untuk $u_\alpha \neq \mathbf{0}$,

$$\Phi_{\text{mix}}^{(\alpha)}(h) \in \left\{ z \in \mathbb{R}^d : \|z\| = \tau \right\}, \tag{3.181}$$

dan lintasan $\alpha \mapsto \Phi_{\text{mix}}^{(\alpha)}(h)$ bergerak dari $\Phi_{\texttt{raw}}(h)$ menuju $\Phi_{\texttt{soft}}(h)$ pada bola tersebut.

Kasus $u_\alpha = \mathbf{0}$ hanya dapat terjadi ketika kedua vektor berlawanan arah. Karena $\|a\| = \|b\| = \tau$, kondisi tersebut mensyaratkan

$$b = -a, \qquad \alpha = \frac{1}{2}, \tag{3.182}$$

yang ekuivalen dengan

$$\cos(a, b) = -1. \tag{3.183}$$

Pada kondisi tersebut normalisasi pada Pers. (3.172) tidak terdefinisi. Oleh karena itu, interpolasi hanya didefinisikan untuk nilai α yang menghasilkan $u_\alpha \neq \mathbf{0}$.

Hubungan α dengan perpindahan sudut. Parameter α menentukan bobot pencampuran, tetapi tidak secara langsung menentukan jarak geometris pada bola. Untuk melihat hubungan tersebut, misalkan θ adalah sudut antara a dan b,

$$\theta = \arccos\left(\frac{a^\top b}{\|a\|\|b\|} \right). \tag{3.184}$$

Definisikan vektor satuan

$$\hat{a} = \frac{a}{\tau}, \tag{3.185}$$

serta $\hat{n}$ sebagai vektor satuan yang berada pada $\text{span}\{a, b\}$ dan tegak lurus terhadap $\hat{a}$. Dengan demikian, b dapat dituliskan sebagai

$$b = \tau \left(\cos\theta\, \hat{a} + \sin\theta\, \hat{n} \right). \tag{3.186}$$

Substitusi Pers. (3.186) ke Pers. (3.171) menghasilkan

$$\begin{aligned} u_\alpha &= (1-\alpha)\tau\hat{a} + \alpha\tau\left(\cos\theta\,\hat{a} + \sin\theta\,\hat{n}\right) \\ &= \tau\left[\left((1-\alpha) + \alpha\cos\theta\right)\hat{a} + \alpha\sin\theta\,\hat{n}\right]. \end{aligned} \tag{3.187}$$

Jika $\varphi(\alpha)$ menyatakan sudut antara a dan $\Phi^{(\alpha)}_{\text{mix}}(h)$, maka dari komponen yang sejajar dan tegak lurus terhadap $\hat{a}$ diperoleh

$$\boxed{\tan\varphi(\alpha) = \frac{\alpha\sin\theta}{(1-\alpha) + \alpha\cos\theta}}. \tag{3.188}$$

Pers. (3.188) menunjukkan bahwa perubahan α tidak secara umum menghasilkan perubahan sudut yang linear. Sebagai contoh, pada $\alpha = \frac{1}{2}$,

$$\begin{aligned} \tan\varphi\left(\frac{1}{2}\right) &= \frac{\frac{1}{2}\sin\theta}{\frac{1}{2} + \frac{1}{2}\cos\theta} \\ &= \frac{\sin\theta}{1+\cos\theta} \\ &= \tan\frac{\theta}{2}. \end{aligned} \tag{3.189}$$

Sehingga

$$\varphi\left(\frac{1}{2}\right) = \frac{\theta}{2}. \tag{3.190}$$

Hasil tersebut menunjukkan bahwa titik tengah pencampuran setelah normalisasi berada pada titik tengah busur antara kedua representasi. Namun, di luar titik tengah tersebut, jarak sudut tidak berubah secara linear terhadap α. Oleh karena itu, α diperlakukan sebagai parameter pencampuran, bukan sebagai ukuran jarak geometris.

Kisi interpolasi. Eksperimen interpolasi menggunakan kisi

$$\boxed{\alpha \in \{0,\ 0{,}25,\ 0{,}50,\ 0{,}75,\ 1\}.} \tag{3.191}$$

Nilai $\alpha = 0$ dan $\alpha = 1$ masing-masing merepresentasikan formulasi *raw* dan *soft* berdasarkan Pers. (3.178). Dengan demikian, hanya tiga nilai tengah yang memerlukan kondisi eksperimen tambahan.

Kisi tersebut memberikan tiga titik di antara kedua formulasi, yaitu $\alpha = 0{,}25$, $\alpha = 0{,}50$, dan $\alpha = 0{,}75$. Ketiga titik tersebut digunakan untuk mengamati bentuk perubahan kinerja sepanjang lintasan, bukan hanya perbedaan pada kedua titik ujung.

Interpolasi dijalankan pada HumanEval+ dengan menggunakan pertanyaan yang sama seperti eksperimen utama. Pemilihan ini mengikuti rancangan eksperimen yang menggunakan interpolasi sebagai analisis tambahan pada kondisi dengan perbedaan kinerja antara *raw* dan formulasi berbasis token yang lebih jelas.

Pengukuran posisi geometris sepanjang interpolasi. Karena α merupakan bobot pencampuran dan bukan ukuran jarak geometris, posisi representasi sepanjang lintasan diukur kembali menggunakan ukuran geometris pada Subbab 3.6.4.. Untuk setiap α, didefinisikan

$$s(\alpha) = \max_{1 \le i \le V} \cos\left(\Phi_{\text{mix}}^{(\alpha)}(h), W_{\text{in}}[i]\right). \tag{3.192}$$

Dengan demikian, terdapat dua besaran yang berbeda. Parameter α menentukan bagaimana representasi *raw* dan *soft* dicampurkan, sedangkan $s(\alpha)$ mengukur posisi representasi hasil pencampuran relatif terhadap ruang *embedding* token.

Hubungan keduanya kemudian dapat digunakan untuk membandingkan perubahan keluaran model dengan perubahan posisi geometris. Secara khusus, untuk setiap nilai α dicatat keluaran model dan ukuran geometris $s(\alpha)$, sehingga pasangan pengamatan dapat dituliskan sebagai

$$\left(s(\alpha), Y^{(\alpha)}\right), \tag{3.193}$$

dengan $Y^{(\alpha)}$ menyatakan indikator keberhasilan keluaran pada nilai α tersebut. Analisis ini digunakan untuk mengamati apakah perubahan kinerja berjalan searah dengan perubahan kedekatan representasi terhadap ruang *embedding* token.

BAB IV

HASIL DAN PEMBAHASAN

4.1. Deskripsi Data dan Lingkungan Eksperimental

Eksperimen dilakukan untuk membandingkan metode representasi langkah laten dan medium komunikasi pada *Multi-Agent System* (MAS). Seluruh eksperimen menggunakan model *open-weight* Qwen3-8B sebagai *backbone*, dengan $L = 36$ lapisan *Transformer decoder-only* dan dimensi *hidden state* $d = 4096$. Model menggunakan *grouped-query attention* (GQA) dengan delapan *key-value heads* serta *untied embedding*. Konfigurasi model tersebut dijaga tetap pada seluruh kondisi eksperimen.

Rancangan eksperimen menggunakan empat agen yang dijalankan secara sekuensial, yaitu *planner*, *critic*, *refiner*, dan *judger*. Pada medium *KV-cache*, informasi internal diteruskan melalui *KV-cache*, sedangkan pada medium teks informasi diteruskan dalam bentuk keluaran tekstual. Kondisi laten menggunakan hingga $m = 10$ langkah laten dengan persamaan Φ yang sesuai.

Eksperimen utama dilaksanakan pada 10 Agustus 2026 menggunakan tiga *benchmark*, yaitu GSM8K, ARC-Challenge, dan HumanEval+. GSM8K digunakan untuk penalaran matematika, ARC-Challenge untuk tugas pilihan ganda, dan HumanEval+ untuk menghasilkan program Python. Data dan tugas yang digunakan disajikan pada Tabel 4.1.

Tabel 4.1 Data dan tugas yang digunakan dalam eksperimen utama.

Tugas	Keluarga	Sumber	*Split*
GSM8K	Matematika	`openai/gsm8k`	`test`
ARC-C	Pilihan ganda	`allenai/ai2_arc`	`test`
HumanEval+	Kode	`evalplus/humanevalplus`	`test`

Pada ARC-Challenge, label jawaban dikonversikan menjadi huruf a hing-

ga d. Pada HumanEval+, keluaran program Python dievaluasi menggunakan *test harness* sesuai dengan *entry point* pada masing-masing soal.

Perlakuan utama terdiri atas empat metode langkah laten pada medium *KV-cache*, yaitu `raw`, `soft`, `sample`, dan `moi`. Medium teks (`text`) digunakan sebagai kondisi pembanding. Matriks perlakuan utama ditunjukkan pada Tabel 4.2.

Tabel 4.2 Matriks perlakuan utama pada tiga *benchmark*.

Perlakuan	Medium	persamaan Φ	GSM8K	ARC-C	HumanEval+
`raw`	`kv`	`raw`	✓	✓	✓
`soft`	`kv`	`soft`	✓	✓	✓
`sample`	`kv`	`sample`	✓	✓	✓
`moi`	`kv`	`moi`	✓	✓	✓
`text`	`text`	—	✓	✓	✓

Parameter yang tidak menjadi objek variasi dijaga tetap selama eksperimen. Ringkasan konfigurasi tersebut disajikan pada Tabel 4.3.

Tabel 4.3 Konfigurasi tetap eksperimen utama.

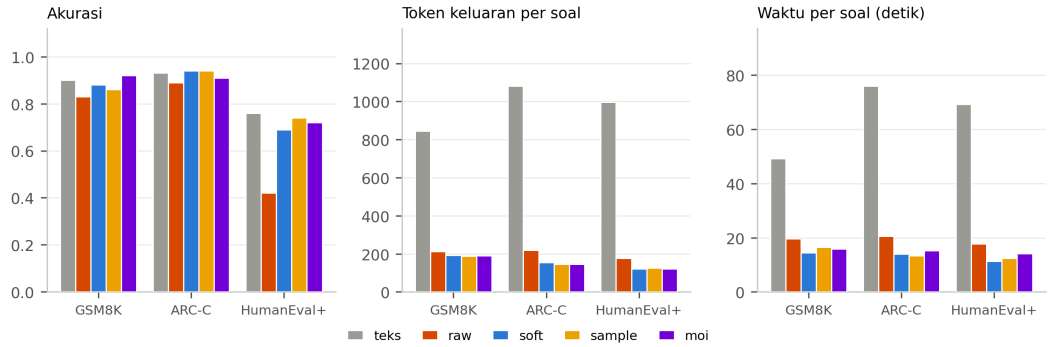
Komponen	Nilai
Backbone	Qwen3-8B
Rantai agen	*planner* $\rightarrow$ *critic* $\rightarrow$ *refiner* $\rightarrow$ *judger*
Jumlah langkah laten	$m = 10$
Suhu langkah laten	$T = 0{,}7$
Parameter MoI	$\beta = 1$
Kriteria *early stopping*	$\cos(h_{k+1}, h_k) > 0{,}999$
Suhu menghasilkan teks	$T_{\text{gen}} = 0{,}6$
Top-p	$0{,}95$
Maksimum token keluaran	2048
Batas konteks medium `text`	8000 karakter

Dengan demikian, terdapat 15 sel eksperimen, yaitu lima kondisi perlakuan pada tiga *benchmark*, dengan 100 soal pada setiap sel. Seluruh kondisi dalam

benchmark yang sama menggunakan himpunan soal identik. Ukuran yang dicatat untuk setiap soal meliputi akurasi, *format rate*, jumlah token keluaran, dan waktu eksekusi.

4.2. Akurasi dan Keandalan Format

Evaluasi awal dilakukan untuk membandingkan akurasi dan *correct format rate* pada medium teks dan medium *KV-cache*. Hasil perbandingan disajikan pada Gambar 4.1 dan Tabel 4.4.



Gambar 4.1 Perbandingan akurasi, jumlah token keluaran per soal, dan waktu inferensi per soal pada tiga *benchmark*.

Gambar 4.1 menunjukkan bahwa akurasi metode *KV-cache* berada pada tingkat yang relatif dekat dengan medium teks pada ketiga *benchmark*. Pada GSM8K, medium teks menghasilkan akurasi sebesar $0{,}90$, sedangkan `soft`, `sample`, dan `moi` masing-masing menghasilkan $0{,}88$, $0{,}86$, dan $0{,}92$. Pada ARC-Challenge, akurasi medium teks sebesar $0{,}93$, sementara `soft` dan `sample` mencapai $0{,}94$ dan `moi` mencapai $0{,}91$. Hasil tersebut menunjukkan bahwa penggunaan medium *KV-cache* tidak secara umum diikuti oleh penurunan akurasi yang besar.

Perbedaan lebih terlihat pada HumanEval+, di mana akurasi medium teks sebesar $0{,}76$, sedangkan `soft`, `sample`, dan `moi` masing-masing menghasilkan $0{,}69$, $0{,}74$, dan $0{,}72$. Dengan demikian, penurunan akurasi juga terjadi pada metode laten lainnya, tetapi `raw` menunjukkan penurunan yang lebih besar dengan akurasi sebesar $0{,}42$.

Selain akurasi, *correct format rate* digunakan untuk melihat keterpenuhan

format keluaran yang diperlukan dalam proses evaluasi. Hasilnya disajikan pada Tabel 4.4.

Tabel 4.4 Akurasi dan *correct format rate* pada masing-masing *benchmark*.

Tolok ukur	Ukuran	Teks	`raw`	`soft`	`sample`	`moi`
GSM8K	Akurasi	0,90	0,83	0,88	0,86	**0,92**
	correct format rate	1,00	0,98	1,00	0,97	1,00
ARC-C	Akurasi	0,93	0,89	**0,94**	**0,94**	0,91
	correct format rate	1,00	1,00	1,00	1,00	0,98
HumanEval+	Akurasi	0,76	0,42	0,69	**0,74**	0,72
	correct format rate	1,00	1,00	0,96	1,00	1,00

Berdasarkan Tabel 4.4, *correct format rate* berada pada tingkat tinggi pada seluruh kondisi, dengan nilai antara $0{,}96$ dan $1{,}00$. Hal ini menunjukkan bahwa perbedaan akurasi yang diamati tidak secara umum disertai oleh kegagalan dalam memenuhi format keluaran. Pada HumanEval+, misalnya, `raw` tetap memiliki *correct format rate* sebesar $1{,}00$ meskipun akurasinya hanya sebesar $0{,}42$.

4.3. Biaya Token dan Waktu Inferensi

Selain mempertahankan akurasi, penggunaan medium *KV-cache* juga ditinjau dari biaya inferensinya. Jumlah token keluaran digunakan untuk menggambarkan banyaknya keluaran tekstual yang dihasilkan selama proses komunikasi, sedangkan waktu per soal menunjukkan durasi yang diperlukan hingga suatu soal selesai diproses. Perbandingan kedua ukuran tersebut ditunjukkan pada Gambar 4.1 dan Tabel 4.5.

Tabel 4.5 Jumlah token keluaran dan waktu inferensi per soal.

Tolok ukur	Ukuran	Teks	`raw`	`soft`	`sample`	`moi`
GSM8K	Token/soal	844,7	211,5	192,3	187,4	189,8
	Detik/soal	49,2	19,7	14,5	16,5	15,9
ARC-C	Token/soal	1081,0	219,4	154,1	145,8	145,0
	Detik/soal	76,0	20,6	14,0	13,3	15,3
HumanEval+	Token/soal	997,2	176,8	121,5	126,0	121,6
	Detik/soal	69,3	17,8	11,4	12,4	14,1

Berdasarkan Tabel 4.5, medium *KV-cache* menghasilkan jumlah token keluaran yang lebih rendah dibandingkan medium teks pada seluruh *benchmark*. Pada GSM8K, misalnya, jumlah token per soal turun dari $844{,}7$ pada medium teks menjadi sekitar $187{,}4$–$211{,}5$ token pada medium *KV-cache*. Pola serupa terlihat pada ARC-Challenge dan HumanEval+, dengan seluruh metode *KV-cache* menghasilkan keluaran yang lebih sedikit dibandingkan medium teks.

Pengurangan jumlah token tersebut diikuti oleh penurunan waktu inferensi. Pada GSM8K, waktu per soal berkurang dari $49{,}2$ detik pada medium teks menjadi $14{,}5$–$19{,}7$ detik pada medium *KV-cache*. Pada ARC-Challenge dan HumanEval+, pola yang sama juga terlihat, yaitu seluruh metode *KV-cache* memerlukan waktu inferensi yang lebih rendah daripada medium teks.

Pola tersebut menunjukkan bahwa perbedaan biaya inferensi terutama terlihat pada tingkat medium komunikasi. Medium teks memerlukan pembuatan keluaran tekstual yang lebih banyak, sedangkan *KV-cache* memungkinkan informasi antaragen diteruskan tanpa seluruh informasi tersebut dibangkitkan kembali dalam bentuk teks. Meskipun terdapat perbedaan biaya di antara metode *KV-cache*, perbedaan tersebut relatif lebih kecil dibandingkan perbedaan antara medium *KV-cache* dan medium teks.

4.4. Efisiensi Medium KV terhadap Medium Teks

Perbandingan selanjutnya dilakukan untuk mengukur efisiensi medium *KV-cache* relatif terhadap medium teks. Efisiensi dinilai berdasarkan penghematan jumlah *token* keluaran dan percepatan waktu inferensi. Kedua ukuran dihitung terhadap kondisi teks pada *benchmark* yang sama. Hasil perbandingan disajikan pada Tabel 4.6 dan Gambar 4.2.

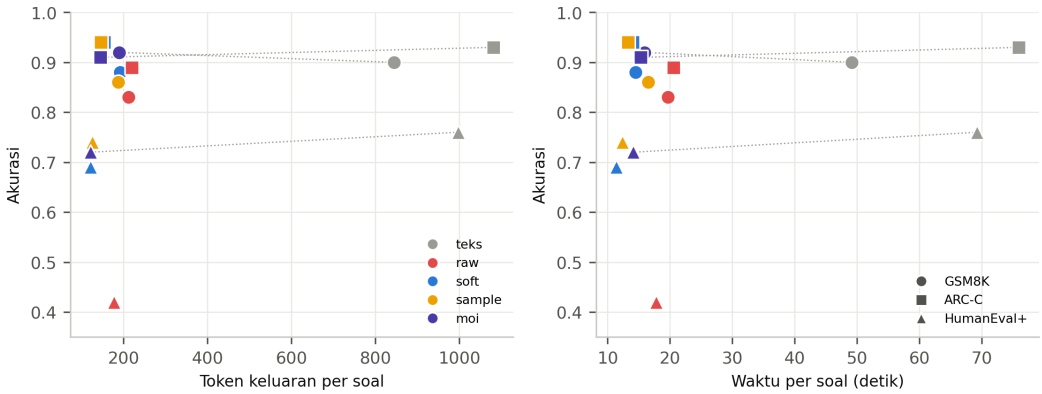
Tabel 4.6 Efisiensi medium *KV-cache* relatif terhadap medium teks.

Tolok ukur	Langkah laten	Akurasi	Penghematan *token*	Percepatan
GSM8K	`raw`	0,83	75,0%	$\times 2,5$
	`soft`	0,88	77,2%	$\times 3,4$
	`sample`	0,86	77,8%	$\times 3,0$
	`moi`	0,92	77,5%	$\times 3,1$
ARC-C	`raw`	0,89	79,7%	$\times 3,7$
	`soft`	0,94	85,7%	$\times 5,4$
	`sample`	0,94	86,5%	$\times 5,7$
	`moi`	0,91	86,6%	$\times 5,0$
HumanEval+	`raw`	0,42	82,3%	$\times 3,9$
	`soft`	0,69	87,8%	$\times 6,1$
	`sample`	0,74	87,4%	$\times 5,6$
	`moi`	0,72	87,8%	$\times 4,9$

Berdasarkan Tabel 4.6, seluruh metode *KV-cache* menghasilkan penghematan *token* dan percepatan waktu inferensi pada ketiga *benchmark*. Penghematan *token* berada pada rentang $75{,}0\%$–$87{,}8\%$, sedangkan percepatan berada pada rentang $\times 2{,}5$–$\times 6{,}1$. Dengan demikian, efisiensi medium *KV-cache* terlihat secara konsisten ketika dibandingkan dengan medium teks, meskipun besarnya penghematan berbeda menurut *benchmark* dan metode yang digunakan.

Gambar 4.2 memperlihatkan hubungan antara akurasi dengan jumlah *token* dan waktu inferensi. Pada kedua panel, kondisi teks berada pada wilayah dengan biaya inferensi yang lebih tinggi, sedangkan metode *KV-cache* berada pada wila-

yah dengan jumlah *token* dan waktu yang lebih rendah. Pola tersebut menunjukkan bahwa penggunaan *KV-cache* memberikan pengurangan biaya komunikasi sekaligus mempertahankan tingkat akurasi yang telah dibahas pada bagian sebelumnya.



Gambar 4.2 Hubungan akurasi dengan jumlah *token* keluaran per soal dan waktu inferensi per soal.

Efisiensi tersebut tidak sepenuhnya seragam pada seluruh metode. Pada HumanEval+, misalnya, `raw` memiliki akurasi $0{,}42$ meskipun menghasilkan penghematan *token* sebesar $82{,}3\%$ dan percepatan sebesar $\times 3{,}9$. Sementara itu, `moi` mencapai akurasi $0{,}72$ dengan penghematan *token* sebesar $87{,}8\%$ dan percepatan sebesar $\times 4{,}9$. Hal ini menunjukkan bahwa besarnya efisiensi perlu dibaca bersama dengan akurasi, karena pengurangan biaya inferensi tidak dengan sendirinya menunjukkan kesetaraan kinerja.

4.5. Perbandingan Berpasangan MoI terhadap metode lain

Setelah membandingkan efisiensi medium *KV-cache* terhadap medium teks, analisis selanjutnya dilakukan secara berpasangan untuk mengetahui apakah perbedaan akurasi `moi` terhadap kondisi acuan didukung oleh data pada tingkat soal. Perbandingan dilakukan menggunakan soal yang sama pada setiap pasangan kondisi. Oleh karena itu, setiap soal membentuk satu pasangan observasi yang memungkinkan perbedaan kinerja dihitung secara langsung.

Dalam analisis ini, `moi` dibandingkan dengan dua kondisi acuan, yaitu `raw` pada medium *KV-cache* dan medium teks. Besarnya perbedaan akurasi dinyatakan

sebagai Δ akurasi, sedangkan ketidakpastian estimasi ditunjukkan melalui selang kepercayaan (*SK*) 95%. Untuk mengetahui apakah terdapat bukti statistik mengenai perbedaan akurasi, digunakan uji McNemar eksak. Hasil perbandingan tersebut disajikan pada Tabel 4.7.

Tabel 4.7 Selisih akurasi berpasangan `moi` terhadap kondisi acuan.

Tolok ukur	Acuan	Δ akurasi	SK 95%
GSM8K	`raw` (KV)	+0,09	$[+0,01;\ +0,17]$
GSM8K	Teks	+0,02	$[-0,04;\ +0,08]$
ARC-C	`raw` (KV)	+0,02	$[-0,03;\ +0,07]$
ARC-C	Teks	-0,02	$[-0,07;\ +0,03]$
HumanEval+	`raw` (KV)	+0,30	$[+0,20;\ +0,40]$
HumanEval+	Teks	-0,04	$[-0,13;\ +0,05]$

Berdasarkan Tabel 4.7, perbedaan `moi` terhadap `raw` menunjukkan pola yang berbeda pada ketiga *benchmark*. Pada GSM8K, `moi` memiliki akurasi $0{,}09$ lebih tinggi daripada `raw`, dengan selang kepercayaan 95% sebesar $[+0{,}01;\ +0{,}17]$ dan nilai-p sebesar $0{,}0490$. Pada ARC-C, selisih tersebut lebih kecil, yaitu $+0{,}02$, dengan selang kepercayaan $[-0{,}03;\ +0{,}07]$ dan nilai-p sebesar $0{,}6875$. Perbedaan terbesar terlihat pada HumanEval+, dengan selisih akurasi sebesar $+0{,}30$, selang kepercayaan $[+0{,}20;\ +0{,}40]$, dan nilai-$p < 0{,}0001$.

Hasil tersebut menunjukkan bahwa keunggulan `moi` terhadap `raw` paling jelas pada HumanEval+. Pada GSM8K terdapat perbedaan positif yang relatif lebih kecil, sedangkan pada ARC-C selisihnya sangat kecil dan interval kepercayaannya mencakup nilai nol. Dengan demikian, perbedaan kinerja antara kedua metode tidak memiliki pola yang sama pada seluruh jenis tugas.

Perbandingan terhadap medium teks menunjukkan hasil yang berbeda. Pada GSM8K, `moi` memiliki akurasi $0{,}02$ lebih tinggi daripada teks, sedangkan pada ARC-C dan HumanEval+ masing-masing lebih rendah sebesar $0{,}02$ dan $0{,}04$. Ketiga selang kepercayaan masing-masing mencakup nilai nol, dengan nilai-p sebesar $0{,}7539$, $0{,}6875$, dan $0{,}5235$. Dengan demikian, berdasarkan pengujian berpasangan,

tidak terdapat bukti statistik yang cukup mengenai perbedaan akurasi antara `moi` dan medium teks pada ketiga *benchmark* tersebut.

Secara keseluruhan, hasil perbandingan menunjukkan bahwa `moi` mempertahankan akurasi yang tidak berbeda secara signifikan dari medium teks, sementara memberikan keunggulan yang lebih nyata dibandingkan `raw` pada HumanEval+. Hasil ini memperlihatkan bahwa metode `moi` tidak hanya perlu dinilai berdasarkan akurasi, tetapi juga berdasarkan mekanisme representasi informasi yang mendasari perbedaan kinerja tersebut.

4.6. Geometri Vektor Langkah Laten

Hasil pada Subbab 4.5. menunjukkan bahwa perbedaan kinerja `moi` terhadap `raw` lebih jelas pada HumanEval+ dibandingkan pada GSM8K dan ARC-C. Analisis selanjutnya digunakan untuk melihat apakah perbedaan tersebut disertai oleh perbedaan karakteristik geometris representasi langkah laten. Fokus analisis adalah kedekatan vektor langkah laten terhadap ruang *input embedding* token.

Kedekatan tersebut diukur menggunakan kemiripan kosinus maksimum antara vektor langkah laten dan seluruh vektor pada matriks *input embedding*, yaitu

$$s\big(\Phi(h)\big) = \max_i \cos\left(\Phi(h), W_{\text{in}}[i]\right), \tag{4.1}$$

di mana nilai yang semakin mendekati 1 menunjukkan bahwa terdapat vektor *embedding* token dengan arah yang semakin dekat terhadap vektor langkah laten. Oleh karena itu, nilai ini digunakan sebagai ukuran kedekatan geometris representasi laten terhadap ruang representasi token.

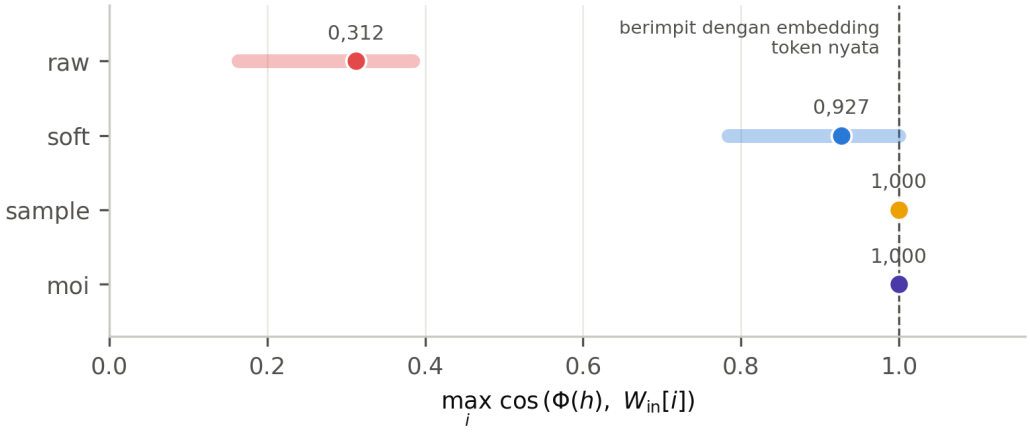
Tabel 4.8 Geometri vektor langkah laten berdasarkan kedekatan terhadap *input embedding* token.

Langkah laten	Vektor yang disisipkan	Konveks	$\max_i \cos$	Rentang
`raw`	$\tau \frac{hM}{\|hM\|}$	tidak	0,312	$[0,164;\ 0,385]$
`soft`	$w = p$	ya	0,927	$[0,784;\ 1,000]$
`sample`	$w = e_y$	ya	1,000	$[1,000;\ 1,000]$
`moi`	$w = \frac{\tilde{H}p + (\beta + 1 - \tilde{H})e_y}{\beta + 1}$	ya	1,000	$[1,000;\ 1,000]$

Tabel 4.8 memperlihatkan pemisahan yang jelas antara `raw` dan tiga metode lainnya. Nilai $\max_i \cos$ pada `raw` hanya sebesar $0{,}312$ dengan rentang $[0{,}164;\ 0{,}385]$. Sebaliknya, `soft` memiliki nilai $0{,}927$, sedangkan `sample` dan `moi` mencapai $1{,}000$ dengan rentang $[1{,}000;\ 1{,}000]$. Dengan demikian, representasi yang dihasilkan oleh `soft`, `sample`, dan `moi` memiliki kedekatan yang jauh lebih tinggi terhadap *embedding* token dibandingkan `raw`.

Perbedaan tersebut sejalan dengan struktur persamaan yang digunakan oleh masing-masing metode. Pada `soft`, `sample`, dan `moi`, representasi dibentuk dari bobot yang berada pada ruang konveks *embedding* token. Sifat tersebut membatasi representasi yang dihasilkan pada ruang yang dibentuk oleh vektor-vektor *embedding* tersebut. Khusus pada `sample`, representasi secara langsung berimpit dengan vektor *embedding* token, sehingga nilai kemiripan maksimum mencapai $1{,}000$. Pada `moi`, nilai yang sama menunjukkan bahwa pada konfigurasi yang diamati terdapat vektor *embedding* yang memiliki arah berimpit dengan representasi yang dihasilkan.

Sebaliknya, `raw` tidak memiliki batasan geometris yang sama. Nilai kemiripan maksimum yang lebih rendah menunjukkan bahwa representasi `raw` cenderung berada lebih jauh dari vektor *embedding* token. Pola tersebut juga terlihat pada Gambar 4.3, yang memperlihatkan pemisahan antara `raw` dan kelompok `soft`, `sample`, dan `moi`.



Gambar 4.3 Kedekatan geometris vektor langkah laten terhadap *input embedding* token.

Untuk menilai apakah rendahnya kedekatan `raw` dapat dijelaskan hanya oleh kemiripan antara ruang sebelum dan sesudah transformasi, digunakan pula beberapa ukuran diagnostik. Jarak relatif transformasi terhadap matriks identitas diperoleh sebesar

$$\frac{\|M - I\|_F}{\|I\|_F} = 1{,}04, \tag{4.2}$$

sedangkan rata-rata kemiripan arah antara h dan hM adalah

$$\overline{\cos(h, hM)} = 0{,}0112. \tag{4.3}$$

Nilai $\|M - I\|_F / \|I\|_F = 1{,}04$ menunjukkan bahwa beda antara matriks transformasi M dan matriks identitas I sedikit lebih besar daripada ukuran matriks identitas itu sendiri. Jadi, M tidak bisa dibilang dekat dengan identitas kalau dilihat dari ukuran ini. Hal ini juga terlihat dari rata-rata kemiripan arah antara h dan hM yang hanya $0{,}0112$. Angka itu sangat dekat dengan nol, jadi hM secara rata-rata tidak lagi searah dengan h. Kedua angka ini sama-sama menunjukkan bahwa transformasi pada `raw` benar-benar mengubah representasi data, bukan hanya mengubah skala atau mempertahankan arah vektor awalnya.

Selain itu, rata-rata kemiripan antara *input embedding* dan *output embedding* pada indeks yang sama adalah

$$\overline{\cos\left(W_{\text{in}}[i], W_{\text{out}}[i]\right)} = 0{,}0041. \tag{4.4}$$

Nilai $0{,}0041$ yang juga sangat dekat dengan nol menunjukkan bahwa *input embedding* dan *output embedding* pada indeks yang sama memiliki kesamaan arah yang sangat rendah. Ini penting karena menunjukkan bahwa kedekatan vektor `raw` dengan *input embedding* tidak bisa dijelaskan hanya dengan anggapan bahwa kedua ruang *embedding* itu punya arah yang hampir sama. Jadi, ketiga ukuran pemeriksaan ini bersama-sama menunjukkan bahwa transformasi dan hubungan antarruang *embedding* pada model yang dipakai memiliki perbedaan arah yang cukup besar.

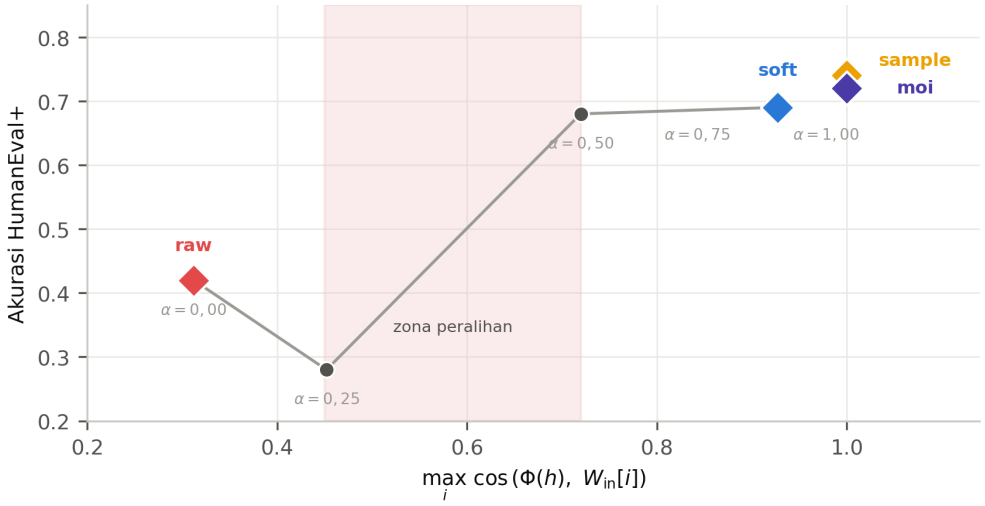
Ketiga ukuran pemeriksaan ini menguatkan bahwa kedekatan `raw` yang rendah dengan *input embedding* bukan hanya akibat transformasi yang mempertahankan arah vektor secara langsung.

Temuan ini menjadi konteks untuk hasil perbandingan berpasangan pada Subbab 4.5.. Pada HumanEval+, `moi` memiliki selisih akurasi $0{,}30$ terhadap `raw`, sedangkan perbedaannya dengan medium teks tidak cukup bukti secara statistik. Pola ini cocok dengan kemungkinan bahwa perbedaan kinerja antara `moi` dan `raw` berkaitan dengan perbedaan sifat geometris representasi laten yang dihasilkan kedua metode.

Namun, kedekatan geometris saja tidak berarti ada hubungan sebab-akibat antara representasi yang lebih dekat dengan *embedding* token dan akurasi. Hasil pada subbab ini menunjukkan adanya perbedaan sifat representasi antarmetode, sedangkan hubungan antara perubahan geometri dan perubahan akurasi perlu dilihat lewat variasi representasi yang dikontrol lebih khusus.

4.7. Kedekatan Geometris dan Akurasi

Hasil pada Subbab 4.6. menunjukkan adanya perbedaan kedekatan geometris antara vektor langkah laten dan *embedding* token, terutama antara `raw` dan metode lainnya. Untuk melihat apakah perubahan kedekatan geometris berkaitan dengan perubahan akurasi, dilakukan percobaan interpolasi dari representasi `raw` menuju `soft`. Percobaan ini digunakan sebagai analisis tambahan untuk melihat



Gambar 4.4 Hubungan kedekatan geometris dengan akurasi HumanEval+ pada sumbu interpolasi dari `raw` menuju `soft`.

perubahan akurasi ketika representasi `raw` secara bertahap digeser menuju representasi `soft`.

Hasil interpolasi disajikan pada Gambar 4.4 dan Tabel 4.9. Nilai $\alpha = 0$ menunjukkan representasi `raw`, sedangkan $\alpha = 1$ menunjukkan representasi `soft`. Kedekatan geometris diukur dengan nilai maksimum kemiripan kosinus terhadap seluruh *input embedding* token. Semakin besar nilainya, semakin dekat representasi laten dengan arah salah satu *embedding* token.

$$s(\alpha) = \max_i \cos\left(z_\alpha, W_{\text{in}}[i]\right). \tag{4.5}$$

Tabel 4.9 Sumbu interpolasi antara `raw` dan `soft`. Vektor langkah laten dibentuk sebagai $(1-\alpha)$ bagian `raw` dan α bagian `soft`, lalu dinormalkan. Kolom kedua adalah kedekatan geometris terhadap *embedding* token nyata, kolom ketiga akurasi HumanEval+ pada $n = 100$ soal yang sama.

α	$\max_i \cos$	Akurasi HumanEval+
$0,00 =$ `raw`	0,312	0,42
$0,25$	0,452	0,28
$0,50$	0,720	0,68
$0,75$	0,924	0,69
$1,00 =$ `soft`	0,927	0,69

Berdasarkan Tabel 4.9, pada $\alpha = 0$, representasi `raw` memiliki kedekatan geometris sebesar $0{,}312$ dan akurasi HumanEval+ sebesar $0{,}42$. Ketika α dinaikkan

menjadi $0{,}25$, kedekatan geometris meningkat menjadi $0{,}452$, tetapi akurasi justru turun menjadi $0{,}28$. Jadi, peningkatan kedekatan geometris pada tahap awal tidak langsung diikuti oleh peningkatan akurasi.

Perubahan yang lebih jelas terlihat mulai dari $\alpha = 0{,}50$. Pada nilai tersebut, kedekatan geometris meningkat menjadi $0{,}720$ dan akurasi naik menjadi $0{,}68$. Selanjutnya, pada $\alpha = 0{,}75$, kedekatan geometris mencapai $0{,}924$ dengan akurasi $0{,}69$. Pada $\alpha = 1$, kedekatan geometris hanya meningkat sedikit menjadi $0{,}927$, sedangkan akurasi tetap sebesar $0{,}69$.

Pola tersebut menunjukkan bahwa perubahan akurasi tidak mengikuti kedekatan geometris secara linear. Pada tahap awal, kenaikan kedekatan dari $0{,}312$ menjadi $0{,}452$ justru disertai penurunan akurasi. Sebaliknya, setelah kedekatan mencapai $0{,}720$, akurasi meningkat dari $0{,}28$ menjadi $0{,}68$ dan kemudian berada pada kisaran $0{,}68$–$0{,}69$. Pada tingkat kedekatan sekitar $0{,}92$, peningkatan kedekatan lebih lanjut tidak lagi diikuti perubahan akurasi yang terlihat.

Dengan demikian, hasil interpolasi menunjukkan adanya hubungan antara posisi geometris representasi dan akurasi HumanEval+. Perubahan akurasi yang lebih besar muncul ketika representasi bergerak cukup jauh dari `raw` menuju `soft`. Hal ini mendukung dugaan bahwa ketidakselarasan geometris `raw` dengan ruang *embedding* token berkaitan dengan kinerjanya pada HumanEval+, meskipun hasil ini belum cukup untuk menyatakan bahwa kedekatan geometris merupakan penyebab langsung perubahan akurasi.

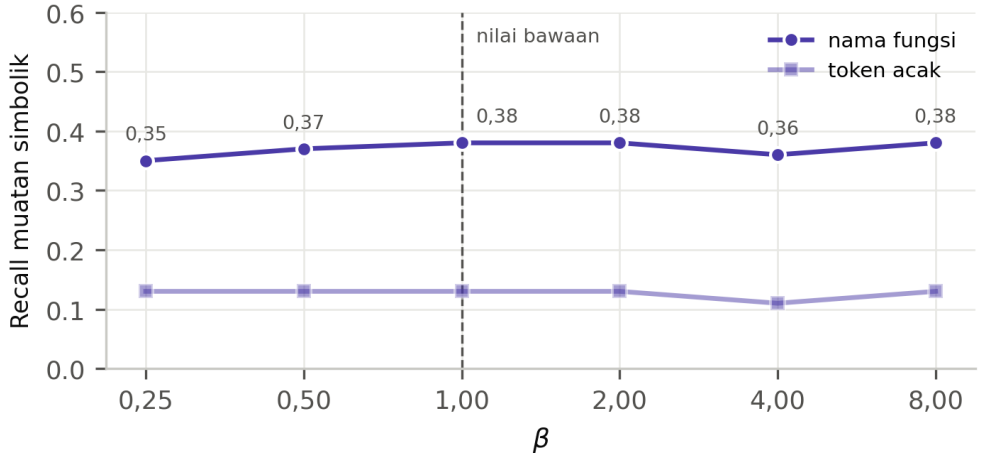
4.8. Ketakpekaan MoI terhadap β

Parameter β pada metode `moi` mengatur bobot relatif antara distribusi p dan token terpilih e_y. Berdasarkan Persamaan (3.92), koefisien distribusi *soft* dapat dituliskan sebagai

$$a = \frac{\tilde{H}}{\beta + 1}, \tag{4.6}$$

sehingga peningkatan β memperkecil kontribusi p dan membuat representa-

si semakin didominasi oleh e_y. Untuk melihat sensitivitas hasil terhadap parameter tersebut, dilakukan variasi β pada rentang $0{,}25$ hingga $8{,}00$. Hasil pengujian disajikan pada Tabel 4.10 dan Gambar 4.5.



Gambar 4.5 Recall informasi simbolik pada berbagai nilai β.

Tabel 4.10 Ketakpekaan MoI terhadap β. Nilai β disapu pada rentang 32 kali lipat sementara seluruh komponen lain dijaga tetap; *recall* diukur pada lengan `kv_latent_only`, $m = 10$, 20 percobaan per nilai.

β	$0,25$	$0,50$	$1,00$	$2,00$	$4,00$	$8,00$
Recall nama fungsi	0,35	0,37	0,38	0,38	0,36	0,38
Recall token acak	0,13	0,13	0,13	0,13	0,11	0,13

Berdasarkan Tabel 4.10, perubahan β tidak menghasilkan perubahan yang besar pada *recall*. Pada *recall* nama fungsi, nilainya berada pada rentang $0{,}35$–$0{,}38$, sedangkan *recall* token acak berada pada rentang $0{,}11$–$0{,}13$. Dengan demikian, meskipun β mengubah bobot komponen penyusun representasi `moi`, perubahan tersebut tidak memberikan pengaruh yang signifikan.

Hasil ini menunjukkan bahwa kinerja kanal laten `moi` tidak banyak berubah saat nilai β diubah pada rentang yang diuji. Jadi, nilai $\beta = 1$ sebagai nilai standar masih bisa dipakai, tanpa perlu mencari parameter khusus untuk mendapatkan kinerja kanal yang jelas berbeda.

4.9. Kinerja Metode Laten

Selain akurasi dan efisiensi, fidelitas keluaran juga diperiksa melalui kemunculan jawaban dengan aksara non-Latin. Hasil pada Tabel 4.11 menunjukkan bahwa `raw` menghasilkan enam kejadian, sedangkan `sample` tidak menghasilkan kejadian tersebut. Pada `soft` dan `moi`, masing-masing hanya terdapat satu kejadian. Hal ini menunjukkan bahwa perbedaan metode tidak hanya terlihat dari nilai akurasi dan efisiensi, tetapi juga pada bentuk keluaran yang dihasilkan.

Tabel 4.11 Jumlah jawaban yang memuat aksara non-Latin pada tugas berbahasa Inggris, dari 100 jawaban per sel.

Tolok ukur	Tunggal	Teks	`raw`	`soft`	`sample`	`moi`
GSM8K	—	0	2	0	0	1
ARC-C	0	0	3	1	0	0
HumanEval+	0	0	1	0	0	0
Jumlah	0	0	6	1	0	1

Untuk melihat kinerja setiap metode secara keseluruhan, hasil akurasi, jumlah *token*, waktu inferensi, dan fidelitas keluaran dirangkum pada Tabel 4.12.

Tabel 4.12 Rekapitulasi lintas tiga tolok ukur (rerata tak berbobot atas GSM8K, ARC-C, dan HumanEval+; kolom terakhir adalah jumlah).

Perlakuan	Akurasi	Laju format	*Token*/soal	Detik/soal	Jawaban rusak
Teks (acuan)	0,863	1,000	974,3	64,8	0
`raw`	0,713	**0,993**	202,6	19,4	6
`soft`	0,837	0,987	156,0	**13,3**	1
`sample`	0,847	0,990	153,1	14,1	**0**
`moi`	**0,850**	**0,993**	**152,1**	15,1	1

Berdasarkan Tabel 4.12, acuan teks menghasilkan akurasi rerata sebesar $0{,}863$ dengan kebutuhan $974{,}3$ *token* dan waktu inferensi $64{,}8$ detik per soal. Sementara itu, `moi` menghasilkan akurasi rerata $0{,}850$ dengan hanya $152{,}1$ *token* dan waktu inferensi $15{,}1$ detik per soal. Artinya, dibandingkan acuan teks, `moi` mengurangi jumlah *token* sekitar $84{,}4\%$ dan waktu inferensi sekitar $76{,}7\%$, dengan akurasi rerata yang tetap dekat dengan acuan.

Akurasi MoI relatif tertinggi jika dibandingkan dengan metode laten lainnya, $0{,}837$ pada `soft`, $0{,}847$ pada `sample`, dan $0{,}713$ pada `raw`. Selain itu, `moi`

menggunakan jumlah *token* paling sedikit, yaitu $152{,}1$ per soal, serta hanya menghasilkan satu jawaban beraksara non-Latin. Kombinasi tersebut menunjukkan bahwa `moi` mampu mempertahankan kinerja mendekati acuan teks dengan kebutuhan sumber daya yang jauh lebih rendah. Hasil ini juga melengkapi analisis sebelumnya mengenai kedekatan geometris representasi dan kapasitas kanal laten, yang menunjukkan bahwa karakteristik representasi `moi` berkaitan dengan kemampuannya dalam mempertahankan informasi sekaligus mengurangi biaya komputasi.

BAB V

KESIMPULAN DAN SARAN

5.1. Kesimpulan

Berdasarkan hasil eksperimen dan analisis yang telah dilakukan, diperoleh beberapa kesimpulan sebagai berikut.

1. Penggunaan medium KV-*cache* dapat mengurangi jumlah *token* yang digunakan dalam komunikasi antargen dibandingkan medium teks. Pada *benchmark* GSM8K, ARC-Challenge, dan HumanEval+, penghematan jumlah *token* berada pada rentang $75{,}0\%$–$87{,}8\%$. Pengurangan jumlah *token* tersebut juga diikuti oleh waktu inferensi yang lebih singkat. Percepatan yang diperoleh berada pada rentang sekitar $2{,}5$–$6{,}1$ kali lebih cepat dibandingkan medium teks. Pada saat yang sama, akurasi keluaran yang diperoleh dengan medium KV-*cache* tidak jauh berbeda dengan medium teks.

2. Di antara metode laten `soft`, `sample`, dan `raw`, `moi` menunjukkan hasil yang kuat pada gabungan akurasi, efisiensi, dan fidelitas keluaran. `moi` menghasilkan akurasi rerata sebesar $0{,}850$ dengan jumlah *token* paling sedikit, yaitu $152{,}1$ per soal dan waktu inferensi rata-rata $15{,}1$ detik per soal. Dibandingkan medium teks yang membutuhkan $974{,}3$ *token* dan $64{,}8$ detik per soal, `moi` mengurangi jumlah *token* sekitar $84{,}4\%$ dan waktu inferensi sekitar $76{,}7\%$.

3. Secara keseluruhan, penelitian ini menunjukkan bahwa komunikasi laten melalui KV-*cache* dapat menjadi alternatif komunikasi berbasis teks yang jauh lebih hemat sumber daya. Namun, hasil yang diperoleh tidak hanya ditentukan oleh medium komunikasi, tetapi juga oleh cara informasi direpresentasikan dan jenis tugas yang dikerjakan. Hasil geometri representasi dan kapasitas kanal laten menunjukkan bahwa keterkaitan representasi dengan ruang

embedding token berkaitan dengan kemampuan mempertahankan informasi simbolik, terutama pada tugas yang membutuhkan presisi simbolik seperti HumanEval+. Dalam kondisi eksperimen penelitian ini, `moi` menunjukkan bahwa efisiensi komunikasi dapat dicapai sekaligus dengan mempertahankan kinerja yang dekat dengan acuan teks.

5.2. Saran

Berdasarkan hasil dan keterbatasan penelitian ini, beberapa hal yang dapat dikembangkan pada penelitian selanjutnya adalah sebagai berikut.

1. Penelitian selanjutnya dapat menggunakan jumlah soal dan jenis *benchmark* yang lebih beragam. Penelitian ini menggunakan 100 soal pada masing-masing GSM8K, ARC-Challenge, dan HumanEval+. Pengujian pada lebih banyak soal dan tugas dengan karakteristik yang berbeda dapat membantu melihat apakah pola efisiensi dan akurasi metode laten tetap muncul pada kondisi yang lebih beragam.

2. Penelitian selanjutnya dapat mengembangkan metode representasi laten selain `raw`, `soft`, `sample`, dan `moi`. Pengembangan metode representasi lain dapat digunakan untuk mengeksplorasi bentuk komunikasi laten yang mampu mempertahankan informasi simbolik dengan kebutuhan *token* dan waktu inferensi yang tetap rendah.

3. Penelitian selanjutnya dapat mengembangkan arsitektur bagian keluaran model untuk mengurangi ketergantungan terhadap ruang *token* dalam proses *decoding* representasi laten. Penggunaan *output head*, *adapter*, atau mekanisme pemetaan keluaran lainnya dapat dieksplorasi untuk mempertahankan informasi laten sebelum dikonversi menjadi *token*.

DAFTAR PUSTAKA

Agresti, A. (2013). *Categorical Data Analysis* (3rd ed.). Hoboken: John Wiley & Sons.

Ainslie, J., Lee-Thorp, J., de Jong, M., Zemlyanskiy, Y., Lebrón, F., & Sanghai, S. (2023). GQA: Training generalized multi-query transformer models from multi-head checkpoints. *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 4895–4901.

Anthropic. (2025). Pricing. *Claude Platform Documentation*. Diakses pada 3 September 2026.

Anton, H., & Rorres, C. (2010). *Elementary Linear Algebra: Applications Version* (10th ed.). Hoboken: John Wiley & Sons.

Austin, J., Odena, A., Nye, M., Bosma, M., Michalewski, H., Dohan, D., Jiang, E., Cai, C., Terry, M., Le, Q., & Sutton, C. (2021). Program synthesis with large language models. *arXiv preprint* arXiv:2108.07732.

Bain, L. J., & Engelhardt, M. (1992). *Introduction to Probability and Mathematical Statistics* (2nd ed.). Boston: PWS-KENT.

Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. New York: Springer.

Boyd, S., & Vandenberghe, L. (2004). *Convex Optimization*. Cambridge: Cambridge University Press.

Casella, G., & Berger, R. L. (2002). *Statistical Inference* (2nd ed.). Pacific Grove: Duxbury.

Chen, M., Tworek, J., Jun, H., Yuan, Q., Pinto, H. P. de O., Kaplan, J., dkk. (2021). Evaluating large language models trained on code. *arXiv preprint* arXiv:2107.03374.

Chen, X., dkk. (2025). *Reasoning beyond language: A comprehensive survey on latent chain-of-thought reasoning*. arXiv:2505.16782.

Clark, P., Cowhey, I., Etzioni, O., Khot, T., Sabharwal, A., Schoenick, C., & Tafjord, O. (2018). Think you have solved question answering? Try ARC, the AI2 Reasoning Challenge. *arXiv preprint* arXiv:1803.05457.

Cobbe, K., Kosaraju, V., Bavarian, M., Chen, M., Jun, H., Kaiser, L., dkk. (2021). Training verifiers to solve math word problems. *arXiv preprint* arXiv:2110.14168.

Cover, T. M., & Thomas, J. A. (2006). *Elements of Information Theory* (2nd ed.). Hoboken: John Wiley & Sons.

Efron, B., & Tibshirani, R. J. (1993). *An Introduction to the Bootstrap*. New York: Chapman & Hall.

Fama, E. F., & French, K. R. (2015). A five-factor asset pricing model. *Journal of Financial Economics*, 116(1), 1–22.

Finin, T., Fritzson, R., McKay, D., & McEntire, R. (1994). KQML as an agent communication language. *Proceedings of the 3rd International Conference on Information and Knowledge Management (CIKM)*, 456–463.

Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 29(5), 1189–1232.

Fu, T., dkk. (2025). *Cache-to-Cache: Direct semantic communication between large language models*. arXiv:2510.03215.

Gelman, A., Carlin, J. B., Stern, H. S., Dunson, D. B., Vehtari, A., & Rubin, D. B. (2013). *Bayesian Data Analysis* (3rd ed.). Boca Raton: CRC Press.

Golub, G. H., & Van Loan, C. F. (2013). *Matrix Computations* (4th ed.). Baltimore: Johns Hopkins University Press.

Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. Cambridge: MIT Press.

Grinold, R. C., & Kahn, R. N. (2000). *Active Portfolio Management: A Quantitative Approach for Producing Superior Returns and Controlling Risk* (2nd ed.). New York: McGraw-Hill.

Gumbel, E. J. (1958). *Statistics of Extremes*. New York: Columbia University Press.

Guo, T., Chen, X., Wang, Y., Chang, R., Pei, S., Chawla, N. V., Wiest, O., & Zhang, X. (2024). *Large language model based multi-agents: A survey of progress and challenges*. arXiv:2402.01680.

Han, J., Zhang, S., Li, W., Dong, Y., Hu, T., dkk. (2026). *QuantaAlpha: An Evolutionary Framework for LLM-Driven Alpha Mining*. arXiv:2602.07085.

Hao, S., Sukhbaatar, S., Su, D., Li, X., Hu, Z., Weston, J., & Tian, Y. (2024). *Training large language models to reason in a continuous latent space*. arXiv:2412.06769.

Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction* (2nd ed.). New York: Springer.

Hoerl, A. E., & Kennard, R. W. (1970). Ridge regression: Biased estimation for nonorthogonal problems. *Technometrics*, 12(1), 55–67.

Holtzman, A., Buys, J., Du, L., Forbes, M., & Choi, Y. (2020). The curious case of neural text degeneration. *International Conference on Learning Representations (ICLR)*.

IBM. (2025). 2025 Cost of a Data Breach Report: Navigating the AI rush without sidelining security. Armonk: IBM Corporation. Diakses pada 3 September 2026.

Jang, E., Gu, S., & Poole, B. (2017). Categorical reparameterization with Gumbel-Softmax. *International Conference on Learning Representations (ICLR)*.

Jensen, M. C. (1968). The performance of mutual funds in the period 1945–1964. *The Journal of Finance*, 23(2), 389–416.

Jin, D., Pan, E., Oufattole, N., Weng, W.-H., Fang, H., & Szolovits, P. (2021). What disease does this patient have? A large-scale open domain question answering dataset from medical exams. *Applied Sciences*, 11(14), 6421.

Johnson, R. A., & Wichern, D. W. (2007). *Applied Multivariate Statistical Analysis* (6th ed.). Upper Saddle River, NJ: Pearson Prentice Hall.

Kakushadze, Z. (2016). 101 formulaic alphas. *Wilmott*, 2016(84), 72–81.

Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems*, 30, 3149–3157.

Kingma, D. P., & Welling, M. (2014). *Auto-encoding variational Bayes*. *Proceedings of the 2nd International Conference on Learning Representations (ICLR)*. arXiv:1312.6114.

Li, Y., Yang, X., Yang, X., Xu, M., Wang, X., Liu, W., & Bian, J. (2025). *R&D-Agent-Quant: A multi-agent framework for data-centric factors and model joint optimization*. arXiv:2505.15155.

Liu, J., Xia, C. S., Wang, Y., & Zhang, L. (2023). Is your code generated by ChatGPT really correct? Rigorous evaluation of large language models for code generation. *Advances in Neural Information Processing Systems (NeurIPS)*, 36.

Luce, R. D. (1959). *Individual Choice Behavior: A Theoretical Analysis*. New York: Wiley.

Maddison, C. J., Mnih, A., & Teh, Y. W. (2017). The Concrete distribution: A continuous relaxation of discrete random variables. *International Conference on Learning Representations (ICLR)*.

Magnus, J. R., & Neudecker, H. (1988). *Matrix Differential Calculus with Applications in Statistics and Econometrics*. Chichester: John Wiley & Sons.

Markowitz, H. (1952). Portfolio selection. *The Journal of Finance*, 7(1), 77–91.

McNemar, Q. (1947). Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika*, 12(2), 153–157.

Zhuang, Y., Liu, S., Cheng, S., Zhang, Y., Wang, X., & Zhang, C. (2025). *Mixture of inputs: Text generation beyond discrete token sampling*. arXiv:2505.14827. Dipresentasikan pada *Advances in Neural Information Processing Systems* (NeurIPS 2025).

Mikolov, T., Chen, K., Corrado, G., & Dean, J. (2013). *Efficient estimation of word representations in vector space*. arXiv:1301.3781.

nostalgebraist. (2020). Interpreting GPT: The logit lens. *LessWrong*.

OpenAI. (2026). Pricing. *OpenAI API Documentation*. Diakses pada 3 September 2026.

Park, K., Choe, Y. J., & Veitch, V. (2024). *The linear representation hypothesis and the geometry of large language models*. Proceedings of the 41st International Conference on Machine Learning (ICML). arXiv:2311.03658.

Rein, D., Hou, B. L., Stickland, A. C., Petty, J., Pang, R. Y., Dirani, J., Michael, J., & Bowman, S. R. (2024). GPQA: A graduate-level Google-proof Q&A benchmark. *Conference on Language Modeling (COLM)*.

Russell, S., & Norvig, P. (2021). *Artificial Intelligence: A Modern Approach* (4th ed.). Hoboken, NJ: Pearson.

Searle, S. R., & Khuri, A. I. (2017). *Matrix Algebra Useful for Statistics* (2nd ed.). Hoboken: John Wiley & Sons.

Sennrich, R., Haddow, B., & Birch, A. (2016). Neural machine translation of rare words with subword units. *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (ACL)*, 1715–1725.

Shannon, C. E. (1948). A mathematical theory of communication. *The Bell System Technical Journal*, 27(3), 379–423.

Sharpe, W. F. (1964). Capital asset prices: A theory of market equilibrium under conditions of risk. *The Journal of Finance*, 19(3), 425–442.

Sharpe, W. F. (1994). The Sharpe ratio. *The Journal of Portfolio Management*, 21(1), 49–58.

Spearman, C. (1904a). The proof and measurement of association between two things. *The American Journal of Psychology*, 15(1), 72–101.

Spearman, C. (1904b). "General intelligence," objectively determined and measured. *The American Journal of Psychology*, 15(2), 201–292.

Stanford Institute for Human-Centered Artificial Intelligence. (2025). *The 2025 AI Index Report*. Stanford: Stanford University. Diakses pada 3 September 2026.

Stanford Institute for Human-Centered Artificial Intelligence. (2026). *The 2026 AI Index Report: Research and development*. Stanford: Stanford University. Diakses pada 3 September 2026.

Su, J., Ahmed, M., Lu, Y., Pan, S., Bo, W., & Liu, Y. (2024). RoFormer: Enhanced transformer with rotary position embedding. *Neurocomputing*, 568, 127063.

Subanar. (2013). *Statistika Matematika*. Yogyakarta: Graha Ilmu.

Tandelilin, E. (2010). *Portofolio dan Investasi: Teori dan Aplikasi* (Edisi Pertama). Yogyakarta: Kanisius.

Tang, Z., Chen, Z., Yang, J., Mai, J., Zheng, Y., Wang, K., Chen, J., & Lin, L. (2025). *AlphaAgent: LLM-driven alpha mining with regularized exploration to counteract alpha decay*. arXiv:2502.16789.

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., & Polosukhin, I. (2017). *Attention is all you need*. *Advances in Neural Information Processing Systems*, 30.

Wei, J., Wang, X., Schuurmans, D., Bosma, M., Ichter, B., Xia, F., Chi, E. H., Le, Q. V., & Zhou, D. (2022). Chain-of-thought prompting elicits reasoning in large language models. *Advances in Neural Information Processing Systems*, 35, 24824–24837.

Wooldridge, M., & Jennings, N. R. (1995). Intelligent agents: Theory and practice. *The Knowledge Engineering Review*, 10(2), 115–152.

Wooldridge, M. (2009). *An Introduction to MultiAgent Systems* (2nd ed.). Chichester: Wiley.

Wu, C., dkk. (2025). LLMs are single-threaded reasoners: Demystifying the working mechanism of soft thinking. *arXiv preprint* arXiv:2508.03440.

Yang, X., Liu, W., Zhou, D., Bian, J., & Liu, T.-Y. (2020). *Qlib: An AI-oriented quantitative investment platform*. arXiv:2009.11189.

Yang, A., dkk. (Qwen Team). (2025). *Qwen3 technical report*. arXiv:2505.09388.

Yu, S., Xue, H., Ao, X., Pan, F., He, J., Tu, D., & He, Q. (2023). Generating synergistic formulaic alpha collections via reinforcement learning. *Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining* (KDD '23).

Zhang, Z., He, X., Yan, W., Shen, A., Zhao, C., Wang, S., Shen, Y., & Wang, X. E. (2025). *Soft thinking: Unlocking the reasoning potential of LLMs in continuous concept space*. arXiv:2505.15778.

Zou, J., Qiu, R., Li, G., Yang, X., Tieu, K., Lu, P., Shen, K., Tong, H., Choi, Y., He, J., Zou, J., Wang, M., & Yang, L. (2025). *Latent collaboration in multi-agent systems*. arXiv:2511.20639.

LAMPIRAN A

Tabel Lengkap Sel Lengan *Benchmark*

Seluruh 21 sel utama lengan *benchmark*. Kolom *format* adalah proporsi keluaran berbentuk sah; kolom CJK adalah cacah jawaban yang memuat aksara Tionghoa pada tugas berbahasa Inggris.

Tugas	Sel	n	Akurasi	SK 95%	Format	Token/soal	CJK
GSM8K	`gumbel/kv`	100	0,91	[0,85; 0,96]	1,00	197	0
GSM8K	`moi/kv`	100	0,92	[0,86; 0,97]	1,00	190	1
GSM8K	`raw/baseline`	100	0,92	[0,86; 0,97]	1,00	—	—
GSM8K	`raw/kv`	100	0,83	[0,75; 0,90]	0,98	212	2
GSM8K	`raw/text`	100	0,90	[0,84; 0,95]	1,00	845	0
GSM8K	`sample/kv`	100	0,86	[0,79; 0,92]	0,97	187	0
GSM8K	`soft/kv`	100	0,88	[0,81; 0,94]	1,00	192	0
ARC-C	`gumbel/kv`	100	0,91	[0,85; 0,96]	0,98	154	1
ARC-C	`moi/kv`	100	0,91	[0,85; 0,96]	0,98	145	0
ARC-C	`raw/baseline`	100	0,91	[0,85; 0,96]	1,00	271	0
ARC-C	`raw/kv`	100	0,89	[0,83; 0,95]	1,00	219	3
ARC-C	`raw/text`	100	0,93	[0,88; 0,98]	1,00	1081	0
ARC-C	`sample/kv`	100	0,94	[0,89; 0,98]	1,00	146	0
ARC-C	`soft/kv`	100	0,94	[0,89; 0,98]	1,00	154	1
HumanEval+	`gumbel/kv`	100	0,71	[0,62; 0,80]	0,97	131	0
HumanEval+	`moi/kv`	100	0,72	[0,63; 0,81]	1,00	122	0
HumanEval+	`raw/baseline`	100	0,72	[0,63; 0,80]	1,00	122	0
HumanEval+	`raw/kv`	100	0,42	[0,32; 0,52]	1,00	177	1
HumanEval+	`raw/text`	100	0,76	[0,68; 0,84]	1,00	997	0
HumanEval+	`sample/kv`	100	0,74	[0,65; 0,82]	1,00	126	0

Tugas	Sel	n	Akurasi	SK 95%	Format	Token/soal	CJK
HumanEval+	`soft/kv`	100	0,69	[0,60; 0,78]	0,96	122	0

LAMPIRAN B

Hasil Lengkap Uji Berpasangan

Seluruh 63 uji McNemar eksak beserta nilai p terkoreksi Holm dan Benjamini–Hochberg. Baris diurutkan menaik menurut p dalam tiap tugas. Kolom n_a dan n_b adalah cacah soal diskordan, yaitu soal yang hanya dijawab benar oleh salah satu perlakuan.

Tugas	Pasangan	Δ	SK 95%	n_a	n_b	p	p
GSM8K	`moi/kv-raw/kv`	+0,090	[+0,01; +0,17]	13	4	0,0490	1,0
GSM8K	`raw/baseline-raw/kv`	+0,090	[+0,01; +0,17]	13	4	0,0490	1,0
GSM8K	`gumbel/kv-raw/kv`	+0,080	[+0,01; +0,16]	12	4	0,0768	1,0
GSM8K	`moi/kv-sample/kv`	+0,060	[-0,01; +0,13]	9	3	0,1460	1,0
GSM8K	`raw/kv-raw/text`	-0,070	[-0,16; +0,02]	7	14	0,1892	1,0
GSM8K	`raw/baseline-sample/kv`	+0,060	[-0,02; +0,14]	11	5	0,2101	1,0
GSM8K	`moi/kv-soft/kv`	+0,040	[-0,01; +0,10]	6	2	0,2891	1,0
GSM8K	`gumbel/kv-sample/kv`	+0,050	[-0,03; +0,13]	11	6	0,3323	1,0
GSM8K	`raw/baseline-soft/kv`	+0,040	[-0,02; +0,10]	7	3	0,3438	1,0
GSM8K	`raw/kv-soft/kv`	-0,050	[-0,14; +0,04]	8	13	0,3833	1,0
GSM8K	`raw/text-sample/kv`	+0,040	[-0,04; +0,12]	11	7	0,4807	1,0
GSM8K	`gumbel/kv-soft/kv`	+0,030	[-0,04; +0,10]	7	4	0,5488	1,0
GSM8K	`raw/kv-sample/kv`	-0,030	[-0,12; +0,05]	8	11	0,6476	1,0
GSM8K	`moi/kv-raw/text`	+0,020	[-0,04; +0,08]	6	4	0,7539	1,0
GSM8K	`raw/baseline-raw/text`	+0,020	[-0,04; +0,08]	6	4	0,7539	1,0
GSM8K	`raw/text-soft/kv`	+0,020	[-0,04; +0,08]	6	4	0,7539	1,0
GSM8K	`sample/kv-soft/kv`	-0,020	[-0,10; +0,06]	8	10	0,8145	1,0
GSM8K	`gumbel/kv-moi/kv`	-0,010	[-0,06; +0,04]	3	4	1,0000	1,0
GSM8K	`gumbel/kv-raw/baseline`	-0,010	[-0,07; +0,05]	4	5	1,0000	1,0
GSM8K	`gumbel/kv-raw/text`	+0,010	[-0,05; +0,08]	6	5	1,0000	1,0

Tugas	Pasangan	Δ	SK 95%	n_a	n_b	p	p
GSM8K	moi/kv−raw/baseline	+0,000	[-0,05; +0,05]	4	4	1,0000	1,0
ARC-C	raw/kv−sample/kv	-0,050	[-0,10; -0,01]	0	5	0,0625	1,0
ARC-C	raw/kv−soft/kv	-0,050	[-0,10; +0,00]	1	6	0,1250	1,0
ARC-C	raw/kv−raw/text	-0,040	[-0,09; +0,00]	1	5	0,2188	1,0
ARC-C	gumbel/kv−sample/kv	-0,030	[-0,08; +0,01]	1	4	0,3750	1,0
ARC-C	gumbel/kv−soft/kv	-0,030	[-0,08; +0,01]	1	4	0,3750	1,0
ARC-C	moi/kv−sample/kv	-0,030	[-0,07; +0,01]	1	4	0,3750	1,0
ARC-C	moi/kv−soft/kv	-0,030	[-0,08; +0,01]	1	4	0,3750	1,0
ARC-C	raw/baseline−sample/kv	-0,030	[-0,07; +0,01]	1	4	0,3750	1,0
ARC-C	raw/baseline−soft/kv	-0,030	[-0,08; +0,01]	1	4	0,3750	1,0
ARC-C	raw/baseline−raw/text	-0,020	[-0,06; +0,02]	1	3	0,6250	1,0
ARC-C	moi/kv−raw/kv	+0,020	[-0,03; +0,07]	4	2	0,6875	1,0
ARC-C	moi/kv−raw/text	-0,020	[-0,07; +0,03]	2	4	0,6875	1,0
ARC-C	raw/baseline−raw/kv	+0,020	[-0,03; +0,07]	4	2	0,6875	1,0
ARC-C	gumbel/kv−raw/kv	+0,020	[-0,03; +0,07]	5	3	0,7266	1,0
ARC-C	gumbel/kv−raw/text	-0,020	[-0,08; +0,03]	3	5	0,7266	1,0
ARC-C	gumbel/kv−moi/kv	+0,000	[-0,06; +0,05]	4	4	1,0000	1,0
ARC-C	gumbel/kv−raw/baseline	+0,000	[-0,06; +0,06]	4	4	1,0000	1,0
ARC-C	moi/kv−raw/baseline	+0,000	[-0,05; +0,05]	3	3	1,0000	1,0
ARC-C	raw/text−sample/kv	-0,010	[-0,05; +0,02]	1	2	1,0000	1,0
ARC-C	raw/text−soft/kv	-0,010	[-0,05; +0,02]	1	2	1,0000	1,0
ARC-C	sample/kv−soft/kv	+0,000	[-0,03; +0,03]	1	1	1,0000	1,0
HumanEval+	raw/kv−sample/kv	-0,320	[-0,42; -0,22]	2	34	0,0000	0,0
HumanEval+	moi/kv−raw/kv	+0,300	[+0,20; +0,40]	32	2	0,0000	0,0
HumanEval+	raw/baseline−raw/kv	+0,300	[+0,20; +0,40]	33	3	0,0000	0,0
HumanEval+	raw/kv−raw/text	-0,340	[-0,45; -0,22]	6	40	0,0000	0,0
HumanEval+	gumbel/kv−raw/kv	+0,290	[+0,19; +0,40]	33	4	0,0000	0,0
HumanEval+	raw/kv−soft/kv	-0,270	[-0,37; -0,17]	4	31	0,0000	0,0
HumanEval+	raw/text−soft/kv	+0,070	[-0,03; +0,17]	16	9	0,2295	1,0

Tugas	Pasangan	Δ	SK 95%	n_a	n_b	p	p
HumanEval+	sample/kv–soft/kv	+0,050	[-0,03; +0,13]	11	6	0,3323	1,0
HumanEval+	gumbel/kv–raw/text	-0,050	[-0,14; +0,04]	8	13	0,3833	1,0
HumanEval+	moi/kv–soft/kv	+0,030	[-0,03; +0,09]	6	3	0,5078	1,0
HumanEval+	moi/kv–raw/text	-0,040	[-0,13; +0,05]	9	13	0,5235	1,0
HumanEval+	raw/baseline–raw/text	-0,040	[-0,13; +0,05]	9	13	0,5235	1,0
HumanEval+	raw/baseline–soft/kv	+0,030	[-0,03; +0,09]	7	4	0,5488	1,0
HumanEval+	gumbel/kv–sample/kv	-0,030	[-0,10; +0,04]	5	8	0,5811	1,0
HumanEval+	moi/kv–sample/kv	-0,020	[-0,09; +0,05]	5	7	0,7744	1,0
HumanEval+	gumbel/kv–soft/kv	+0,020	[-0,05; +0,09]	8	6	0,7905	1,0
HumanEval+	raw/baseline–sample/kv	-0,020	[-0,10; +0,06]	7	9	0,8036	1,0
HumanEval+	raw/text–sample/kv	+0,020	[-0,07; +0,11]	12	10	0,8318	1,0
HumanEval+	gumbel/kv–moi/kv	-0,010	[-0,07; +0,05]	4	5	1,0000	1,0
HumanEval+	gumbel/kv–raw/baseline	-0,010	[-0,08; +0,05]	5	6	1,0000	1,0
HumanEval+	moi/kv–raw/baseline	+0,000	[-0,06; +0,06]	5	5	1,0000	1,0

LAMPIRAN C

Hiperparameter dan Lingkungan Eksekusi

Parameter	Nilai
Model	`Qwen/Qwen3-8B`
Ukuran kosakata V	151.936
Dimensi *hidden* d	4096
Embedding terikat	tidak
Langkah laten m	10
Suhu langkah laten T	0,70
Regularisasi ridge λ	10^{-5}
Parameter MoI β	1
Suhu pembangkitan	0,60
top-p	0,95
Token baru maksimum	2048
Rantai agen	`planner`, `critic`, `refiner`, `judger`
GPU	NVIDIA A40 46 GB, CUDA 12.8
Kerangka kerja	PyTorch 2.6.0+cu124, HuggingFace Transformers